Universidad XXXXX

Programa de Doctorado en XXXXX

Título provisional de la investigación

Estimación de la validez durante la operación para integrar modelos híbridos con aprendizaje en el control de la dinámica vehicular

Doctorando

Director de tesis

Año

Resumen

Índice general

1. Introducción **4**

1.1. Contexto y motivación 5

1.2. Problema de investigación 7

1.2.1. Planta de referencia y modelo interno del controlador 8

1.2.2. Construcción del modelo de bicicleta nominal B0 9

1.2.3. Definición de la corrección residual 11

1.2.4. Datos y entrenamiento del modelo residual 12

1.2.5. Integración del modelo híbrido B1 y validez de la corrección 13

1.3. Alcance del problema (prioridad 1) 14

1.4. Brecha de investigación 14

1.5. Pregunta de investigación 14

1.6. Preguntas específicas de investigación 15

1.7. Hipótesis de investigación 15

2. Objetivos **16**

2.1. Objetivo general 16

2.2. Objetivos específicos 16

3. Fundamentos de dinámica vehicular y control **18**

3.1. Dinámica vehicular relevante para el control 18

3.2. Modelos orientados al control y discrepancias del modelo 18

3.3. Modelos híbridos: física y residuales aprendidos 18

3.4. Control predictivo basado en modelos 18

3.5. Funciones de barrera de control como extensión opcional 18

4. Información aprendida y validez durante la operación **19**

4.1. Información aprendida relevante para el controlador 19

4.2. Incertidumbre predictiva 19

4.2.1. Incertidumbre aleatoria 19

4.2.2. Incertidumbre epistémica 19

4.2.3. Calibración 19

4.3. Detección fuera de distribución y cambios de distribución en la dinámica vehicular . . . 19
4.3.1. Régimen físico no representado . . . 19
4.3.2. Dinámica fuera de distribución . . . 19
4.3.3. Entradas fuera de distribución . . . 19
4.3.4. Fallo o degradación de sensores . . . 19
4.4. Validez y confianza durante la operación . . . 19
4.5. Validez relevante para el control . . . 20

5. Estado del arte **21**
5.1. Estrategia de revisión bibliográfica . . . 21
5.2. Modelos aprendidos e híbridos para el control de la dinámica vehicular . . . 21
5.3. Dinámica aprendida con consideración de la incertidumbre para el control . . . 21
5.4. Detección fuera de distribución, cambios de distribución y supervisión durante la operación . . . 21
5.5. Control con consideración de la validez y la confianza . . . 21
5.6. Síntesis crítica y brecha de investigación . . . 21

6. Marco conceptual y arquitectura propuesta **22**
6.1. La cadena cambio–validez–control . . . 22
6.2. Modelo híbrido de predicción . . . 22
6.3. Estimador de validez . . . 22
6.4. Integración con MPC/NMPC . . . 22
6.5. Extensiones opcionales . . . 22
6.5.1. Modulación de una función de barrera de control (CBF) . . . 22
6.5.2. Adquisición de datos y reentrenamiento . . . 22

7. Metodología de investigación y validación (prioridad 1) **23**
7.1. Estrategia general . . . 23
7.2. Escenarios de cambio de distribución . . . 24
7.2.1. Cambio desconocido de fricción . . . 24
7.2.2. Ampliación del rango de velocidades . . . 24
7.2.3. Fallo o degradación de sensores . . . 24
7.2.4. Entradas fuera de distribución . . . 24
7.3. Modelo aprendido e incertidumbre . . . 24
7.4. Construcción y evaluación de la señal de validez . . . 24
7.5. Uso de la señal de validez en MPC/NMPC . . . 24
7.6. Arquitecturas de referencia y estudio de ablación . . . 24
7.7. Métricas de evaluación . . . 25
7.7.1. Métricas del modelo . . . 25

7.7.2. Métricas de incertidumbre, calibración y detección fuera de distribución . . . 25
7.7.3. Métricas de desempeño en lazo cerrado . . . 25
7.8. Criterio de robustez empírica . . . 25
7.9. Nivel de garantía y alcance de las conclusiones . . . 25
7.10. Análisis estadístico y reproducibilidad . . . 25

8. Resultados preliminares **26**
8.1. Viabilidad del aprendizaje de modelos de dinámica vehicular . . . 26
8.2. Comportamiento de la incertidumbre y de los indicadores fuera de distribución ante cambios de distribución . . . 26
8.3. Integración preliminar con el control . . . 26
8.4. Discusión de los resultados preliminares . . . 26

9. Contribuciones esperadas **27**
9.1. Estimación de la validez relevante para el control . . . 27
9.2. Control vehicular con consideración de la validez . . . 27
9.3. Caracterización de la validez durante la operación . . . 27
9.4. Taxonomía experimental de cambios en la dinámica vehicular . . . 27
9.5. Posibles extensiones . . . 27

10. Plan de trabajo (prioridad 1) **28**
10.1. Actividades pendientes . . . 28
10.2. Cronograma . . . 28
10.3. Hitos de decisión . . . 28

11. Riesgos, limitaciones y estrategias de mitigación **29**
11.1. Riesgo de redundancia entre incertidumbre y detección fuera de distribución 29
11.2. Riesgo de calibración inadecuada o de correlación débil con el error . . . 29
11.3. Riesgo de que la adaptación del horizonte no mejore el desempeño en lazo cerrado . . . 29
11.4. Riesgo computacional . . . 29
11.5. Riesgo de ampliación del alcance . . . 29
11.6. Limitaciones de las garantías formales . . . 29

12. Conclusiones del examen de calificación **30**

Capítulo 1

Introducción

Consideremos a un conductor que circula por una autopista a 100 km/h cuando empieza a llover. Al disminuir la visibilidad, decide detenerse en el arcén. Durante la maniobra, el agua sobre la calzada puede reducir la adherencia entre los neumáticos y la carretera, dificultando el cambio de dirección. Lo que comenzó como un intento de detenerse puede, en estas condiciones, provocar una pérdida de control y un riesgo de colisión con otros vehículos o con las barreras de la vía.

La dificultad de este ejemplo reside en ejecutar una maniobra cuando cambia la adherencia disponible. La dirección y el frenado dependen de las fuerzas transmitidas a través del contacto entre los neumáticos y la carretera, por lo que una variación en estas condiciones puede alterar la capacidad del vehículo para seguir la trayectoria prevista [1].

La adherencia disponible varía con la superficie del pavimento y con las condiciones que se encuentran a lo largo del recorrido. Los estudios sobre fricción del pavimento relacionan la resistencia al deslizamiento con la textura de la superficie y las características de la vía [23, 12]. El agua sobre la calzada puede dificultar el contacto entre los neumáticos y la carretera, mientras que los surcos en las zonas de rodadura pueden retener agua y aumentar el riesgo de hidroplaneo [18].

Estos límites cobran relevancia cuando el conductor necesita cambiar de carril con poco margen de reacción o desviarse para evitar un obstáculo. Las fuerzas laterales necesarias para seguir la trayectoria prevista pueden superar las que el contacto entre los neumáticos y la carretera permite transmitir [1]. A velocidades elevadas y con baja adherencia, esta limitación puede dar lugar a deslizamiento lateral e inestabilidad de guiñada, comprometiendo la maniobra [11].

Los sistemas de control vehicular asisten al conductor en el frenado y el mantenimiento de la estabilidad. El sistema antibloqueo de frenos (ABS) busca evitar que las ruedas se bloqueen durante el frenado [4]. El control electrónico de estabilidad (ESC, por sus siglas en inglés) ayuda a corregir las desviaciones entre el movimiento del vehículo y la dirección que pretende seguir el conductor; el programa electrónico de estabilidad (ESP) de Bosch, introducido en 1995, es una implementación de esta función [3]. Desde entonces,

el desarrollo se ha extendido a la coordinación del frenado, la dirección y la propulsión. Esta coordinación ofrece más posibilidades de actuar sobre el movimiento del vehículo y requiere información sobre su respuesta, incluidos estados y parámetros que pueden necesitar estimarse durante la operación [19].

1.1. Contexto y motivación

La respuesta del vehículo también depende de su masa, su carga y las propiedades de los neumáticos. La fricción y las cargas por eje afectan a la predicción de la distancia de frenado [27], mientras que la masa y la rigidez lateral de los neumáticos intervienen en la descripción del movimiento lateral y de guiñada [26]. En el rango lineal, la rigidez lateral es la pendiente de la relación entre la fuerza lateral del neumático y su ángulo de deriva [19]. Por tanto, describe un aspecto del comportamiento del neumático distinto del límite de fricción: este último acota las fuerzas disponibles, mientras que la rigidez influye en cómo se desarrolla la fuerza lateral con el ángulo de deriva. Las variaciones de estas magnitudes pueden afectar tanto a las fuerzas disponibles para una maniobra como al movimiento que resulta de ellas.

Los estudios sobre control vehicular adaptativo ilustran las consecuencias de estas variaciones. Xu et al. evalúan el seguimiento de trayectoria mediante simulaciones en vías con fricción baja y variable, y obtienen menores errores laterales y de orientación con su estrategia adaptativa que con los controladores de comparación [24]. Yeneneh et al. utilizan estimación de parámetros durante la operación para actualizar un modelo de seguimiento lateral que incluye masa y rigidez lateral. En sus simulaciones, el controlador adaptativo reduce los errores de seguimiento respecto al control predictivo convencional y a un regulador cuadrático lineal [26]. Estos resultados motivan considerar cambios tanto en el entorno vial como en el propio vehículo y examinar si la descripción de la dinámica utilizada para el control sigue siendo representativa.

Los controladores predictivos utilizan un modelo para relacionar las entradas de control con la respuesta que esperan del vehículo. El control predictivo basado en modelos (MPC, por sus siglas en inglés), incluida su formulación no lineal (NMPC), utiliza estas predicciones para seleccionar entradas sobre un horizonte finito, teniendo en cuenta las restricciones [20]. El modelo debe ofrecer suficiente detalle para fundamentar estas decisiones y mantener el problema de control resoluble con los recursos de cómputo disponibles. Chen et al., por ejemplo, emplean un modelo bicicleta simplificado para equilibrar la precisión de la predicción y el costo computacional [8]. Estas simplificaciones pueden introducir discrepancias entre el movimiento predicho y el real. Pan et al. identifican la estructura del modelo y los errores paramétricos como fuentes de estas discrepancias y las consideran en un controlador predictivo robusto [16].

La incertidumbre sobre el valor de un parámetro no implica que este esté cambiando.

Una diferencia entre su valor real y el supuesto puede afectar a las predicciones incluso cuando su valor físico permanece constante. Yeneneh y Sufe consideran la incertidumbre en la masa, las rigideces laterales de los neumáticos delanteros y traseros y la fricción de la carretera dentro de una formulación de control predictivo robusto [25]. Li et al. abordan la incertidumbre en la rigidez lateral y el momento de inercia de guiñada mediante un controlador con acoplamiento longitudinal y lateral, evaluado en pruebas donde hardware real interactúa con una simulación (HIL) [15]. Estos estudios motivan tener en cuenta la incertidumbre paramétrica al utilizar un modelo simplificado para el control.

Conviene, por tanto, distinguir los parámetros físicos del vehículo, los valores nominales utilizados por el modelo y las estimaciones obtenidas a partir de mediciones durante la operación. La estimación puede reducir el error paramétrico, pero no elimina las aproximaciones estructurales del modelo. Chen et al. reflejan esta distinción al combinar la calibración de un modelo físico nominal con la compensación de la dinámica no modelada restante [7]. Su formulación ilustra por qué mejorar la predicción puede requerir tratar discrepancias que la calibración de parámetros por sí sola no recoge.

El modelado híbrido aborda parte de estas discrepancias combinando ecuaciones físicas con información aprendida a partir de datos [9, 29]. En un modelo con un residual aprendido aditivo, el componente físico proporciona una predicción nominal y el componente aprendido estima una corrección a partir de la diferencia entre esa predicción y la respuesta observada [13, 8]. La corrección puede representar efectos que el modelo simplificado no describe de forma adecuada. En la formulación de Kabzan et al., los valores objetivo del entrenamiento se obtienen a partir de transiciones de estado medidas y predicciones nominales, lo que permite aprender el error del modelo sin identificar por separado sus causas físicas [13].

Kabzan et al. utilizan regresión por procesos gaussianos para esta corrección en conducción autónoma de competición. Durante las pruebas con un vehículo de competición a escala real, el modelo corregido mantuvo un error medio de predicción aproximadamente constante a medida que la conducción se volvía más exigente en vueltas sucesivas, mientras que el error del modelo nominal aumentó [13]. El aprendizaje también puede asignarse a componentes individuales de las fuerzas. Zhou et al. combinan un modelo de tracción basado en una red neuronal con la dinámica longitudinal física y un estimador de la masa del vehículo y de un coeficiente modificado de fricción de rodadura. Su evaluación incluye cargas y condiciones de la vía distintas de las utilizadas para el entrenamiento [29]. Se trata de una arquitectura híbrida de modelado de fuerzas y estimación de parámetros, cuya función del aprendizaje difiere de la de un residual aditivo.

Otros enfoques híbridos fusionan modelos físicos y neuronales para predecir la dinámica o acoplan un estimador neuronal con un observador físico para estimar el ángulo de deriva del vehículo [9, 2]. El conocimiento físico también puede orientar el entrenamiento: Wang et al. incluyen residuos de las ecuaciones de equilibrio de fuerzas en el objetivo de

aprendizaje de un modelo de dinámica vehicular [21]. Estos usos del aprendizaje cumplen funciones distintas. En esta tesis, el interés se centra en un residual aditivo dentro del modelo de predicción del controlador, evaluado tanto por la precisión de sus predicciones como por su efecto en el control.

Consideremos, como ejemplo conceptual, un residual entrenado con una determinada carga del vehículo y utilizado después en un recorrido con pasajeros o carga adicionales. Si el modelo nominal y el residual permanecen sin cambios, la corrección aprendida puede dejar de describir la discrepancia bajo la nueva carga. Los cambios en las propiedades de los neumáticos pueden plantear una dificultad similar: velocidades y entradas de dirección conocidas no tienen por qué producir la misma respuesta cuando los parámetros subyacentes son distintos [25].

La carga puede variar entre recorridos y las características de los neumáticos pueden evolucionar durante la conducción. Kalaria et al. aprenden y actualizan un modelo de neumáticos durante la operación para tener en cuenta cambios en su comportamiento de deslizamiento lateral; su evaluación utiliza simuladores numéricos y de alta fidelidad, e incluye cambios simulados que buscan representar el desgaste [14]. En un contexto más general, Brunke et al. identifican la escasez de datos y los cambios de distribución como dificultades prácticas del control basado en aprendizaje [6]. Un cambio no invalida necesariamente un residual aprendido, pero el desempeño en unas condiciones no establece por sí solo su utilidad en otras. Chen et al. identifican la capacidad limitada de una corrección entrenada antes de la operación para adaptarse a nuevas condiciones como una motivación para actualizarla durante la operación [8].

El reto de investigación consiste en evaluar durante la operación si el residual sigue aportando información útil para el control cuando cambia la respuesta del vehículo, y determinar cómo esa evaluación debe influir en el controlador. Para ello, es necesario relacionar el error del modelo con las decisiones a las que afecta, sin que sea imprescindible identificar la causa física de la discrepancia.

1.2. Problema de investigación

Para concretar el problema de investigación, se presenta una estructura de control en la que un MPC utiliza un modelo híbrido compuesto por un modelo de bicicleta y una corrección residual aprendida. Su construcción parte de un modelo físico nominal y utiliza datos de CarSim para entrenar un residual que reduzca las discrepancias entre las predicciones del modelo de bicicleta y la respuesta de esta planta de referencia. A continuación, se describe el papel de cada componente, la obtención de los datos y la integración de la corrección en la predicción utilizada por el controlador.

1.2.1. Planta de referencia y modelo interno del controlador

El uso de formulaciones de alta fidelidad, como las de software comercial tipo CarSim o Adams, garantiza una representación detallada de suspensiones y acoplamientos tridimensionales [22, 28, 10]. Sin embargo, estas formulaciones no lineales son costosas y sufren problemas de identificabilidad cuando los datos son escasos [30].

Además, CarSim no se utiliza como un modelo automotriz embarcado (*on-board*) dentro de las unidades de control electrónico (ECU) de producción debido a su alta complejidad computacional, arquitectura cerrada y formulación multicuerpo no lineal [22, 17]. En la ingeniería automotriz, CarSim actúa como una planta de referencia de alta fidelidad ejecutada en computadoras de escritorio o procesadores de tiempo real dedicados para validar controladores externos, pero no como el modelo interno de cálculo en un procesador embarcado [5].

Esta distinción define la estructura considerada: CarSim proporciona la respuesta de referencia del vehículo, mientras que el MPC utiliza un modelo de bicicleta como base de su predicción. Sobre esta base se construye posteriormente la corrección residual. La figura 1.1 muestra el sistema completo, con la planta CarSim, el controlador MPC y el modelo híbrido que combina la predicción física con la corrección aprendida.

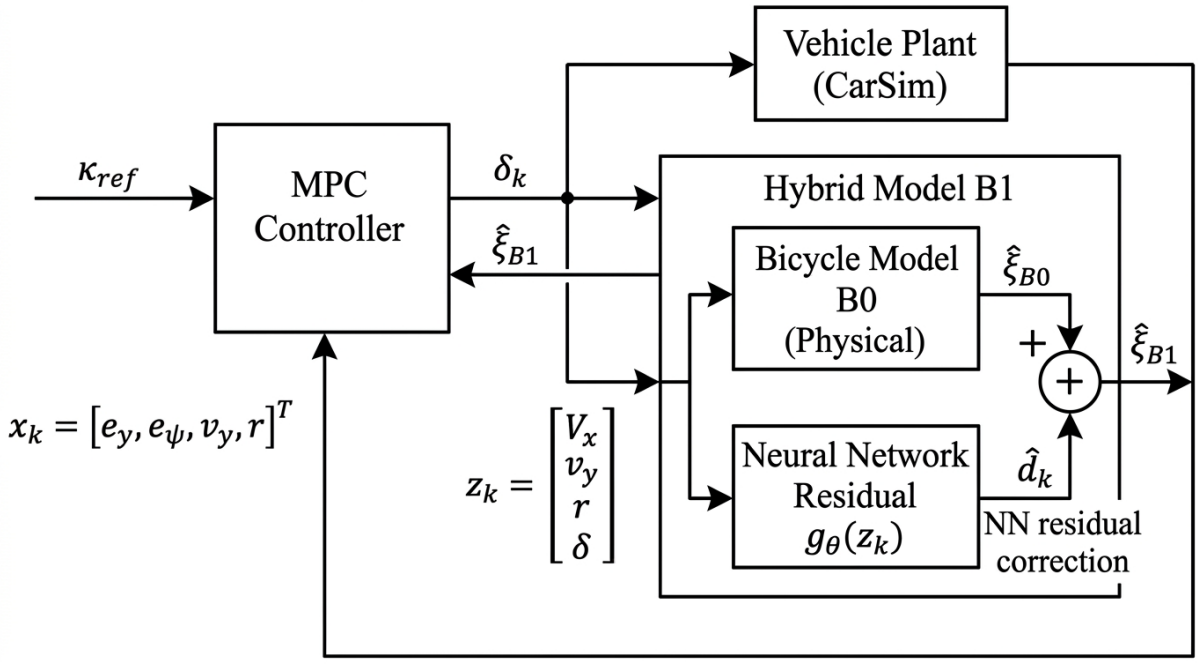


Figura 1.1: Estructura de control con la planta CarSim y el modelo híbrido B1, formado por el modelo de bicicleta B0 y el residual neuronal.

1.2.2. Construcción del modelo de bicicleta nominal B0

El modelo de bicicleta dinámico lineal representa los movimientos lateral y de guiñada del vehículo, considerando pequeños ángulos de deriva de los neumáticos y velocidad longitudinal constante. Para el seguimiento de trayectoria, este modelo se amplía con los errores lateral y de orientación, dando lugar al vector de estados:

$$\mathbf{x} = \begin{bmatrix} e_y & e_\psi & v_y & r \end{bmatrix}^\mathsf{T}, \tag{1.1}$$

donde $e_\psi = \psi - \psi_{\text{ref}}$. La entrada de control es el ángulo efectivo de dirección de las ruedas delanteras, δ, mientras que la curvatura de la trayectoria de referencia, κ_{ref}, constituye una entrada conocida.

La figura 1.2 ilustra la representación del vehículo y las variables asociadas al seguimiento de la trayectoria de referencia.

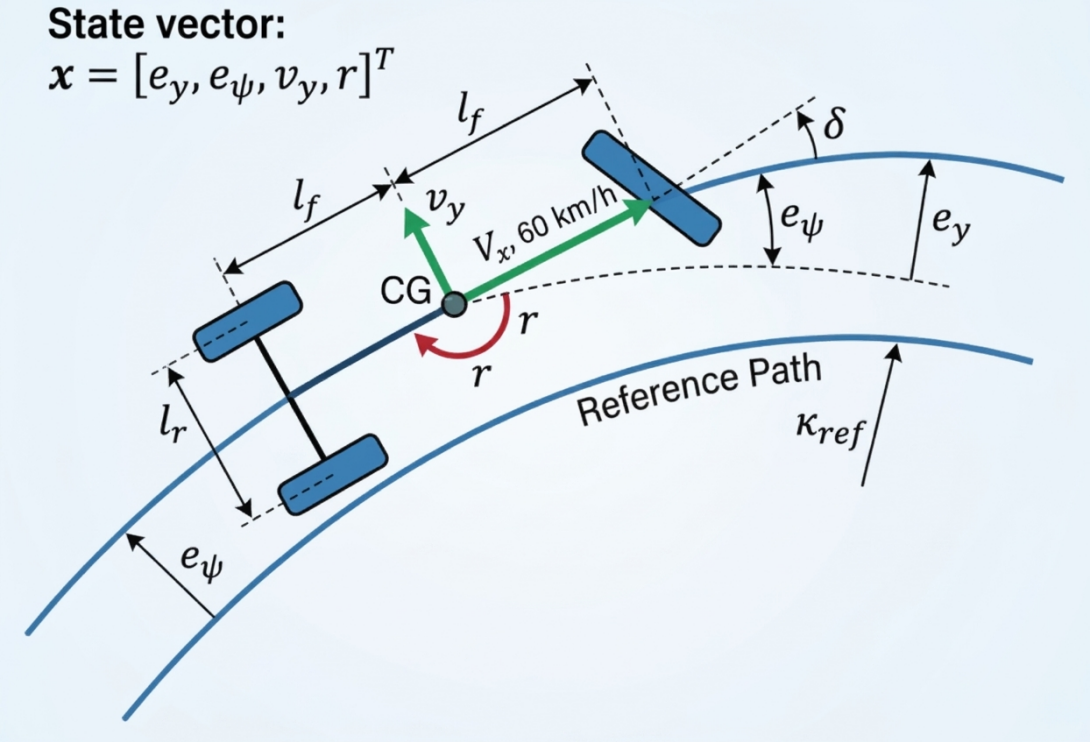


Figura 1.2: Esquema del modelo de bicicleta y de las variables utilizadas para describir el movimiento lateral y el seguimiento de trayectoria.

Las ecuaciones del modelo son

$$\dot{e}_y = V_{x,0} e_\psi + v_y, \tag{1.2}$$

$$\dot{e}_\psi = r - V_{x,0}\kappa_{\text{ref}}, \tag{1.3}$$

$$\dot{v}_y = -\frac{C_f + C_r}{m V_{x,0}} v_y + \left(\frac{C_r l_r - C_f l_f}{m V_{x,0}} - V_{x,0} \right) r + \frac{C_f}{m}\delta, \tag{1.4}$$

$$\dot{r} = \frac{C_r l_r - C_f l_f}{I_z V_{x,0}} v_y - \frac{C_f l_f^2 + C_r l_r^2}{I_z V_{x,0}} r + \frac{C_f l_f}{I_z}\delta. \tag{1.5}$$

Las rigideces laterales C_f y C_r representan valores equivalentes por eje. Las fuerzas laterales se aproximan linealmente, sin saturación explícita por adherencia.

Cuadro 1.1: Estados y entradas del modelo de bicicleta ampliado.

Símbolo	Descripción	Unidad
e_y	Error lateral respecto a la trayectoria	m
e_ψ	Error de orientación	rad
v_y	Velocidad lateral en el centro de gravedad	m/s
r	Velocidad angular de guiñada	rad/s
δ	Ángulo efectivo de dirección delantero	rad
κ_{ref}	Curvatura de la trayectoria de referencia	m^{-1}

A partir de estas ecuaciones, la representación continua en espacio de estados es

$$\dot{\mathbf{x}} = \mathbf{A}_c \mathbf{x} + \mathbf{B}_c \delta + \mathbf{E}_c \kappa_{\text{ref}}, \tag{1.6}$$

con

$$\mathbf{A}_c = \begin{bmatrix} 0 & V_{x,0} & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -\dfrac{C_f + C_r}{m V_{x,0}} & \dfrac{C_r l_r - C_f l_f}{m V_{x,0}} - V_{x,0} \\ 0 & 0 & \dfrac{C_r l_r - C_f l_f}{I_z V_{x,0}} & -\dfrac{C_f l_f^2 + C_r l_r^2}{I_z V_{x,0}} \end{bmatrix}, \tag{1.7}$$

$$\mathbf{B}_c = \begin{bmatrix} 0 \\ 0 \\ C_f/m \\ C_f l_f / I_z \end{bmatrix}, \qquad \mathbf{E}_c = \begin{bmatrix} 0 \\ -V_{x,0} \\ 0 \\ 0 \end{bmatrix}. \tag{1.8}$$

Para utilizarlo en la predicción del MPC, el modelo se discretiza mediante un retenedor de orden cero (*zero-order hold*, ZOH), considerando las entradas constantes en cada intervalo de muestreo:

$$\mathbf{x}_{k+1} = \mathbf{A}_d \mathbf{x}_k + \mathbf{B}_d \delta_k + \mathbf{E}_d \kappa_{\text{ref},k}, \tag{1.9}$$

Cuadro 1.2: Parámetros utilizados en el modelo de bicicleta nominal.

Símbolo	Descripción	Valor	Unidad
m	Masa del vehículo	1501	kg
I_z	Momento de inercia de guiñada	2192,089539	$\mathrm{kg\,m^2}$
l_f	Distancia del CG al eje delantero	1,049562958	m
l_r	Distancia del CG al eje trasero	1,860437042	m
C_f	Rigidez lateral equivalente del eje delantero	159055	N/rad
C_r	Rigidez lateral equivalente del eje trasero	92776,5	N/rad
$V_{x,0}$	Velocidad longitudinal nominal	60/3,6	m/s
T_s	Período de muestreo	0,020	s

donde

$$\mathbf{A}_d = \exp\left(\mathbf{A}_c T_s\right), \tag{1.10}$$

$$\begin{bmatrix}\mathbf{B}_d & \mathbf{E}_d\end{bmatrix} = \int_0^{T_s} \exp\left(\mathbf{A}_c \tau\right) \begin{bmatrix}\mathbf{B}_c & \mathbf{E}_c\end{bmatrix} \mathrm{d}\tau. \tag{1.11}$$

Las matrices se calculan a la velocidad nominal $V_{x,0}$ y se mantienen constantes durante la simulación. Este modelo interno lineal, compuesto únicamente por el modelo de bicicleta, se denomina B0 y constituye la base física sobre la que se incorpora la corrección aprendida.

1.2.3. Definición de la corrección residual

Para complementar la descripción física de B0, se incorpora un modelo residual que estima las discrepancias de predicción de la velocidad lateral y de la velocidad angular de guiñada. La combinación del modelo de bicicleta con esta corrección aprendida se denomina B1. Su propósito es representar parte de la dinámica que no queda recogida por las aproximaciones del modelo nominal, conservando la estructura física como base de la predicción.

Se define el vector de estados laterales como

$$\boldsymbol{\xi}_k = \begin{bmatrix} v_{y,k} \\ r_k \end{bmatrix}. \tag{1.12}$$

La predicción física de estos estados se obtiene mediante

$$\hat{\boldsymbol{\xi}}^{\mathrm{B0}}_{k+1|k} = \mathbf{A}_{\mathrm{lat}} \boldsymbol{\xi}_k + \mathbf{B}_{\mathrm{lat}} \delta_k, \tag{1.13}$$

donde $\mathbf{A}_{\mathrm{lat}} \in \mathbb{R}^{2\times 2}$ y $\mathbf{B}_{\mathrm{lat}} \in \mathbb{R}^{2\times 1}$ son las submatrices de $\mathbf{A}_d$ y $\mathbf{B}_d$ correspondientes a los estados v_y y r, respectivamente.

Una vez definida la predicción física, el residual utilizado como objetivo de entrena-

miento se obtiene como la diferencia entre la respuesta de CarSim en el instante siguiente y la predicción física a un paso:

$$\mathbf{d}_k = \boldsymbol{\xi}_{k+1}^{\mathrm{CarSim}} - \hat{\boldsymbol{\xi}}_{k+1|k}^{\mathrm{B0}} = \begin{bmatrix} d_{v_y,k} \\ d_{r,k} \end{bmatrix}. \tag{1.14}$$

Ambas respuestas se comparan para la misma transición, utilizando el estado inicial y la entrada de dirección correspondientes. El intervalo de predicción coincide con el período de muestreo del controlador, $T_s = 0{,}02\,\mathrm{s}$. Por tanto, las componentes del residual tienen unidades de m/s y rad/s: representan correcciones discretas de los estados, no de sus derivadas.

Para aproximar este residual, se utiliza una red neuronal de tipo *multilayer perceptron* (MLP), cuyo vector de entrada es

$$\mathbf{z}_k = \begin{bmatrix} V_{x,k} & v_{y,k} & r_k & \delta_k \end{bmatrix}^{\mathsf{T}}. \tag{1.15}$$

La red proporciona una estimación determinista de las dos componentes del residual:

$$\hat{\mathbf{d}}_k = \mathbf{g}_{\boldsymbol{\theta}}(\mathbf{z}_k), \tag{1.16}$$

donde $\boldsymbol{\theta}$ agrupa sus pesos y sesgos. Aunque la velocidad longitudinal medida forma parte de las entradas de la red, las matrices del modelo físico permanecen fijas en el punto nominal.

1.2.4. Datos y entrenamiento del modelo residual

Los datos utilizados para ajustar B1 proceden de simulaciones en lazo cerrado con el MPC físico B0 y la planta CarSim. El dominio nominal comprende las maniobras DLC y DLCT, una velocidad de referencia de 60 km/h, un coeficiente de adherencia $\mu = 1$ y el vehículo *C-Class hatchback*. Las muestras se adquieren a 50 Hz y las condiciones externas a este dominio se excluyen del ajuste y de la selección del modelo.

La partición se realiza por corrida completa y por tipo de maniobra. Para cada maniobra, se reserva una corrida para validación y otra para prueba dentro del dominio nominal; las restantes se destinan al entrenamiento. De este modo, ninguna corrida comparte muestras entre particiones. El procedimiento requiere al menos tres corridas por maniobra y utiliza la semilla aleatoria 42 para su asignación.

La arquitectura contiene cuatro entradas, dos capas ocultas de 64 neuronas con activación ReLU y una capa de salida lineal de dos componentes. Las entradas y los objetivos

se estandarizan mediante

$$\tilde{\mathbf{z}}_k = \mathbf{S}_z^{-1}\left(\mathbf{z}_k - \boldsymbol{\mu}_z\right), \tag{1.17}$$

$$\tilde{\mathbf{d}}_k = \mathbf{S}_d^{-1}\left(\mathbf{d}_k - \boldsymbol{\mu}_d\right), \tag{1.18}$$

donde $\boldsymbol{\mu}_z$ y $\boldsymbol{\mu}_d$ son los vectores de medias, mientras que $\mathbf{S}_z$ y $\mathbf{S}_d$ son matrices diagonales con las desviaciones estándar. Estas estadísticas se calculan exclusivamente con los datos de entrenamiento y se mantienen para validación, prueba e inferencia. Los factores de escala inferiores a 10^{-12} se sustituyen por uno.

En el espacio estandarizado, la red se expresa como

$$\mathbf{h}_{1,k} = \rho\left(\mathbf{W}_1\tilde{\mathbf{z}}_k + \mathbf{b}_1\right), \tag{1.19}$$

$$\mathbf{h}_{2,k} = \rho\left(\mathbf{W}_2\mathbf{h}_{1,k} + \mathbf{b}_2\right), \tag{1.20}$$

$$\hat{\tilde{\mathbf{d}}}_k = \mathbf{W}_3\mathbf{h}_{2,k} + \mathbf{b}_3, \tag{1.21}$$

con $\rho(a) = \max(0, a)$ aplicada componente a componente. La salida se transforma nuevamente a unidades físicas mediante

$$\hat{\mathbf{d}}_k = \boldsymbol{\mu}_d + \mathbf{S}_d\hat{\tilde{\mathbf{d}}}_k. \tag{1.22}$$

Con esta representación y la partición de datos definida, el ajuste se realiza con la función `fitrnet` de MATLAB, evaluando dos candidatos con límites de 100 y 200 iteraciones. Se selecciona el candidato que minimiza el RMSE conjunto de validación en el espacio estandarizado:

$$J_{\text{val}} = \sqrt{\frac{1}{2N_{\text{val}}}\sum_{k\in\mathcal{I}_{\text{val}}}\left\|\tilde{\mathbf{d}}_k - \hat{\tilde{\mathbf{d}}}_k\right\|_2^2}, \tag{1.23}$$

donde $\mathcal{I}_{\text{val}}$ contiene los índices de las N_{val} muestras de validación. La estandarización permite combinar ambas componentes sin sumar directamente errores expresados en unidades diferentes. El conjunto de prueba no interviene en la selección.

1.2.5. Integración del modelo híbrido B1 y validez de la corrección

Una vez entrenado el residual, la predicción lateral del modelo híbrido se construye sumando la corrección aprendida a la predicción de B0:

$$\boxed{\hat{\boldsymbol{\xi}}_{k+1|k}^{\text{B1}} = \mathbf{A}_{\text{lat}}\boldsymbol{\xi}_k + \mathbf{B}_{\text{lat}}\delta_k + \mathbf{g}_{\boldsymbol{\theta}}(\mathbf{z}_k).} \tag{1.24}$$

El residual se suma directamente a la predicción física, sin multiplicarlo nuevamente por T_s, porque ya representa una discrepancia sobre un intervalo de muestreo. La evaluación

Cuadro 1.3: Configuración del modelo residual determinista B1.

Elemento	Configuración
Planta de adquisición	CarSim, vehículo *C-Class hatchback*
Controlador de adquisición	MPC físico B0 en lazo cerrado
Dominio nominal	DLC y DLCT, 60 km/h, $\mu = 1$
Período de muestreo	0,02 s
Entradas	V_x, v_y, r y δ
Salidas	Residuos de predicción a un paso de v_y y r
Arquitectura	$4 \to 64 \to 64 \to 2$
Activación oculta	ReLU
Partición de datos	Por corrida completa, separada por maniobra
Estandarización	Estadísticas calculadas solo con entrenamiento
Límites de iteración	100 y 200
Criterio de selección	Menor RMSE conjunto estandarizado de validación
Semilla aleatoria	42

predictiva compara B0 y B1 sobre las mismas transiciones del conjunto de prueba mediante el RMSE y el MAE de cada estado lateral.

Esta estructura permite formular el problema de investigación: el controlador puede continuar utilizando la corrección aprendida cuando cambian las condiciones de operación, aunque su validez predictiva haya disminuido. Como B1 no proporciona una estimación de incertidumbre ni un indicador de validez, su incorporación no permite determinar por sí sola cuándo la corrección sigue siendo adecuada. Una discrepancia en las predicciones utilizadas por el MPC puede afectar la selección de las acciones de control y deteriorar el desempeño en lazo cerrado. Por ello, la evaluación del residual debe considerar tanto su precisión predictiva como las consecuencias de su utilización por el controlador.

1.3. Alcance del problema (prioridad 1)

1.4. Brecha de investigación

1.5. Pregunta de investigación

¿Cómo puede estimarse la validez de un residual aprendido de dinámica vehicular durante la operación y utilizarse para adaptar un controlador MPC/NMPC bajo condiciones de operación no representadas durante el entrenamiento?

1.6. Preguntas específicas de investigación

PI1: ¿Qué tipos de cambios físicamente relevantes en la dinámica vehicular provocan una pérdida significativa de validez del residual aprendido?

PI2: ¿Qué información aportan la incertidumbre epistémica, la incertidumbre aleatoria, la calibración y un indicador de condiciones fuera de distribución (OOD, por sus siglas en inglés) sobre el error del modelo relevante para el control?

PI3: ¿En qué medida las señales de incertidumbre, calibración y OOD son complementarias o redundantes al caracterizar la validez durante la operación?

PI4: ¿Cómo puede construirse una señal de confianza/validez

$$C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$$

que refleje el error relevante para el controlador?

PI5: ¿Cómo debe utilizarse C_k para adaptar el horizonte de MPC/NMPC y reducir la degradación del desempeño en lazo cerrado cuando disminuye la validez del modelo aprendido?

PI6: ¿Qué mejora ofrece la arquitectura propuesta frente a un controlador basado solo en el modelo físico, un controlador que utiliza el modelo aprendido sin supervisar su validez y arquitecturas que utilizan únicamente información de validez o de OOD?

PI7: Como extensión opcional, ¿puede utilizarse la información de validez para modificar la acción de una función de barrera de control (CBF, por sus siglas en inglés) o activar estrategias de actualización de datos o del modelo en respuesta a la incertidumbre epistémica?

1.7. Hipótesis de investigación

Una combinación calibrada de incertidumbre epistémica, incertidumbre aleatoria y evidencia de operación fuera de distribución puede proporcionar una estimación útil de la validez de un residual aprendido de dinámica vehicular durante la operación. Incorporar esta estimación a la adaptación de un controlador MPC/NMPC puede reducir la degradación del desempeño en lazo cerrado ante cambios de régimen, en comparación con arquitecturas que utilizan el modelo aprendido sin considerar su validez.

Capítulo 2

Objetivos

2.1. Objetivo general

Desarrollar y evaluar una metodología de estimación de validez en tiempo real para un modelo híbrido de dinámica vehicular compuesto por un modelo físico y un residual aprendido, e integrar esta estimación en un controlador MPC/NMPC para reducir la degradación del desempeño en lazo cerrado bajo condiciones de operación no representadas durante el entrenamiento.

2.2. Objetivos específicos

OE1: Formular una arquitectura híbrida de dinámica vehicular compuesta por un modelo físico orientado al control y un residual aprendido.

OE2: Definir de forma operativa los tipos de cambio y las situaciones fuera de distribución relevantes para el estudio, distinguiendo al menos los regímenes físicos no representados y la dinámica fuera de distribución, e incluyendo las entradas fuera de distribución si el tiempo lo permite.

OE3: Estimar y calibrar la incertidumbre aleatoria y epistémica del modelo aprendido mediante un modelo heterocedástico y un conjunto reducido de modelos, complementados con un indicador OOD de bajo costo computacional.

OE4: Caracterizar experimentalmente las relaciones entre cambio de distribución, incertidumbre, calibración, OOD, error de predicción y error relevante para el control.

OE5: Definir una representación de confianza/validez durante la operación

$$C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$$

y evaluar su capacidad para anticipar o representar la degradación del modelo de forma útil para el controlador.

OE6: Integrar la señal de validez en un controlador MPC/NMPC mediante la adaptación del horizonte y evaluar su efecto en el desempeño en lazo cerrado y la robustez empírica.

OE7: Comparar el enfoque propuesto con arquitecturas de referencia que permitan aislar los efectos del modelo aprendido, la estimación de validez y la detección fuera de distribución.

OE8: Como extensión, si el calendario lo permite, evaluar el uso de la señal de validez en una CBF y/o en una estrategia de adquisición de datos y reentrenamiento basada en DAgger para condiciones asociadas con la incertidumbre epistémica.

Capítulo 3

Fundamentos de dinámica vehicular y control

3.1. Dinámica vehicular relevante para el control

3.2. Modelos orientados al control y discrepancias del modelo

3.3. Modelos híbridos: física y residuales aprendidos

3.4. Control predictivo basado en modelos

3.5. Funciones de barrera de control como extensión opcional

Capítulo 4

Información aprendida y validez durante la operación

4.1. Información aprendida relevante para el controlador

4.2. Incertidumbre predictiva

4.2.1. Incertidumbre aleatoria

4.2.2. Incertidumbre epistémica

4.2.3. Calibración

4.3. Detección fuera de distribución y cambios de distribución en la dinámica vehicular

4.3.1. Régimen físico no representado

4.3.2. Dinámica fuera de distribución

4.3.3. Entradas fuera de distribución

4.3.4. Fallo o degradación de sensores

4.4. Validez y confianza durante la operación

$$C_k = g(U_{\mathrm{epi},k}, U_{\mathrm{ale},k}, \mathrm{Cal}_k, S_{\mathrm{OOD},k}) \,, \tag{4.1}$$

4.5. Validez relevante para el control

Capítulo 5

Estado del arte

5.1. Estrategia de revisión bibliográfica

5.2. Modelos aprendidos e híbridos para el control de la dinámica vehicular

5.3. Dinámica aprendida con consideración de la incertidumbre para el control

5.4. Detección fuera de distribución, cambios de distribución y supervisión durante la operación

5.5. Control con consideración de la validez y la confianza

5.6. Síntesis crítica y brecha de investigación

Capítulo 6

Marco conceptual y arquitectura propuesta

6.1. La cadena cambio–validez–control

6.2. Modelo híbrido de predicción

6.3. Estimador de validez

6.4. Integración con MPC/NMPC

6.5. Extensiones opcionales

6.5.1. Modulación de una función de barrera de control (CBF)

6.5.2. Adquisición de datos y reentrenamiento

Capítulo 7

Metodología de investigación y validación (prioridad 1)

7.1. Estrategia general

E1: Establecer el modelo físico orientado al control y el controlador MPC/NMPC de referencia.

E2: Entrenar el residual aprendido y cuantificar su mejora y sus limitaciones respecto al modelo físico dentro del dominio nominal.

E3: Implementar la estimación de incertidumbre aleatoria y epistémica, la calibración y una puntuación OOD de bajo costo computacional.

E4: Diseñar cambios físicamente interpretables en la dinámica vehicular y caracterizar sus efectos sobre la predicción, la incertidumbre, OOD y la validez.

E5: Construir y validar la señal C_k frente al error relevante para el control.

E6: Integrar C_k en la adaptación de MPC/NMPC.

E7: Comparar las arquitecturas de referencia y el enfoque propuesto bajo condiciones nominales y fuera de distribución.

E8: Evaluar la robustez empírica y, si el avance lo permite, incorporar las extensiones con CBF y/o DAgger.

7.2. Escenarios de cambio de distribución

7.2.1. Cambio desconocido de fricción

7.2.2. Ampliación del rango de velocidades

7.2.3. Fallo o degradación de sensores

7.2.4. Entradas fuera de distribución

7.3. Modelo aprendido e incertidumbre

7.4. Construcción y evaluación de la señal de validez

7.5. Uso de la señal de validez en MPC/NMPC

7.6. Arquitecturas de referencia y estudio de ablación

B0 – Solo modelo físico:
Controlador que utiliza un modelo físico sin residual aprendido.

B1 – Modelo aprendido sin supervisión de validez:
Controlador que utiliza un modelo físico y un residual aprendido, sin estimación de validez ni detección fuera de distribución.

B2 – Solo validez/incertidumbre:
Controlador que utiliza un modelo aprendido y una señal construida a partir de la incertidumbre y la calibración, sin un componente explícito de detección fuera de distribución.

B3 – Solo detección fuera de distribución:
Controlador que utiliza un modelo aprendido y una respuesta basada únicamente en la puntuación OOD, sin estimación probabilística de incertidumbre.

P – Propuesta:
Controlador que utiliza un modelo físico, un residual aprendido y la señal $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, OOD)$ para adaptar el controlador MPC/NMPC.

7.7. Métricas de evaluación

7.7.1. Métricas del modelo

7.7.2. Métricas de incertidumbre, calibración y detección fuera de distribución

7.7.3. Métricas de desempeño en lazo cerrado

7.8. Criterio de robustez empírica

$$\Delta J_{\text{prop}} < \Delta J_{\text{ref}}, \tag{7.1}$$

7.9. Nivel de garantía y alcance de las conclusiones

7.10. Análisis estadístico y reproducibilidad

Capítulo 8

Resultados preliminares

8.1. Viabilidad del aprendizaje de modelos de dinámica vehicular

8.2. Comportamiento de la incertidumbre y de los indicadores fuera de distribución ante cambios de distribución

8.3. Integración preliminar con el control

8.4. Discusión de los resultados preliminares

Capítulo 9

Contribuciones esperadas

9.1. Estimación de la validez relevante para el control

9.2. Control vehicular con consideración de la validez

9.3. Caracterización de la validez durante la operación

9.4. Taxonomía experimental de cambios en la dinámica vehicular

9.5. Posibles extensiones

Capítulo 10

Plan de trabajo (prioridad 1)

10.1. Actividades pendientes

10.2. Cronograma

10.3. Hitos de decisión

Capítulo 11

Riesgos, limitaciones y estrategias de mitigación

11.1. Riesgo de redundancia entre incertidumbre y detección fuera de distribución

11.2. Riesgo de calibración inadecuada o de correlación débil con el error

11.3. Riesgo de que la adaptación del horizonte no mejore el desempeño en lazo cerrado

11.4. Riesgo computacional

11.5. Riesgo de ampliación del alcance

11.6. Limitaciones de las garantías formales

Capítulo 12

Conclusiones del examen de calificación

Bibliografía

[1] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. Model predictive contouring control for vehicle obstacle avoidance at the limit of handling. In Wei Huang and Mehdi Ahmadian, editors, *Advances in Dynamics of Vehicles on Roads and Tracks III*, volume 2 of *Lecture Notes in Mechanical Engineering*, pages 132–142. Springer, 2024.

[2] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. An unscented Kalman filter-informed neural network for vehicle sideslip angle estimation. *IEEE Transactions on Vehicular Technology*, 73(9):12731–12746, 2024.

[3] Bosch. 30 years of ESP: technology developed by Bosch evolves and continues to shape the future of mobility. Bosch Media Service Brasil, 2025. Press release in Portuguese; title translated into English. Accessed October 12, 2026.

[4] Bosch. Safe braking. Bosch Global, n.d. Accessed October 13, 2026.

[5] M. M. Brugnolli, B. Angélico, Diego Colón, and João Francisco Justo. Predictive electronic stability control: Validation with real-time simulations. *IET Control Theory & Applications*, 2026.

[6] Lukas Brunke, Melissa Greeff, Adam W. Hall, Zhaocong Yuan, Siqi Zhou, Jacopo Panerati, and Angela P. Schoellig. Safe learning in robotics: From learning-based control to safe reinforcement learning. *Annual Review of Control, Robotics, and Autonomous Systems*, 5:411–444, 2022.

[7] Guoying Chen, Chenxiao Bi, Xuanming Zhao, Xinyu Wang, Zhenhai Gao, Wei Deng, Huili Yu, and Liunan Yang. Data-mechanism fused integrated motion control for distributed vehicle considering online model mismatch compensation. *IEEE Transactions on Vehicular Technology*, 75(9):19147–19160, 2026.

[8] Yutao Chen, Jie He, Jun Cheng, Jingli Huang, and Jie Huang. Hybrid offline–online Gaussian process regression-based model predictive control for autonomous vehicles trajectory tracking. *Engineering Applications of Artificial Intelligence*, 182:115841, 2026.

[9] Shuo Cheng, Bin-Bin Hu, Heng-Lai Wei, Liang Li, and Chen Lv. Deep learning-based hybrid dynamic modeling and improved handling stability assessment for autonomous vehicles at driving limits. *IEEE Transactions on Vehicular Technology*, 74(4):5582–5593, 2025. Published online December 11, 2024.

[10] Wei Dai, Yong-Jun Pan, Chuan Min, Shenmin Zhang, and Jian Zhao. Real-time modeling of vehicle's longitudinal-vertical dynamics in adas applications. *Actuators*, 2022.

[11] J. Hu, H. Liu, S. Yi, and C. Huang. Lane-changing control strategy for distributed drive vehicles considering yaw stability. *IET Intelligent Transport Systems*, 19:e12605, 2025.

[12] Miren Isasa, Ángela Alonso-Solórzano, Itziar Gurrutxaga, and Heriberto Pérez-Acebo. A skid resistance predicting model for single carriageways. *Lubricants*, 13(8):365, 2025.

[13] Juraj Kabzan, Lukas Hewing, Alexander Liniger, and Melanie N. Zeilinger. Learning-based model predictive control for autonomous racing. *IEEE Robotics and Automation Letters*, 4(4):3363–3370, 2019.

[14] Dvij Kalaria, Qin Lin, and John M. Dolan. Adaptive planning and control with time-varying tire models for autonomous racing using extreme learning machine. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 10443–10449, 2024.

[15] Lun Li, Deping Wang, Zhicheng Chen, Bing Zhu, Jian Zhao, Haiqiao Li, Jiayi Han, Dongjian Song, and Peixing Zhang. Trajectory-tracking control of autonomous vehicles with dynamic nonlinear coupling characteristics and parameter uncertainty. *International Journal of Automotive Technology*, 27:1035–1049, 2026. Published online September 1, 2025.

[16] Wei Pan, Haoqi Hu, Yiding Hua, Han Wang, Lin Zhang, and Hong Chen. A real-time nonlinear robust MPC strategy for electric vehicle stability with model uncertainty. *Control Engineering Practice*, 172:106894, 2026.

[17] Luigi Pariota, Angelo Coppola, Luca Di Costanzo, Arcangelo Andolfi, Claudio D'Aniello, and G. Bifulco. Integrating tools for an effective testing of connected and automated vehicles technologies. *IET Intelligent Transport Systems*, 2020.

[18] S. Salleh, R. Muhamad, and M.H. Abdillah. Performance of ralumac micro surfacing at blackspot eastbound, latar highway. *IOP Conference Series: Materials Science and Engineering*, 527(1):012054, 2019.

[19] Viktor Skrickij, Paulius Kojis, Eldar Šabanovič, Barys Shyrokau, and Valentin Ivanov. Review of integrated chassis control techniques for automated ground vehicles. *Sensors*, 24(2):600, 2024.

[20] Dongxu Su, Zhiguo Zhao, and Kun Zhao. Reinforcement learning-based tube nonlinear model predictive control for robust trajectory tracking control of autonomous vehicles. *IEEE Transactions on Vehicular Technology*, 75(9):18857–18870, 2026.

[21] Wenjie Wang, Hao Chen, Ran Shu, Solyeon Kwon, Kyoungseok Han, and Hongyu Shu. Adaptive deep Koopman operator for vehicle dynamics modeling: A physics-informed and tire-force-driven approach. *Expert Systems with Applications*, 333:134228, 2027. Available online August 29, 2026.

[22] Yukio Watanabe and M. Sayers. The effect of nonlinear suspension kinematics on the simulated pitching and rolling dynamic behavior of cars. *Vehicle System Dynamics*, 41:23–32, 2026.

[23] Zihang Weng, Zhen Leng, Yuchuan Du, Chenglong Liu, Xinqiang Zhang, Danning Li, and Yulin He. Leveraging tabular prior-data fitted networks for accurate pavement friction coefficient prediction from 3d texture features. *Tribology International*, 218:111794, 2026.

[24] Feixiang Xu, Junkang Feng, Yafei Wang, Xiaoyi Wang, Chuanwang Shen, and Chen Zhou. Parallel self-learning adaptive strategy based on model predictive control for trajectory tracking of autonomous vehicles. *Engineering Applications of Artificial Intelligence*, 173:114495, 2026.

[25] Kumlachew Yeneneh and Gadisa Sufe. AutoDyn: robust model predictive control design for trajectory tracking under varying vehicle dynamics. *Scientific Reports*, 16:25130, 2026.

[26] Kumlachew Yeneneh, Bisrat Yoseph, and Gadisa Sufe. Adaptive model predictive control for robust lateral motion tracking of semi-autonomous vehicles with dynamic parameter variation. *Scientific Reports*, 16:716, 2026. Published online November 30, 2025.

[27] Duk Sun Yun and Byung Chul Lim. Real-time axle-load sensing and AI-enhanced braking-distance prediction for multi-axle heavy-duty trucks. *Applied Sciences*, 16:1547, 2026.

[28] Se-En Yun, Jeonga Lee, Woojae Jang, Daeji Kim, M. Choi, and Jin-Sang Chung. Dynamic modeling and analysis of a driving passenger vehicle. *Applied Sciences*, 2023.

[29] Zhisong Zhou, Yafei Wang, Xulei Liu, Zexing Li, Mingyu Wu, and Guofeng Zhou. Hybrid of neural network and physics-based estimator for vehicle longitudinal dynamics modeling using limited driving data. *IEEE Transactions on Intelligent Transportation Systems*, 26(10):16735–16746, 2025.

[30] Özgür Ünsal and Hakan Yavuz. Bridging regimes: A state-dependent blending methodology for parsimonious and robust heavy vehicle dynamics modeling. *Actuators*, 2025.