Universidad XXXXX

Programa de Doctorado en XXXXX

Título provisional de la investigación

Estimación de la validez durante la operación para integrar modelos híbridos con aprendizaje en el control de la dinámica vehicular

Doctorando

Director de tesis

Año

Resumen

Índice general

1. Introducción **4**

1.1. Contexto y motivación 5
1.2. Problema de investigación 7
1.3. Alcance del problema (prioridad 1) 9
1.4. Brecha de investigación 9
1.5. Pregunta de investigación 9
1.6. Preguntas específicas de investigación 9
1.7. Hipótesis de investigación 10

2. Objetivos **11**

2.1. Objetivo general 11
2.2. Objetivos específicos 11

3. Fundamentos de dinámica vehicular y control **13**

3.1. Dinámica vehicular relevante para el control 13
3.2. Modelos orientados al control y discrepancias del modelo 13
3.3. Modelos híbridos: física y residuales aprendidos 13
3.4. Control predictivo basado en modelos 13
3.5. Funciones de barrera de control como extensión opcional 13

4. Información aprendida y validez durante la operación **14**

4.1. Información aprendida relevante para el controlador 14
4.2. Incertidumbre predictiva 14
4.2.1. Incertidumbre aleatoria 14
4.2.2. Incertidumbre epistémica 14
4.2.3. Calibración 14
4.3. Detección fuera de distribución y cambios de distribución en la dinámica vehicular 14
4.3.1. Régimen físico no representado 14
4.3.2. Dinámica fuera de distribución 14
4.3.3. Entradas fuera de distribución 14

4.3.4. Fallo o degradación de sensores 14
4.4. Validez y confianza durante la operación 14
4.5. Validez relevante para el control 15

5. Estado del arte **16**
5.1. Estrategia de revisión bibliográfica 16
5.2. Modelos aprendidos e híbridos para el control de la dinámica vehicular . . 16
5.3. Dinámica aprendida con consideración de la incertidumbre para el control . 16
5.4. Detección fuera de distribución, cambios de distribución y supervisión durante la operación 16
5.5. Control con consideración de la validez y la confianza 16
5.6. Síntesis crítica y brecha de investigación 16

6. Marco conceptual y arquitectura propuesta **17**
6.1. La cadena cambio–validez–control 17
6.2. Modelo híbrido de predicción 17
6.3. Estimador de validez 17
6.4. Integración con MPC/NMPC 17
6.5. Extensiones opcionales 17
6.5.1. Modulación de una función de barrera de control (CBF) 17
6.5.2. Adquisición de datos y reentrenamiento 17

7. Metodología de investigación y validación (prioridad 1) **18**
7.1. Estrategia general 18
7.2. Escenarios de cambio de distribución 19
7.2.1. Cambio desconocido de fricción 19
7.2.2. Ampliación del rango de velocidades 19
7.2.3. Fallo o degradación de sensores 19
7.2.4. Entradas fuera de distribución 19
7.3. Modelo aprendido e incertidumbre 19
7.4. Construcción y evaluación de la señal de validez 19
7.5. Uso de la señal de validez en MPC/NMPC 19
7.6. Arquitecturas de referencia y estudio de ablación 19
7.7. Métricas de evaluación 20
7.7.1. Métricas del modelo 20
7.7.2. Métricas de incertidumbre, calibración y detección fuera de distribución 20
7.7.3. Métricas de desempeño en lazo cerrado 20
7.8. Criterio de robustez empírica 20
7.9. Nivel de garantía y alcance de las conclusiones 20

7.10. Análisis estadístico y reproducibilidad 20

8. Resultados preliminares **21**
8.1. Viabilidad del aprendizaje de modelos de dinámica vehicular 21
8.2. Comportamiento de la incertidumbre y de los indicadores fuera de distribución ante cambios de distribución 21
8.3. Integración preliminar con el control 21
8.4. Discusión de los resultados preliminares 21

9. Contribuciones esperadas **22**
9.1. Estimación de la validez relevante para el control 22
9.2. Control vehicular con consideración de la validez 22
9.3. Caracterización de la validez durante la operación 22
9.4. Taxonomía experimental de cambios en la dinámica vehicular 22
9.5. Posibles extensiones 22

10. Plan de trabajo (prioridad 1) **23**
10.1. Actividades pendientes 23
10.2. Cronograma 23
10.3. Hitos de decisión 23

11. Riesgos, limitaciones y estrategias de mitigación **24**
11.1. Riesgo de redundancia entre incertidumbre y detección fuera de distribución 24
11.2. Riesgo de calibración inadecuada o de correlación débil con el error 24
11.3. Riesgo de que la adaptación del horizonte no mejore el desempeño en lazo cerrado 24
11.4. Riesgo computacional 24
11.5. Riesgo de ampliación del alcance 24
11.6. Limitaciones de las garantías formales 24

12. Conclusiones del examen de calificación **25**

Capítulo 1

Introducción

Consideremos a un conductor que circula por una autopista a 100 km/h cuando empieza a llover. Al disminuir la visibilidad, decide detenerse en el arcén. Durante la maniobra, el agua sobre la calzada puede reducir la adherencia entre los neumáticos y la carretera, dificultando el cambio de dirección. Lo que comenzó como un intento de detenerse puede, en estas condiciones, provocar una pérdida de control y un riesgo de colisión con otros vehículos o con las barreras de la vía.

La dificultad de este ejemplo reside en ejecutar una maniobra cuando cambia la adherencia disponible. La dirección y el frenado dependen de las fuerzas transmitidas a través del contacto entre los neumáticos y la carretera, por lo que una variación en estas condiciones puede alterar la capacidad del vehículo para seguir la trayectoria prevista [1].

La adherencia disponible varía con la superficie del pavimento y con las condiciones que se encuentran a lo largo del recorrido. Los estudios sobre fricción del pavimento relacionan la resistencia al deslizamiento con la textura de la superficie y las características de la vía [19, 10]. El agua sobre la calzada puede dificultar el contacto entre los neumáticos y la carretera, mientras que los surcos en las zonas de rodadura pueden retener agua y aumentar el riesgo de hidroplaneo [15].

Estos límites cobran relevancia cuando el conductor necesita cambiar de carril con poco margen de reacción o desviarse para evitar un obstáculo. Las fuerzas laterales necesarias para seguir la trayectoria prevista pueden superar las que el contacto entre los neumáticos y la carretera permite transmitir [1]. A velocidades elevadas y con baja adherencia, esta limitación puede dar lugar a deslizamiento lateral e inestabilidad de guiñada, comprometiendo la maniobra [9].

Los sistemas de control vehicular asisten al conductor en el frenado y el mantenimiento de la estabilidad. El sistema antibloqueo de frenos (ABS) busca evitar que las ruedas se bloqueen durante el frenado [4]. El control electrónico de estabilidad (ESC, por sus siglas en inglés) ayuda a corregir las desviaciones entre el movimiento del vehículo y la dirección que pretende seguir el conductor; el programa electrónico de estabilidad (ESP) de Bosch, introducido en 1995, es una implementación de esta función [3]. Desde entonces,

el desarrollo se ha extendido a la coordinación del frenado, la dirección y la propulsión. Esta coordinación ofrece más posibilidades de actuar sobre el movimiento del vehículo y requiere información sobre su respuesta, incluidos estados y parámetros que pueden necesitar estimarse durante la operación [16].

1.1. Contexto y motivación

La respuesta del vehículo también depende de su masa, su carga y las propiedades de los neumáticos. La fricción y las cargas por eje afectan a la predicción de la distancia de frenado [23], mientras que la masa y la rigidez lateral de los neumáticos intervienen en la descripción del movimiento lateral y de guiñada [22]. En el rango lineal, la rigidez lateral es la pendiente de la relación entre la fuerza lateral del neumático y su ángulo de deriva [16]. Por tanto, describe un aspecto del comportamiento del neumático distinto del límite de fricción: este último acota las fuerzas disponibles, mientras que la rigidez influye en cómo se desarrolla la fuerza lateral con el ángulo de deriva. Las variaciones de estas magnitudes pueden afectar tanto a las fuerzas disponibles para una maniobra como al movimiento que resulta de ellas.

Los estudios sobre control vehicular adaptativo ilustran las consecuencias de estas variaciones. Xu et al. evalúan el seguimiento de trayectoria mediante simulaciones en vías con fricción baja y variable, y obtienen menores errores laterales y de orientación con su estrategia adaptativa que con los controladores de comparación [20]. Yeneneh et al. utilizan estimación de parámetros durante la operación para actualizar un modelo de seguimiento lateral que incluye masa y rigidez lateral. En sus simulaciones, el controlador adaptativo reduce los errores de seguimiento respecto al control predictivo convencional y a un regulador cuadrático lineal [22]. Estos resultados motivan considerar cambios tanto en el entorno vial como en el propio vehículo y examinar si la descripción de la dinámica utilizada para el control sigue siendo representativa.

Los controladores predictivos utilizan un modelo para relacionar las entradas de control con la respuesta que esperan del vehículo. El control predictivo basado en modelos (MPC, por sus siglas en inglés), incluida su formulación no lineal (NMPC), utiliza estas predicciones para seleccionar entradas sobre un horizonte finito, teniendo en cuenta las restricciones [17]. El modelo debe ofrecer suficiente detalle para fundamentar estas decisiones y mantener el problema de control resoluble con los recursos de cómputo disponibles. Chen et al., por ejemplo, emplean un modelo bicicleta simplificado para equilibrar la precisión de la predicción y el costo computacional [7]. Estas simplificaciones pueden introducir discrepancias entre el movimiento predicho y el real. Pan et al. identifican la estructura del modelo y los errores paramétricos como fuentes de estas discrepancias y las consideran en un controlador predictivo robusto [14].

La incertidumbre sobre el valor de un parámetro no implica que este esté cambiando.

Una diferencia entre su valor real y el supuesto puede afectar a las predicciones incluso cuando su valor físico permanece constante. Yeneneh y Sufe consideran la incertidumbre en la masa, las rigideces laterales de los neumáticos delanteros y traseros y la fricción de la carretera dentro de una formulación de control predictivo robusto [21]. Li et al. abordan la incertidumbre en la rigidez lateral y el momento de inercia de guiñada mediante un controlador con acoplamiento longitudinal y lateral, evaluado en pruebas donde hardware real interactúa con una simulación (HIL) [13]. Estos estudios motivan tener en cuenta la incertidumbre paramétrica al utilizar un modelo simplificado para el control.

Conviene, por tanto, distinguir los parámetros físicos del vehículo, los valores nominales utilizados por el modelo y las estimaciones obtenidas a partir de mediciones durante la operación. La estimación puede reducir el error paramétrico, pero no elimina las aproximaciones estructurales del modelo. Chen et al. reflejan esta distinción al combinar la calibración de un modelo físico nominal con la compensación de la dinámica no modelada restante [6]. Su formulación ilustra por qué mejorar la predicción puede requerir tratar discrepancias que la calibración de parámetros por sí sola no recoge.

El modelado híbrido aborda parte de estas discrepancias combinando ecuaciones físicas con información aprendida a partir de datos [8, 24]. En un modelo con un residual aprendido aditivo, el componente físico proporciona una predicción nominal y el componente aprendido estima una corrección a partir de la diferencia entre esa predicción y la respuesta observada [11, 7]. La corrección puede representar efectos que el modelo simplificado no describe de forma adecuada. En la formulación de Kabzan et al., los valores objetivo del entrenamiento se obtienen a partir de transiciones de estado medidas y predicciones nominales, lo que permite aprender el error del modelo sin identificar por separado sus causas físicas [11].

Kabzan et al. utilizan regresión por procesos gaussianos para esta corrección en conducción autónoma de competición. Durante las pruebas con un vehículo de competición a escala real, el modelo corregido mantuvo un error medio de predicción aproximadamente constante a medida que la conducción se volvía más exigente en vueltas sucesivas, mientras que el error del modelo nominal aumentó [11]. El aprendizaje también puede asignarse a componentes individuales de las fuerzas. Zhou et al. combinan un modelo de tracción basado en una red neuronal con la dinámica longitudinal física y un estimador de la masa del vehículo y de un coeficiente modificado de fricción de rodadura. Su evaluación incluye cargas y condiciones de la vía distintas de las utilizadas para el entrenamiento [24]. Se trata de una arquitectura híbrida de modelado de fuerzas y estimación de parámetros, cuya función del aprendizaje difiere de la de un residual aditivo.

Otros enfoques híbridos fusionan modelos físicos y neuronales para predecir la dinámica o acoplan un estimador neuronal con un observador físico para estimar el ángulo de deriva del vehículo [8, 2]. El conocimiento físico también puede orientar el entrenamiento: Wang et al. incluyen residuos de las ecuaciones de equilibrio de fuerzas en el objetivo de

aprendizaje de un modelo de dinámica vehicular [18]. Estos usos del aprendizaje cumplen funciones distintas. En esta tesis, el interés se centra en un residual aditivo dentro del modelo de predicción del controlador, evaluado tanto por la precisión de sus predicciones como por su efecto en el control.

Consideremos, como ejemplo conceptual, un residual entrenado con una determinada carga del vehículo y utilizado después en un recorrido con pasajeros o carga adicionales. Si el modelo nominal y el residual permanecen sin cambios, la corrección aprendida puede dejar de describir la discrepancia bajo la nueva carga. Los cambios en las propiedades de los neumáticos pueden plantear una dificultad similar: velocidades y entradas de dirección conocidas no tienen por qué producir la misma respuesta cuando los parámetros subyacentes son distintos [21].

La carga puede variar entre recorridos y las características de los neumáticos pueden evolucionar durante la conducción. Kalaria et al. aprenden y actualizan un modelo de neumáticos durante la operación para tener en cuenta cambios en su comportamiento de deslizamiento lateral; su evaluación utiliza simuladores numéricos y de alta fidelidad, e incluye cambios simulados que buscan representar el desgaste [12]. En un contexto más general, Brunke et al. identifican la escasez de datos y los cambios de distribución como dificultades prácticas del control basado en aprendizaje [5]. Un cambio no invalida necesariamente un residual aprendido, pero el desempeño en unas condiciones no establece por sí solo su utilidad en otras. Chen et al. identifican la capacidad limitada de una corrección entrenada antes de la operación para adaptarse a nuevas condiciones como una motivación para actualizarla durante la operación [7].

El reto de investigación consiste en evaluar durante la operación si el residual sigue aportando información útil para el control cuando cambia la respuesta del vehículo, y determinar cómo esa evaluación debe influir en el controlador. Para ello, es necesario relacionar el error del modelo con las decisiones a las que afecta, sin que sea imprescindible identificar la causa física de la discrepancia.

1.2. Problema de investigación

Para ilustrar el problema de nvestigacion se presenta una estructura de control donde un MPC utiliza un modelo híbrido compuesto por la unión de un modelo de bicicleta con un modelo residual entrenado.

El modelo de bicicleta dinámico lineal representa los movimientos lateral y de guiñada del vehículo, considerando pequeños ángulos de deriva de los neumáticos y velocidad longitudinal constante. Para el seguimiento de trayectoria, este modelo se amplía con los errores lateral y de orientación, dando lugar al vector de estados:

$$\mathbf{x} = \begin{bmatrix} e_y & e_\psi & v_y & r \end{bmatrix}^\mathsf{T}, \tag{1.1}$$

donde $e_\psi = \psi - \psi_{\text{ref}}$. La entrada de control es el ángulo efectivo de dirección de las ruedas delanteras, δ, mientras que la curvatura de la trayectoria de referencia, κ_{ref}, constituye una entrada conocida.

Las ecuaciones del modelo son

$$\dot{e}_y = V_{x,0} e_\psi + v_y, \tag{1.2}$$

$$\dot{e}_\psi = r - V_{x,0} \kappa_{\text{ref}}, \tag{1.3}$$

$$\dot{v}_y = -\frac{C_f + C_r}{m V_{x,0}} v_y + \left(\frac{C_r l_r - C_f l_f}{m V_{x,0}} - V_{x,0} \right) r + \frac{C_f}{m} \delta, \tag{1.4}$$

$$\dot{r} = \frac{C_r l_r - C_f l_f}{I_z V_{x,0}} v_y - \frac{C_f l_f^2 + C_r l_r^2}{I_z V_{x,0}} r + \frac{C_f l_f}{I_z} \delta. \tag{1.5}$$

Las rigideces laterales C_f y C_r representan valores equivalentes por eje. Las fuerzas laterales se aproximan linealmente, sin saturación explícita por adherencia.

Cuadro 1.1: Estados y entradas del modelo de bicicleta ampliado.

Símbolo	Descripción	Unidad
e_y	Error lateral respecto a la trayectoria	m
e_ψ	Error de orientación	rad
v_y	Velocidad lateral en el centro de gravedad	m/s
r	Velocidad angular de guiñada	rad/s
δ	Ángulo efectivo de dirección delantero	rad
κ_{ref}	Curvatura de la trayectoria de referencia	m^{-1}

La representación continua en espacio de estados es

$$\dot{\mathbf{x}} = \mathbf{A}_c \mathbf{x} + \mathbf{B}_c \delta + \mathbf{E}_c \kappa_{\text{ref}}, \tag{1.6}$$

con

$$\mathbf{A}_c = \begin{bmatrix} 0 & V_{x,0} & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -\dfrac{C_f + C_r}{m V_{x,0}} & \dfrac{C_r l_r - C_f l_f}{m V_{x,0}} - V_{x,0} \\ 0 & 0 & \dfrac{C_r l_r - C_f l_f}{I_z V_{x,0}} & -\dfrac{C_f l_f^2 + C_r l_r^2}{I_z V_{x,0}} \end{bmatrix}, \tag{1.7}$$

$$\mathbf{B}_c = \begin{bmatrix} 0 \\ 0 \\ C_f/m \\ C_f l_f / I_z \end{bmatrix}, \qquad \mathbf{E}_c = \begin{bmatrix} 0 \\ -V_{x,0} \\ 0 \\ 0 \end{bmatrix}. \tag{1.8}$$

El modelo se discretiza mediante un retenedor de orden cero (*zero-order hold*, ZOH),

Cuadro 1.2: Parámetros utilizados en el modelo de bicicleta nominal.

Símbolo	Descripción	Valor	Unidad
m	Masa del vehículo	1501	kg
I_z	Momento de inercia de guiñada	2192,089539	$\mathrm{kg\,m^2}$
l_f	Distancia del CG al eje delantero	1,049562958	m
l_r	Distancia del CG al eje trasero	1,860437042	m
C_f	Rigidez lateral equivalente del eje delantero	159055	N/rad
C_r	Rigidez lateral equivalente del eje trasero	92776,5	N/rad
$V_{x,0}$	Velocidad longitudinal nominal	60/3,6	m/s
T_s	Período de muestreo	0,020	s

considerando las entradas constantes en cada intervalo de muestreo:

$$\mathbf{x}_{k+1} = \mathbf{A}_d \mathbf{x}_k + \mathbf{B}_d \delta_k + \mathbf{E}_d \kappa_{\mathrm{ref},k}, \tag{1.9}$$

donde

$$\mathbf{A}_d = \exp\left(\mathbf{A}_c T_s\right), \tag{1.10}$$

$$\begin{bmatrix}\mathbf{B}_d & \mathbf{E}_d\end{bmatrix} = \int_0^{T_s} \exp\left(\mathbf{A}_c \tau\right) \begin{bmatrix}\mathbf{B}_c & \mathbf{E}_c\end{bmatrix} \mathrm{d}\tau. \tag{1.11}$$

Las matrices se calculan a la velocidad nominal $V_{x,0}$ y se mantienen constantes durante la simulación. Así, el modelo interno utilizado en B0 es lineal e invariante en el tiempo, sin corrección residual aprendida.

1.3. Alcance del problema (prioridad 1)

1.4. Brecha de investigación

1.5. Pregunta de investigación

¿Cómo puede estimarse la validez de un residual aprendido de dinámica vehicular durante la operación y utilizarse para adaptar un controlador MPC/NMPC bajo condiciones de operación no representadas durante el entrenamiento?

1.6. Preguntas específicas de investigación

PI1: ¿Qué tipos de cambios físicamente relevantes en la dinámica vehicular provocan una pérdida significativa de validez del residual aprendido?

PI2: ¿Qué información aportan la incertidumbre epistémica, la incertidumbre aleatoria, la calibración y un indicador de condiciones fuera de distribución (OOD, por sus siglas en inglés) sobre el error del modelo relevante para el control?

PI3: ¿En qué medida las señales de incertidumbre, calibración y OOD son complementarias o redundantes al caracterizar la validez durante la operación?

PI4: ¿Cómo puede construirse una señal de confianza/validez

$$C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$$

que refleje el error relevante para el controlador?

PI5: ¿Cómo debe utilizarse C_k para adaptar el horizonte de MPC/NMPC y reducir la degradación del desempeño en lazo cerrado cuando disminuye la validez del modelo aprendido?

PI6: ¿Qué mejora ofrece la arquitectura propuesta frente a un controlador basado solo en el modelo físico, un controlador que utiliza el modelo aprendido sin supervisar su validez y arquitecturas que utilizan únicamente información de validez o de OOD?

PI7: Como extensión opcional, ¿puede utilizarse la información de validez para modificar la acción de una función de barrera de control (CBF, por sus siglas en inglés) o activar estrategias de actualización de datos o del modelo en respuesta a la incertidumbre epistémica?

1.7. Hipótesis de investigación

Una combinación calibrada de incertidumbre epistémica, incertidumbre aleatoria y evidencia de operación fuera de distribución puede proporcionar una estimación útil de la validez de un residual aprendido de dinámica vehicular durante la operación. Incorporar esta estimación a la adaptación de un controlador MPC/NMPC puede reducir la degradación del desempeño en lazo cerrado ante cambios de régimen, en comparación con arquitecturas que utilizan el modelo aprendido sin considerar su validez.

Capítulo 2

Objetivos

2.1. Objetivo general

Desarrollar y evaluar una metodología de estimación de validez en tiempo real para un modelo híbrido de dinámica vehicular compuesto por un modelo físico y un residual aprendido, e integrar esta estimación en un controlador MPC/NMPC para reducir la degradación del desempeño en lazo cerrado bajo condiciones de operación no representadas durante el entrenamiento.

2.2. Objetivos específicos

OE1: Formular una arquitectura híbrida de dinámica vehicular compuesta por un modelo físico orientado al control y un residual aprendido.

OE2: Definir de forma operativa los tipos de cambio y las situaciones fuera de distribución relevantes para el estudio, distinguiendo al menos los regímenes físicos no representados y la dinámica fuera de distribución, e incluyendo las entradas fuera de distribución si el tiempo lo permite.

OE3: Estimar y calibrar la incertidumbre aleatoria y epistémica del modelo aprendido mediante un modelo heterocedástico y un conjunto reducido de modelos, complementados con un indicador OOD de bajo costo computacional.

OE4: Caracterizar experimentalmente las relaciones entre cambio de distribución, incertidumbre, calibración, OOD, error de predicción y error relevante para el control.

OE5: Definir una representación de confianza/validez durante la operación

$$C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$$

y evaluar su capacidad para anticipar o representar la degradación del modelo de forma útil para el controlador.

OE6: Integrar la señal de validez en un controlador MPC/NMPC mediante la adaptación del horizonte y evaluar su efecto en el desempeño en lazo cerrado y la robustez empírica.

OE7: Comparar el enfoque propuesto con arquitecturas de referencia que permitan aislar los efectos del modelo aprendido, la estimación de validez y la detección fuera de distribución.

OE8: Como extensión, si el calendario lo permite, evaluar el uso de la señal de validez en una CBF y/o en una estrategia de adquisición de datos y reentrenamiento basada en DAgger para condiciones asociadas con la incertidumbre epistémica.

Capítulo 3

Fundamentos de dinámica vehicular y control

3.1. Dinámica vehicular relevante para el control

3.2. Modelos orientados al control y discrepancias del modelo

3.3. Modelos híbridos: física y residuales aprendidos

3.4. Control predictivo basado en modelos

3.5. Funciones de barrera de control como extensión opcional

Capítulo 4

Información aprendida y validez durante la operación

4.1. Información aprendida relevante para el controlador

4.2. Incertidumbre predictiva

4.2.1. Incertidumbre aleatoria

4.2.2. Incertidumbre epistémica

4.2.3. Calibración

4.3. Detección fuera de distribución y cambios de distribución en la dinámica vehicular

4.3.1. Régimen físico no representado

4.3.2. Dinámica fuera de distribución

4.3.3. Entradas fuera de distribución

4.3.4. Fallo o degradación de sensores

4.4. Validez y confianza durante la operación

$$C_k = g(U_{\mathrm{epi},k}, U_{\mathrm{ale},k}, \mathrm{Cal}_k, S_{\mathrm{OOD},k}) \,, \tag{4.1}$$

4.5. Validez relevante para el control

Capítulo 5

Estado del arte

5.1. Estrategia de revisión bibliográfica

5.2. Modelos aprendidos e híbridos para el control de la dinámica vehicular

5.3. Dinámica aprendida con consideración de la incertidumbre para el control

5.4. Detección fuera de distribución, cambios de distribución y supervisión durante la operación

5.5. Control con consideración de la validez y la confianza

5.6. Síntesis crítica y brecha de investigación

Capítulo 6

Marco conceptual y arquitectura propuesta

6.1. La cadena cambio–validez–control

6.2. Modelo híbrido de predicción

6.3. Estimador de validez

6.4. Integración con MPC/NMPC

6.5. Extensiones opcionales

6.5.1. Modulación de una función de barrera de control (CBF)

6.5.2. Adquisición de datos y reentrenamiento

Capítulo 7

Metodología de investigación y validación (prioridad 1)

7.1. Estrategia general

E1: Establecer el modelo físico orientado al control y el controlador MPC/NMPC de referencia.

E2: Entrenar el residual aprendido y cuantificar su mejora y sus limitaciones respecto al modelo físico dentro del dominio nominal.

E3: Implementar la estimación de incertidumbre aleatoria y epistémica, la calibración y una puntuación OOD de bajo costo computacional.

E4: Diseñar cambios físicamente interpretables en la dinámica vehicular y caracterizar sus efectos sobre la predicción, la incertidumbre, OOD y la validez.

E5: Construir y validar la señal C_k frente al error relevante para el control.

E6: Integrar C_k en la adaptación de MPC/NMPC.

E7: Comparar las arquitecturas de referencia y el enfoque propuesto bajo condiciones nominales y fuera de distribución.

E8: Evaluar la robustez empírica y, si el avance lo permite, incorporar las extensiones con CBF y/o DAgger.

7.2. Escenarios de cambio de distribución

7.2.1. Cambio desconocido de fricción

7.2.2. Ampliación del rango de velocidades

7.2.3. Fallo o degradación de sensores

7.2.4. Entradas fuera de distribución

7.3. Modelo aprendido e incertidumbre

7.4. Construcción y evaluación de la señal de validez

7.5. Uso de la señal de validez en MPC/NMPC

7.6. Arquitecturas de referencia y estudio de ablación

B0 – Solo modelo físico:
Controlador que utiliza un modelo físico sin residual aprendido.

B1 – Modelo aprendido sin supervisión de validez:
Controlador que utiliza un modelo físico y un residual aprendido, sin estimación de validez ni detección fuera de distribución.

B2 – Solo validez/incertidumbre:
Controlador que utiliza un modelo aprendido y una señal construida a partir de la incertidumbre y la calibración, sin un componente explícito de detección fuera de distribución.

B3 – Solo detección fuera de distribución:
Controlador que utiliza un modelo aprendido y una respuesta basada únicamente en la puntuación OOD, sin estimación probabilística de incertidumbre.

P – Propuesta:
Controlador que utiliza un modelo físico, un residual aprendido y la señal $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, OOD)$ para adaptar el controlador MPC/NMPC.

7.7. Métricas de evaluación

7.7.1. Métricas del modelo

7.7.2. Métricas de incertidumbre, calibración y detección fuera de distribución

7.7.3. Métricas de desempeño en lazo cerrado

7.8. Criterio de robustez empírica

$$\Delta J_{\text{prop}} < \Delta J_{\text{ref}}, \tag{7.1}$$

7.9. Nivel de garantía y alcance de las conclusiones

7.10. Análisis estadístico y reproducibilidad

Capítulo 8

Resultados preliminares

8.1. Viabilidad del aprendizaje de modelos de dinámica vehicular

8.2. Comportamiento de la incertidumbre y de los indicadores fuera de distribución ante cambios de distribución

8.3. Integración preliminar con el control

8.4. Discusión de los resultados preliminares

Capítulo 9

Contribuciones esperadas

9.1. Estimación de la validez relevante para el control

9.2. Control vehicular con consideración de la validez

9.3. Caracterización de la validez durante la operación

9.4. Taxonomía experimental de cambios en la dinámica vehicular

9.5. Posibles extensiones

Capítulo 10

Plan de trabajo (prioridad 1)

10.1. Actividades pendientes

10.2. Cronograma

10.3. Hitos de decisión

Capítulo 11

Riesgos, limitaciones y estrategias de mitigación

11.1. Riesgo de redundancia entre incertidumbre y detección fuera de distribución

11.2. Riesgo de calibración inadecuada o de correlación débil con el error

11.3. Riesgo de que la adaptación del horizonte no mejore el desempeño en lazo cerrado

11.4. Riesgo computacional

11.5. Riesgo de ampliación del alcance

11.6. Limitaciones de las garantías formales

Capítulo 12

Conclusiones del examen de calificación

Bibliografía

[1] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. Model predictive contouring control for vehicle obstacle avoidance at the limit of handling. In Wei Huang and Mehdi Ahmadian, editors, *Advances in Dynamics of Vehicles on Roads and Tracks III*, volume 2 of *Lecture Notes in Mechanical Engineering*, pages 132–142. Springer, 2024.

[2] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. An unscented Kalman filter-informed neural network for vehicle sideslip angle estimation. *IEEE Transactions on Vehicular Technology*, 73(9):12731–12746, 2024.

[3] Bosch. 30 years of ESP: technology developed by Bosch evolves and continues to shape the future of mobility. Bosch Media Service Brasil, 2025. Press release in Portuguese; title translated into English. Accessed October 12, 2026.

[4] Bosch. Safe braking. Bosch Global, n.d. Accessed October 13, 2026.

[5] Lukas Brunke, Melissa Greeff, Adam W. Hall, Zhaocong Yuan, Siqi Zhou, Jacopo Panerati, and Angela P. Schoellig. Safe learning in robotics: From learning-based control to safe reinforcement learning. *Annual Review of Control, Robotics, and Autonomous Systems*, 5:411–444, 2022.

[6] Guoying Chen, Chenxiao Bi, Xuanming Zhao, Xinyu Wang, Zhenhai Gao, Wei Deng, Huili Yu, and Liunan Yang. Data-mechanism fused integrated motion control for distributed vehicle considering online model mismatch compensation. *IEEE Transactions on Vehicular Technology*, 75(9):19147–19160, 2026.

[7] Yutao Chen, Jie He, Jun Cheng, Jingli Huang, and Jie Huang. Hybrid offline–online Gaussian process regression-based model predictive control for autonomous vehicles trajectory tracking. *Engineering Applications of Artificial Intelligence*, 182:115841, 2026.

[8] Shuo Cheng, Bin-Bin Hu, Heng-Lai Wei, Liang Li, and Chen Lv. Deep learning-based hybrid dynamic modeling and improved handling stability assessment for autonomous vehicles at driving limits. *IEEE Transactions on Vehicular Technology*, 74(4):5582–5593, 2025. Published online December 11, 2024.

[9] J. Hu, H. Liu, S. Yi, and C. Huang. Lane-changing control strategy for distributed drive vehicles considering yaw stability. *IET Intelligent Transport Systems*, 19:e12605, 2025.

[10] Miren Isasa, Ángela Alonso-Solórzano, Itziar Gurrutxaga, and Heriberto Pérez-Acebo. A skid resistance predicting model for single carriageways. *Lubricants*, 13(8):365, 2025.

[11] Juraj Kabzan, Lukas Hewing, Alexander Liniger, and Melanie N. Zeilinger. Learning-based model predictive control for autonomous racing. *IEEE Robotics and Automation Letters*, 4(4):3363–3370, 2019.

[12] Dvij Kalaria, Qin Lin, and John M. Dolan. Adaptive planning and control with time-varying tire models for autonomous racing using extreme learning machine. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 10443–10449, 2024.

[13] Lun Li, Deping Wang, Zhicheng Chen, Bing Zhu, Jian Zhao, Haiqiao Li, Jiayi Han, Dongjian Song, and Peixing Zhang. Trajectory-tracking control of autonomous vehicles with dynamic nonlinear coupling characteristics and parameter uncertainty. *International Journal of Automotive Technology*, 27:1035–1049, 2026. Published online September 1, 2025.

[14] Wei Pan, Haoqi Hu, Yiding Hua, Han Wang, Lin Zhang, and Hong Chen. A real-time nonlinear robust MPC strategy for electric vehicle stability with model uncertainty. *Control Engineering Practice*, 172:106894, 2026.

[15] S. Salleh, R. Muhamad, and M.H. Abdillah. Performance of ralumac micro surfacing at blackspot eastbound, latar highway. *IOP Conference Series: Materials Science and Engineering*, 527(1):012054, 2019.

[16] Viktor Skrickij, Paulius Kojis, Eldar Šabanovič, Barys Shyrokau, and Valentin Ivanov. Review of integrated chassis control techniques for automated ground vehicles. *Sensors*, 24(2):600, 2024.

[17] Dongxu Su, Zhiguo Zhao, and Kun Zhao. Reinforcement learning-based tube nonlinear model predictive control for robust trajectory tracking control of autonomous vehicles. *IEEE Transactions on Vehicular Technology*, 75(9):18857–18870, 2026.

[18] Wenjie Wang, Hao Chen, Ran Shu, Solyeon Kwon, Kyoungseok Han, and Hongyu Shu. Adaptive deep Koopman operator for vehicle dynamics modeling: A physics-informed and tire-force-driven approach. *Expert Systems with Applications*, 333:134228, 2027. Available online August 29, 2026.

[19] Zihang Weng, Zhen Leng, Yuchuan Du, Chenglong Liu, Xinqiang Zhang, Danning Li, and Yulin He. Leveraging tabular prior-data fitted networks for accurate pavement friction coefficient prediction from 3d texture features. *Tribology International*, 218:111794, 2026.

[20] Feixiang Xu, Junkang Feng, Yafei Wang, Xiaoyi Wang, Chuanwang Shen, and Chen Zhou. Parallel self-learning adaptive strategy based on model predictive control for trajectory tracking of autonomous vehicles. *Engineering Applications of Artificial Intelligence*, 173:114495, 2026.

[21] Kumlachew Yeneneh and Gadisa Sufe. AutoDyn: robust model predictive control design for trajectory tracking under varying vehicle dynamics. *Scientific Reports*, 16:25130, 2026.

[22] Kumlachew Yeneneh, Bisrat Yoseph, and Gadisa Sufe. Adaptive model predictive control for robust lateral motion tracking of semi-autonomous vehicles with dynamic parameter variation. *Scientific Reports*, 16:716, 2026. Published online November 30, 2025.

[23] Duk Sun Yun and Byung Chul Lim. Real-time axle-load sensing and AI-enhanced braking-distance prediction for multi-axle heavy-duty trucks. *Applied Sciences*, 16:1547, 2026.

[24] Zhisong Zhou, Yafei Wang, Xulei Liu, Zexing Li, Mingyu Wu, and Guofeng Zhou. Hybrid of neural network and physics-based estimator for vehicle longitudinal dynamics modeling using limited driving data. *IEEE Transactions on Intelligent Transportation Systems*, 26(10):16735–16746, 2025.