Universidad XXXXX

Programa de Doctorado en XXXXX

Título provisional de la investigación

Estimación de validez en tiempo de ejecución para la integración de modelos híbridos aprendidos en control de dinámica vehicular

Nombre del doctorando

Director / Orientador

Año

Resumen

Índice general

1. Introducción **4**

1.1. Contexto y motivación 5
1.2. Problema científico 5
1.3. Delimitación del problema (Prioridad 1) 5
1.4. Brecha de investigación 5
1.5. Pregunta de investigación 5
1.6. Preguntas específicas de investigación 5
1.7. Hipótesis de investigación 6

2. Objetivos **7**

2.1. Objetivo general 7
2.2. Objetivos específicos 7

3. Fundamentos de dinámica y control vehicular **9**

3.1. Dinámica vehicular relevante para control 9
3.2. Modelos control-oriented y model mismatch 9
3.3. Modelos híbridos: physics + learned residual 9
3.4. Control predictivo basado en modelo 9
3.5. Control Barrier Functions como extensión opcional 9

4. Información aprendida y validez en tiempo de ejecución **10**

4.1. Información aprendida relevante para el controlador 10
4.2. Incertidumbre predictiva 10
4.2.1. Incertidumbre aleatoria 10
4.2.2. Incertidumbre epistémica 10
4.2.3. Calibración 10
4.3. OOD y distribution shift en dinámica vehicular 10
4.3.1. Régimen físico no representado 10
4.3.2. Dynamics OOD 10
4.3.3. Input OOD 10
4.3.4. Fallo o degradación sensorial 10

4.4. Validez/confianza runtime . . . 10
4.5. Validez relevante para control . . . 11

5. Estado del arte **12**
5.1. Estrategia de revisión de literatura . . . 12
5.2. Modelos aprendidos e híbridos en control de dinámica vehicular . . . 12
5.3. Uncertainty-aware learned dynamics para control . . . 12
5.4. OOD, distribution shift y runtime monitoring . . . 12
5.5. Validity-aware y confidence-aware control . . . 12
5.6. Síntesis crítica y brecha . . . 12

6. Marco conceptual y arquitectura propuesta **13**
6.1. Cadena shift–validity–control . . . 13
6.2. Modelo híbrido de predicción . . . 13
6.3. Estimador de validez . . . 13
6.4. Integración con MPC/NMPC . . . 13
6.5. Extensiones opcionales . . . 13
6.5.1. Modulación de una CBF . . . 13
6.5.2. Adquisición de datos y reentrenamiento . . . 13

7. Metodología de investigación y validación (Prioridad 1) **14**
7.1. Estrategia general . . . 14
7.2. Escenarios de shift . . . 15
7.2.1. Cambio de fricción desconocida . . . 15
7.2.2. Extensión del rango de velocidad . . . 15
7.2.3. Fallo/degradación de sensores . . . 15
7.2.4. Input OOD . . . 15
7.3. Modelo aprendido e incertidumbre . . . 15
7.4. Construcción y evaluación de la señal de validez . . . 15
7.5. Integración validity-aware con MPC/NMPC . . . 15
7.6. Baselines y ablation study . . . 15
7.7. Métricas de evaluación . . . 16
7.7.1. Métricas del modelo . . . 16
7.7.2. Métricas de uncertainty, calibration y OOD . . . 16
7.7.3. Métricas closed-loop . . . 16
7.8. Criterio de robustez empírica . . . 16
7.9. Nivel de garantía y alcance de las conclusiones . . . 16
7.10. Análisis estadístico y reproducibilidad . . . 16

8. Resultados preliminares **17**
8.1. Viabilidad del modelado aprendido de dinámica vehicular 17
8.2. Comportamiento de uncertainty y OOD bajo shifts 17
8.3. Integración preliminar con control 17
8.4. Discusión de resultados preliminares 17

9. Contribuciones esperadas **18**
9.1. Control-relevant validity estimation 18
9.2. Validity-aware vehicle control 18
9.3. Runtime validity characterization 18
9.4. Taxonomía experimental de shifts vehiculares 18
9.5. Extensiones potenciales 18

10. Plan de trabajo (Prioridad 1) **19**
10.1. Actividades restantes 19
10.2. Cronograma 19
10.3. Hitos de decisión 19

11. Riesgos, limitaciones y estrategias de mitigación **20**
11.1. Riesgo de redundancia entre uncertainty y OOD 20
11.2. Riesgo de mala calibración o mala correlación con error 20
11.3. Riesgo de que la adaptación del horizonte no mejore closed-loop 20
11.4. Riesgo computacional 20
11.5. Riesgo de sobreextensión del alcance 20
11.6. Limitaciones de garantías formales 20

12. Conclusiones del examen de calificación **21**

Capítulo 1

Introducción

Para ilustrar o problema, considere um motorista que trafega por uma rodovia a 100 km/h quando começa a chover. Com a redução da visibilidade, ele decide se dirigir ao acostamento. Durante a manobra, porém, a presença de água na pista pode reduzir a aderência entre os pneus e o pavimento, dificultando a mudança de trajetória. O que começou como uma tentativa de interromper a viagem pode, nessas condições, resultar em perda de controle e risco de colisão com outros veículos ou com as barreiras de contenção.

O exemplo chama a atenção para uma dificuldade que vai além da decisão do motorista: a possibilidade de executar uma manobra depende das condições de contato entre os pneus e o pavimento. Quando essas condições mudam, as forças disponíveis para frear ou alterar a direção do veículo também podem mudar. Compreender como a aderência varia ao longo do percurso é, portanto, parte do problema de manter o veículo na trajetória pretendida.

Entre os fatores que alteram a aderência estão o desgaste do pavimento e a presença de água na pista. Ao longo do tempo, a passagem dos veículos provoca o polimento dos agregados e modifica a textura da superfície, reduzindo sua resistência ao deslizamento [6, 3, 7]. Durante a chuva, a água pode comprometer o contato entre os pneus e o pavimento e, em condições de hidroplanagem, levar à perda desse contato [5]. Os sulcos formados nas trilhas de roda favorecem o acúmulo de água, contribuindo para o problema [4]. Assim, tanto o desgaste da via quanto as condições encontradas durante a viagem podem modificar a aderência disponível para uma manobra.

Essa limitação ganha relevância quando o motorista precisa mudar de faixa em pouco tempo ou desviar de um obstáculo. Nessas manobras, as forças laterais necessárias para seguir a trajetória pretendida podem superar aquelas que os pneus conseguem transmitir ao pavimento [1]. A combinação de alta velocidade e baixa aderência pode, então, provocar deslizamento lateral e instabilidade de guinada, levando à perda de controle do veículo [2]. A dificuldade está, portanto, em executar a manobra dentro dos limites impostos pela interação entre os pneus e a pista.

É nesse contexto que se insere o controle automotivo, com sistemas destinados a auxiliar o motorista na frenagem e na manutenção da estabilidade do veículo.

1.1. Contexto y motivación

1.2. Problema científico

1.3. Delimitación del problema (Prioridad 1)

1.4. Brecha de investigación

1.5. Pregunta de investigación

¿Cómo estimar en tiempo de ejecución la validez de un modelo residual aprendido de dinámica vehicular y utilizar esa estimación para adaptar un controlador MPC/NMPC ante condiciones de operación no representadas durante el entrenamiento?

1.6. Preguntas específicas de investigación

P1: ¿Qué tipos de shifts físicamente relevantes en dinámica vehicular producen pérdida significativa de validez del residual aprendido?

P2: ¿Qué información proporcionan la incertidumbre epistémica, la incertidumbre aleatoria, la calibración y un indicador OOD sobre el error del modelo relevante para control?

P3: ¿En qué medida las señales de uncertainty, calibration y OOD son complementarias o redundantes para caracterizar validez runtime?

P4: ¿Cómo construir una señal de confianza/validez $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Calibration}, \text{OOD})$ que guarde relación con el error relevante para el controlador?

P5: ¿Cómo debe utilizarse C_k para adaptar el horizonte de un MPC/NMPC de manera que se reduzca la degradación closed-loop cuando disminuye la validez del modelo aprendido?

P6: ¿Qué mejora ofrece la arquitectura propuesta frente a un controlador basado únicamente en el modelo físico, un controlador que utiliza el modelo aprendido sin monitoreo de validez y arquitecturas que utilizan únicamente validity o únicamente OOD?

P7: Como extensión opcional, ¿puede la información de validez emplearse para modificar la acción de una CBF o activar estrategias de actualización de datos/modelo ante incertidumbre epistémica?

1.7. Hipótesis de investigación

La combinación calibrada de incertidumbre epistémica, incertidumbre aleatoria y evidencia de distribución fuera del dominio puede proporcionar una estimación útil de la validez runtime de un residual aprendido de dinámica vehicular; al incorporar explícitamente esta estimación en la adaptación de un controlador MPC/NMPC, es posible reducir la degradación de desempeño closed-loop bajo cambios de régimen respecto a arquitecturas que utilizan el modelo aprendido sin validity awareness.

Capítulo 2

Objetivos

2.1. Objetivo general

Desarrollar y evaluar una metodología de estimación de validez en tiempo real para un modelo híbrido de dinámica vehicular basado en un modelo físico y un residual aprendido, e integrar dicha estimación en un controlador MPC/NMPC para reducir la degradación del desempeño closed-loop ante condiciones de operación no representadas durante el entrenamiento.

2.2. Objetivos específicos

OE1: Formular una arquitectura híbrida de dinámica vehicular compuesta por un modelo físico control-oriented y un residual aprendido.

OE2: Definir operacionalmente los tipos de shift/OOD relevantes para el estudio, distinguiendo al menos régimen físico no representado y dynamics OOD, e incluyendo input OOD si el alcance temporal lo permite.

OE3: Estimar y calibrar incertidumbre aleatoria y epistémica del modelo aprendido mediante un modelo heteroscedástico y un ensemble pequeño, complementado con un indicador OOD de bajo costo computacional.

OE4: Caracterizar experimentalmente la relación entre shift, uncertainty, calibration, OOD, error de predicción y error relevante para control.

OE5: Definir una representación de confianza/validez runtime $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Calibration}, \text{OOD})$ y evaluar su capacidad para anticipar o representar degradación del modelo útil para el controlador.

OE6: Integrar la señal de validez en un MPC/NMPC mediante adaptación de su horizonte y evaluar el efecto sobre desempeño y robustez empírica closed-loop.

OE7: Comparar la propuesta con arquitecturas de referencia que separen el efecto del modelo aprendido, la estimación de validez y la detección OOD.

OE8: Como extensión, si el cronograma lo permite, evaluar el uso de la señal de validez en una CBF y/o una estrategia de adquisición y reentrenamiento basada en DAgger para condiciones asociadas a incertidumbre epistémica.

Capítulo 3

Fundamentos de dinámica y control vehicular

3.1. Dinámica vehicular relevante para control

3.2. Modelos control-oriented y model mismatch

3.3. Modelos híbridos: physics + learned residual

3.4. Control predictivo basado en modelo

3.5. Control Barrier Functions como extensión opcional

Capítulo 4

Información aprendida y validez en tiempo de ejecución

4.1. Información aprendida relevante para el controlador

4.2. Incertidumbre predictiva

4.2.1. Incertidumbre aleatoria

4.2.2. Incertidumbre epistémica

4.2.3. Calibración

4.3. OOD y distribution shift en dinámica vehicular

4.3.1. Régimen físico no representado

4.3.2. Dynamics OOD

4.3.3. Input OOD

4.3.4. Fallo o degradación sensorial

4.4. Validez/confianza runtime

$$C_k = g(U_{\mathrm{epi},k}, U_{\mathrm{ale},k}, \mathrm{Cal}_k, S_{\mathrm{OOD},k}) \,, \tag{4.1}$$

4.5. Validez relevante para control

Capítulo 5

Estado del arte

5.1. Estrategia de revisión de literatura

5.2. Modelos aprendidos e híbridos en control de dinámica vehicular

5.3. Uncertainty-aware learned dynamics para control

5.4. OOD, distribution shift y runtime monitoring

5.5. Validity-aware y confidence-aware control

5.6. Síntesis crítica y brecha

Capítulo 6

Marco conceptual y arquitectura propuesta

6.1. Cadena shift–validity–control

6.2. Modelo híbrido de predicción

6.3. Estimador de validez

6.4. Integración con MPC/NMPC

6.5. Extensiones opcionales

6.5.1. Modulación de una CBF

6.5.2. Adquisición de datos y reentrenamiento

Capítulo 7

Metodología de investigación y validación (Prioridad 1)

7.1. Estrategia general

E1: Establecer el modelo físico control-oriented y el controlador MPC/NMPC de referencia.

E2: Entrenar el residual aprendido y cuantificar su mejora y sus límites frente al modelo físico dentro del dominio nominal.

E3: Implementar estimación de incertidumbre aleatoria y epistémica, calibración y un score OOD de bajo costo.

E4: Diseñar shifts vehiculares físicamente interpretables y caracterizar cómo afectan predicción, incertidumbre, OOD y validez.

E5: Construir y validar la señal C_k respecto a error relevante para control.

E6: Integrar C_k en la adaptación del MPC/NMPC.

E7: Comparar baselines y propuesta bajo condiciones nominales y OOD.

E8: Evaluar robustez empírica y, si el desarrollo lo permite, incorporar extensiones CBF y/o DAgger.

7.2. Escenarios de shift

7.2.1. Cambio de fricción desconocida

7.2.2. Extensión del rango de velocidad

7.2.3. Fallo/degradación de sensores

7.2.4. Input OOD

7.3. Modelo aprendido e incertidumbre

7.4. Construcción y evaluación de la señal de validez

7.5. Integración validity-aware con MPC/NMPC

7.6. Baselines y ablation study

B0 – Physics-only: controlador con modelo físico sin residual aprendido.

B1 – Learned/no-awareness: controlador con modelo physics + learned residual, sin estimación de validity ni detección OOD.

B2 – Validity/uncertainty-only: controlador con modelo aprendido y señal construida a partir de uncertainty/calibration, excluyendo el componente OOD explícito.

B3 – OOD-only: controlador con modelo aprendido y reacción basada únicamente en el score OOD, sin estimación probabilística de uncertainty.

P – Proposed: controlador con modelo physics + learned residual y señal $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, OO$ utilizada para adaptar el MPC/NMPC.

7.7. Métricas de evaluación

7.7.1. Métricas del modelo

7.7.2. Métricas de uncertainty, calibration y OOD

7.7.3. Métricas closed-loop

7.8. Criterio de robustez empírica

$$\Delta J_{\text{prop}} < \Delta J_{\text{baseline}}, \tag{7.1}$$

7.9. Nivel de garantía y alcance de las conclusiones

7.10. Análisis estadístico y reproducibilidad

Capítulo 8

Resultados preliminares

8.1. Viabilidad del modelado aprendido de dinámica vehicular

8.2. Comportamiento de uncertainty y OOD bajo shifts

8.3. Integración preliminar con control

8.4. Discusión de resultados preliminares

Capítulo 9

Contribuciones esperadas

9.1. Control-relevant validity estimation

9.2. Validity-aware vehicle control

9.3. Runtime validity characterization

9.4. Taxonomía experimental de shifts vehiculares

9.5. Extensiones potenciales

Capítulo 10

Plan de trabajo (Prioridad 1)

10.1. Actividades restantes

10.2. Cronograma

10.3. Hitos de decisión

Capítulo 11

Riesgos, limitaciones y estrategias de mitigación

11.1. Riesgo de redundancia entre uncertainty y OOD

11.2. Riesgo de mala calibración o mala correlación con error

11.3. Riesgo de que la adaptación del horizonte no mejore closed-loop

11.4. Riesgo computacional

11.5. Riesgo de sobreextensión del alcance

11.6. Limitaciones de garantías formales

Capítulo 12

Conclusiones del examen de calificación

Bibliografía

[1] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. Model predictive contouring control for vehicle obstacle avoidance at the limit of handling. In Wei Huang and Mehdi Ahmadian, editors, *Advances in Dynamics of Vehicles on Roads and Tracks III*, volume 2 of *Lecture Notes in Mechanical Engineering*, pages 132–142. Springer, 2024.

[2] J. Hu, H. Liu, S. Yi, and C. Huang. Lane-changing control strategy for distributed drive vehicles considering yaw stability. *IET Intelligent Transport Systems*, 19:e12605, 2025.

[3] Miren Isasa, Ángela Alonso-Solórzano, Itziar Gurrutxaga, and Heriberto Pérez-Acebo. A skid resistance predicting model for single carriageways. *Lubricants*, 13(8), 2025. Cited by: 4; All Open Access, Gold Open Access, Green Open Access.

[4] J. Rajendra Prasad, Shalini Kanuganti, Pooja N. Bhanegaonkar, Ashoke Kumar Sarkar, and Shriniwas Arkatkar. Development of relationship between roughness (iri) and visible surface distresses: A study on pmgsy roads. *Procedia - Social and Behavioral Sciences*, 104:322–331, 2013. 2nd Conference of Transportation Research Group of India (2nd CTRG).

[5] S. Salleh, R. Muhamad, and M.H. Abdillah. Performance of ralumac micro surfacing at blackspot eastbound, latar highway. volume 527, 2019. Cited by: 0; All Open Access, Gold Open Access.

[6] Zihang Weng, Zhen Leng, Yuchuan Du, Chenglong Liu, Xinqiang Zhang, Danning Li, and Yulin He. Leveraging tabular prior-data fitted networks for accurate pavement friction coefficient prediction from 3d texture features. *Tribology International*, 218, 2026. Cited by: 4.

[7] D. J. Wilson. *An Analysis of the Seasonal and Short-Term Variation of Road Pavement Skid Resistance*. PhD thesis, The University of Auckland, Auckland, New Zealand, 2006.