Universidad XXXXX

Programa de Doctorado en XXXXX

Título provisional de la investigación

Estimación de la validez durante la operación para integrar modelos híbridos con aprendizaje en el control de la dinámica vehicular

Doctorando

Director de tesis

Año

Resumen

Índice general

1. Introducción **5**
1.1. Contexto y motivación 6
1.2. Problema de investigación 8
1.3. Alcance del problema 10
1.4. Brecha de investigación 10
1.5. Pregunta de investigación 10
1.6. Preguntas específicas de investigación 11
1.7. Hipótesis de investigación 11

2. Objetivos **13**
2.1. Objetivo general 13
2.2. Objetivos específicos 13

3. Fundamentos de dinámica vehicular y control **15**
3.1. Dinámica vehicular relevante para el control 15
3.2. Modelos orientados al control y discrepancias del modelo 17
3.3. Modelos híbridos: física y residuales aprendidos 18
3.4. Control predictivo basado en modelos 19
3.5. Funciones de barrera de control como extensión opcional 20

4. Información aprendida y validez durante la operación **21**
4.1. Información aprendida relevante para el controlador 21
4.2. Incertidumbre predictiva 22
4.2.1. Incertidumbre aleatoria 23
4.2.2. Incertidumbre epistémica 23
4.2.3. Calibración 24
4.3. Detección fuera de distribución y cambios de distribución en la dinámica vehicular 25
4.3.1. Régimen físico no representado 25
4.3.2. Dinámica fuera de distribución 25
4.3.3. Entradas fuera de distribución 25

4.3.4. Fallo o degradación de sensores . . . 25
4.4. Validez y confianza durante la operación . . . 25
4.5. Validez relevante para el control . . . 25

5. Estado del arte **26**
5.1. Estrategia de revisión bibliográfica . . . 26
5.2. Modelos aprendidos e híbridos para el control de la dinámica vehicular . . . 26
5.3. Dinámica aprendida con consideración de la incertidumbre para el control . . . 26
5.4. Detección fuera de distribución, cambios de distribución y supervisión durante la operación . . . 26
5.5. Control con consideración de la validez y la confianza . . . 26
5.6. Síntesis crítica y brecha de investigación . . . 26

6. Marco conceptual y arquitectura propuesta **27**
6.1. La cadena cambio–validez–control . . . 27
6.2. Modelo híbrido de predicción . . . 27
6.3. Estimador de validez . . . 27
6.4. Integración con MPC/NMPC . . . 27
6.5. Extensiones opcionales . . . 27
6.5.1. Modulación de una función de barrera de control (CBF) . . . 27
6.5.2. Adquisición de datos y reentrenamiento . . . 27

7. Metodología de investigación y validación (prioridad 1) **28**
7.1. Estrategia general . . . 28
7.2. Entorno común de entrenamiento y evaluación de los modelos . . . 28
7.2.1. Modelo físico nominal B0 . . . 29
7.2.2. Generación de datos y dominio nominal . . . 29
7.2.3. Partición congelada por corridas . . . 30
7.2.4. Preprocesamiento y protocolo de comparación . . . 30
7.3. Descripción de los modelos entrenados . . . 31
7.3.1. B1: MLP residual determinista . . . 31
7.3.2. B2: proceso gaussiano homoscedástico . . . 32
7.3.3. B3: conjunto profundo de MLP heteroscedásticas . . . 35
7.3.4. B4: proceso gaussiano heteroscedástico en dos etapas . . . 38
7.4. Escenarios de cambio de distribución . . . 40
7.4.1. Referencia nominal y generalización de excitación: E0–E1 . . . 41
7.4.2. Cambios observables del punto de operación: E2–E3 . . . 43
7.4.3. Cambios dinámicos latentes de adherencia: E4–E6 . . . 43
7.4.4. Cambio combinado de maniobra y adherencia: E7 . . . 43
7.4.5. Cambio estructural del vehículo: E8 . . . 43

7.4.6. Cambio abrupto durante la ejecución: E9 44
7.5. Modelo aprendido e incertidumbre 44
7.6. Construcción y evaluación de la señal de validez 44
7.7. Uso de la señal de validez en MPC/NMPC 44
7.8. Arquitecturas de referencia y estudio de ablación 44
7.9. Métricas de evaluación 45
7.9.1. Métricas del modelo 45
7.9.2. Métricas de incertidumbre, calibración y detección fuera de distribución 45
7.9.3. Métricas de desempeño en lazo cerrado 45
7.10. Criterio de robustez empírica 45
7.11. Nivel de garantía y alcance de las conclusiones 45
7.12. Análisis estadístico y reproducibilidad 45

8. Resultados preliminares **46**
8.1. Viabilidad del aprendizaje de modelos de dinámica vehicular 46
8.2. Comportamiento de la incertidumbre y de los indicadores fuera de distribución ante cambios de distribución 46
8.3. Integración preliminar con el control 46
8.4. Discusión de los resultados preliminares 46

9. Contribuciones esperadas **47**
9.1. Estimación de la validez relevante para el control 47
9.2. Control vehicular con consideración de la validez 47
9.3. Caracterización de la validez durante la operación 47
9.4. Taxonomía experimental de cambios en la dinámica vehicular 47
9.5. Posibles extensiones 47

10. Plan de trabajo (prioridad 1) **48**
10.1. Actividades pendientes 48
10.2. Cronograma 48
10.3. Hitos de decisión 48

11. Riesgos, limitaciones y estrategias de mitigación **49**
11.1. Riesgo de redundancia entre incertidumbre y detección fuera de distribución 49
11.2. Riesgo de calibración inadecuada o de correlación débil con el error 49
11.3. Riesgo de que la adaptación del horizonte no mejore el desempeño en lazo cerrado 49
11.4. Riesgo computacional 49
11.5. Riesgo de ampliación del alcance 49

11.6. Limitaciones de las garantías formales 49

12. Conclusiones del examen de calificación **50**

Capítulo 1

Introducción

Consideremos a un conductor que circula por una autopista a 100 km/h cuando empieza a llover. Al disminuir la visibilidad, decide detenerse en el arcén. Durante la maniobra, el agua sobre la calzada puede reducir la adherencia entre los neumáticos y la carretera, dificultando el cambio de dirección. Lo que comenzó como un intento de detenerse puede, en estas condiciones, provocar una pérdida de control y un riesgo de colisión con otros vehículos o con las barreras de la vía.

La dificultad de este ejemplo reside en ejecutar una maniobra cuando cambia la adherencia disponible. La dirección y el frenado dependen de las fuerzas transmitidas a través del contacto entre los neumáticos y la carretera, por lo que una variación en estas condiciones puede alterar la capacidad del vehículo para seguir la trayectoria prevista [1].

La adherencia disponible varía con la superficie del pavimento y con las condiciones que se encuentran a lo largo del recorrido. Los estudios sobre fricción del pavimento relacionan la resistencia al deslizamiento con la textura de la superficie y las características de la vía [19, 10]. El agua sobre la calzada puede dificultar el contacto entre los neumáticos y la carretera, mientras que los surcos en las zonas de rodadura pueden retener agua y aumentar el riesgo de hidroplaneo [15].

Estos límites cobran relevancia cuando el conductor necesita cambiar de carril con poco margen de reacción o desviarse para evitar un obstáculo. Las fuerzas laterales necesarias para seguir la trayectoria prevista pueden superar las que el contacto entre los neumáticos y la carretera permite transmitir [1]. A velocidades elevadas y con baja adherencia, esta limitación puede dar lugar a deslizamiento lateral e inestabilidad de guiñada, comprometiendo la maniobra [9].

Los sistemas de control vehicular asisten al conductor en el frenado y el mantenimiento de la estabilidad. El sistema antibloqueo de frenos (ABS) busca evitar que las ruedas se bloqueen durante el frenado [4]. El control electrónico de estabilidad (ESC, por sus siglas en inglés) ayuda a corregir las desviaciones entre el movimiento del vehículo y la dirección que pretende seguir el conductor; el programa electrónico de estabilidad (ESP) de Bosch, introducido en 1995, es una implementación de esta función [3]. Desde entonces,

el desarrollo se ha extendido a la coordinación del frenado, la dirección y la propulsión. Esta coordinación ofrece más posibilidades de actuar sobre el movimiento del vehículo y requiere información sobre su respuesta, incluidos estados y parámetros que pueden necesitar estimarse durante la operación [16].

1.1. Contexto y motivación

La respuesta del vehículo también depende de su masa, su carga y las propiedades de los neumáticos. La fricción y las cargas por eje afectan a la predicción de la distancia de frenado [23], mientras que la masa y la rigidez lateral de los neumáticos intervienen en la descripción del movimiento lateral y de guiñada [22]. En el rango lineal, la rigidez lateral es la pendiente de la relación entre la fuerza lateral del neumático y su ángulo de deriva [16]. Por tanto, describe un aspecto del comportamiento del neumático distinto del límite de fricción: este último acota las fuerzas disponibles, mientras que la rigidez influye en cómo se desarrolla la fuerza lateral con el ángulo de deriva. Las variaciones de estas magnitudes pueden afectar tanto a las fuerzas disponibles para una maniobra como al movimiento que resulta de ellas.

Los estudios sobre control vehicular adaptativo ilustran las consecuencias de estas variaciones. Xu et al. evalúan el seguimiento de trayectoria mediante simulaciones en vías con fricción baja y variable, y obtienen menores errores laterales y de orientación con su estrategia adaptativa que con los controladores de comparación [20]. Yeneneh et al. utilizan estimación de parámetros durante la operación para actualizar un modelo de seguimiento lateral que incluye masa y rigidez lateral. En sus simulaciones, el controlador adaptativo reduce los errores de seguimiento respecto al control predictivo convencional y a un regulador cuadrático lineal [22]. Estos resultados motivan considerar cambios tanto en el entorno vial como en el propio vehículo y examinar si la descripción de la dinámica utilizada para el control sigue siendo representativa.

Los controladores predictivos utilizan un modelo para relacionar las entradas de control con la respuesta que esperan del vehículo. El control predictivo basado en modelos (MPC, por sus siglas en inglés), incluida su formulación no lineal (NMPC), utiliza estas predicciones para seleccionar entradas sobre un horizonte finito, teniendo en cuenta las restricciones [17]. El modelo debe ofrecer suficiente detalle para fundamentar estas decisiones y mantener el problema de control resoluble con los recursos de cómputo disponibles. Chen et al., por ejemplo, emplean un modelo bicicleta simplificado para equilibrar la precisión de la predicción y el costo computacional [7]. Estas simplificaciones pueden introducir discrepancias entre el movimiento predicho y el real. Pan et al. identifican la estructura del modelo y los errores paramétricos como fuentes de estas discrepancias y las consideran en un controlador predictivo robusto [14].

La incertidumbre sobre el valor de un parámetro no implica que este esté cambiando.

Una diferencia entre su valor real y el supuesto puede afectar a las predicciones incluso cuando su valor físico permanece constante. Yeneneh y Sufe consideran la incertidumbre en la masa, las rigideces laterales de los neumáticos delanteros y traseros y la fricción de la carretera dentro de una formulación de control predictivo robusto [21]. Li et al. abordan la incertidumbre en la rigidez lateral y el momento de inercia de guiñada mediante un controlador con acoplamiento longitudinal y lateral, evaluado en pruebas donde hardware real interactúa con una simulación (HIL) [13]. Estos estudios motivan tener en cuenta la incertidumbre paramétrica al utilizar un modelo simplificado para el control.

Conviene, por tanto, distinguir los parámetros físicos del vehículo, los valores nominales utilizados por el modelo y las estimaciones obtenidas a partir de mediciones durante la operación. La estimación puede reducir el error paramétrico, pero no elimina las aproximaciones estructurales del modelo. Chen et al. reflejan esta distinción al combinar la calibración de un modelo físico nominal con la compensación de la dinámica no modelada restante [6]. Su formulación ilustra por qué mejorar la predicción puede requerir tratar discrepancias que la calibración de parámetros por sí sola no recoge.

El modelado híbrido aborda parte de estas discrepancias combinando ecuaciones físicas con información aprendida a partir de datos [8, 24]. En un modelo con un residual aprendido aditivo, el componente físico proporciona una predicción nominal y el componente aprendido estima una corrección a partir de la diferencia entre esa predicción y la respuesta observada [11, 7]. La corrección puede representar efectos que el modelo simplificado no describe de forma adecuada. En la formulación de Kabzan et al., los valores objetivo del entrenamiento se obtienen a partir de transiciones de estado medidas y predicciones nominales, lo que permite aprender el error del modelo sin identificar por separado sus causas físicas [11].

Kabzan et al. utilizan regresión por procesos gaussianos para esta corrección en conducción autónoma de competición. Durante las pruebas con un vehículo de competición a escala real, el modelo corregido mantuvo un error medio de predicción aproximadamente constante a medida que la conducción se volvía más exigente en vueltas sucesivas, mientras que el error del modelo nominal aumentó [11]. El aprendizaje también puede asignarse a componentes individuales de las fuerzas. Zhou et al. combinan un modelo de tracción basado en una red neuronal con la dinámica longitudinal física y un estimador de la masa del vehículo y de un coeficiente modificado de fricción de rodadura. Su evaluación incluye cargas y condiciones de la vía distintas de las utilizadas para el entrenamiento [24]. Se trata de una arquitectura híbrida de modelado de fuerzas y estimación de parámetros, cuya función del aprendizaje difiere de la de un residual aditivo.

Otros enfoques híbridos fusionan modelos físicos y neuronales para predecir la dinámica o acoplan un estimador neuronal con un observador físico para estimar el ángulo de deriva del vehículo [8, 2]. El conocimiento físico también puede orientar el entrenamiento: Wang et al. incluyen residuos de las ecuaciones de equilibrio de fuerzas en el objetivo de

aprendizaje de un modelo de dinámica vehicular [18]. Estos usos del aprendizaje cumplen funciones distintas. En esta tesis, el interés se centra en un residual aditivo dentro del modelo de predicción del controlador, evaluado tanto por la precisión de sus predicciones como por su efecto en el control.

Consideremos, como ejemplo conceptual, un residual entrenado con una determinada carga del vehículo y utilizado después en un recorrido con pasajeros o carga adicionales. Si el modelo nominal y el residual permanecen sin cambios, la corrección aprendida puede dejar de describir la discrepancia bajo la nueva carga. Los cambios en las propiedades de los neumáticos pueden plantear una dificultad similar: velocidades y entradas de dirección conocidas no tienen por qué producir la misma respuesta cuando los parámetros subyacentes son distintos [21].

La carga puede variar entre recorridos y las características de los neumáticos pueden evolucionar durante la conducción. Kalaria et al. aprenden y actualizan un modelo de neumáticos durante la operación para tener en cuenta cambios en su comportamiento de deslizamiento lateral; su evaluación utiliza simuladores numéricos y de alta fidelidad, e incluye cambios simulados que buscan representar el desgaste [12]. En un contexto más general, Brunke et al. identifican la escasez de datos y los cambios de distribución como dificultades prácticas del control basado en aprendizaje [5]. Un cambio no invalida necesariamente un residual aprendido, pero el desempeño en unas condiciones no establece por sí solo su utilidad en otras. Chen et al. identifican la capacidad limitada de una corrección entrenada antes de la operación para adaptarse a nuevas condiciones como una motivación para actualizarla durante la operación [7].

El reto de investigación consiste en evaluar durante la operación si el residual sigue aportando información útil para el control cuando cambia la respuesta del vehículo, y determinar cómo esa evaluación debe influir en el controlador. Para ello, es necesario relacionar el error del modelo con las decisiones a las que afecta, sin que sea imprescindible identificar la causa física de la discrepancia.

1.2. Problema de investigación

El problema se estudia mediante una arquitectura de control que distingue entre la planta de referencia y los modelos internos considerados por el controlador. CarSim representa la respuesta de alta fidelidad del vehículo, mientras que el MPC debe operar con descripciones suficientemente compactas para realizar predicciones y optimizar las acciones de dirección en tiempo de ejecución. El punto de partida es un modelo de bicicleta lineal nominal, denominado B0.

La investigación no se limita al entrenamiento de un único modelo residual. A partir de B0 se construyen y comparan varias configuraciones híbridas y de supervisión, denominadas B1, B2, B3 y B4, con el propósito de analizar distintas formas de aprender,

evaluar y utilizar la discrepancia entre el modelo físico y la planta. Como ejemplo básico, B1 conserva la estructura física de B0 e incorpora una corrección residual neuronal aprendida a partir de datos de CarSim. La figura 1.1 ilustra esta configuración y resume la relación entre la planta de referencia, el modelo híbrido y el controlador. La descripción y formulación de B0–B4 se analizarán en el Capítulo 3, mientras que sus parámetros, datos y procedimientos de entrenamiento se especificarán en el Capítulo 7.

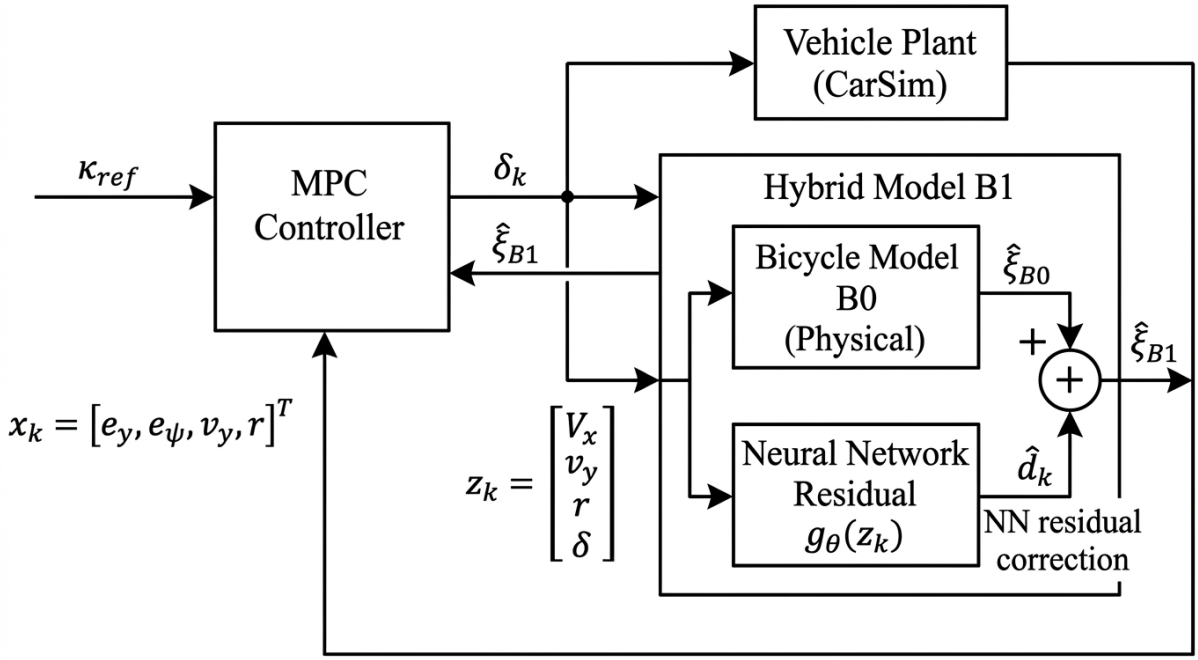


Figura 1.1: Estructura de control para la configuración B1, utilizada como ejemplo de modelo híbrido formado por el modelo de bicicleta B0 y un residual neuronal.

Dentro del dominio representado por los datos de entrenamiento, los modelos residuales pueden mejorar la precisión de B0. Sin embargo, esa mejora no garantiza que cada corrección conserve su utilidad cuando cambia la distribución de operación. Variaciones de adherencia, masa o carga y rigidez lateral de los neumáticos, así como velocidades no representadas durante el entrenamiento o degradaciones de sensores, pueden modificar las relaciones aprendidas entre el estado, la entrada de dirección y la discrepancia modelo–planta.

El problema central surge porque el MPC puede continuar utilizando información aprendida aun cuando su validez predictiva haya disminuido. B1 ilustra el caso elemental: una corrección residual, por sí sola, no informa si sigue siendo confiable para las decisiones de control. El mismo problema debe examinarse en las demás configuraciones B2–B4. Una predicción degradada puede alterar la secuencia de acciones optimizada y deteriorar el desempeño en lazo cerrado. La investigación aborda, en consecuencia, cómo caracterizar durante la operación la validez de los modelos aprendidos, cómo relacionarla con el error relevante para el control y cómo hacer que el MPC reaccione cuando esa validez disminuye.

1.3. Alcance del problema

Esta tesis se concentra en la dinámica lateral del vehículo y en el seguimiento de trayectoria mediante un controlador MPC/NMPC. El modelo de predicción combina un modelo físico orientado al control con un residual aprendido a partir de datos. Sobre esta arquitectura se estudiará la estimación, durante la operación, de la validez de la corrección aprendida y su utilización para adaptar el controlador cuando las condiciones difieran de las representadas durante el entrenamiento. Las familias de cambio consideradas comprenden variaciones de adherencia, masa o carga y rigidez lateral de los neumáticos, así como la operación fuera del rango de estados, velocidades o entradas utilizado para entrenar el residual. La metodología seleccionará escenarios representativos de estas familias, sin pretender cubrir todas sus combinaciones ni identificar necesariamente el parámetro físico que origine la degradación.

El protocolo experimental distinguirá entre las variables medidas, los estados o parámetros estimados y las magnitudes que no estén disponibles para el controlador. Las señales cinemáticas y la entrada de dirección requeridas por el modelo se considerarán disponibles mediante medición o estimación, según corresponda. En cambio, los valores reales de parámetros como la adherencia, la masa, las inercias o la rigidez lateral podrán utilizarse para configurar y analizar los escenarios sin proporcionarlos al estimador de validez ni al controlador cuando el experimento los defina como desconocidos. El alcance no comprende la percepción, la detección de objetos, la planificación global, la predicción de otros agentes ni las garantías del sistema autónomo completo; en particular, la pérdida de visibilidad del ejemplo inicial no constituye un problema de percepción abordado por la tesis. La contribución principal se evaluará mediante el desempeño predictivo y en lazo cerrado y mediante criterios de robustez empírica, sin prometer garantías formales de seguridad o estabilidad. El uso de funciones de barrera de control y las estrategias de adquisición de datos o reentrenamiento se mantienen como extensiones opcionales.

1.4. Brecha de investigación

1.5. Pregunta de investigación

¿Cómo puede estimarse la validez de un residual aprendido de dinámica vehicular durante la operación y utilizarse para adaptar un controlador MPC/NMPC bajo condiciones de operación no representadas durante el entrenamiento?

1.6. Preguntas específicas de investigación

PI1: ¿Qué tipos de cambios físicamente relevantes en la dinámica vehicular provocan una pérdida significativa de validez del residual aprendido?

PI2: ¿Qué información aportan la incertidumbre epistémica, la incertidumbre aleatoria, la calibración y un indicador de condiciones fuera de distribución (OOD, por sus siglas en inglés) sobre el error del modelo relevante para el control?

PI3: ¿En qué medida las señales de incertidumbre, calibración y OOD son complementarias o redundantes al caracterizar la validez durante la operación?

PI4: ¿Cómo puede construirse una señal de confianza/validez

$$C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$$

que refleje el error relevante para el controlador?

PI5: ¿Cómo debe utilizarse C_k para adaptar el horizonte de MPC/NMPC y reducir la degradación del desempeño en lazo cerrado cuando disminuye la validez del modelo aprendido?

PI6: ¿Qué mejora ofrece la arquitectura propuesta frente a un controlador basado solo en el modelo físico, un controlador que utiliza el modelo aprendido sin supervisar su validez y arquitecturas que utilizan únicamente información de validez o de OOD?

PI7: Como extensión opcional, ¿puede utilizarse la información de validez para modificar la acción de una función de barrera de control (CBF, por sus siglas en inglés) o activar estrategias de actualización de datos o del modelo en respuesta a la incertidumbre epistémica?

1.7. Hipótesis de investigación

Una combinación calibrada de incertidumbre epistémica, incertidumbre aleatoria y evidencia de operación fuera de distribución puede proporcionar una estimación útil de la validez de un residual aprendido de dinámica vehicular durante la operación. Incorporar esta estimación a la adaptación de un controlador MPC/NMPC puede reducir la degradación del desempeño en lazo cerrado ante cambios de régimen, en comparación con arquitecturas que utilizan el modelo aprendido sin considerar su validez.

El resto del documento se organiza de la siguiente manera. El Capítulo 2 establece los objetivos de la investigación; los Capítulos 3 y 4 presentan los fundamentos de dinámica vehicular y control, así como los conceptos necesarios para caracterizar la validez de la información aprendida durante la operación. El Capítulo 5 revisa el estado del arte y sustenta la brecha de investigación. Los Capítulos 6 y 7 desarrollan la arquitectura propuesta y la metodología empleada para su evaluación. Los Capítulos 8 y 9 reúnen, respectivamente, los resultados preliminares y las contribuciones esperadas. Finalmente, los Capítulos 10–12 exponen el plan de trabajo, los riesgos y limitaciones del estudio y las conclusiones del examen de calificación.

Capítulo 2

Objetivos

2.1. Objetivo general

Desarrollar y evaluar una metodología de estimación de validez en tiempo real para un modelo híbrido de dinámica vehicular compuesto por un modelo físico y un residual aprendido, e integrar esta estimación en un controlador MPC/NMPC para reducir la degradación del desempeño en lazo cerrado bajo condiciones de operación no representadas durante el entrenamiento.

2.2. Objetivos específicos

OE1: Formular una arquitectura híbrida de dinámica vehicular compuesta por un modelo físico orientado al control y un residual aprendido.

OE2: Definir de forma operativa los tipos de cambio y las situaciones fuera de distribución relevantes para el estudio, distinguiendo al menos los regímenes físicos no representados y la dinámica fuera de distribución, e incluyendo las entradas fuera de distribución si el tiempo lo permite.

OE3: Estimar y calibrar la incertidumbre aleatoria y epistémica del modelo aprendido mediante un modelo heterocedástico y un conjunto reducido de modelos, complementados con un indicador OOD de bajo costo computacional.

OE4: Caracterizar experimentalmente las relaciones entre cambio de distribución, incertidumbre, calibración, OOD, error de predicción y error relevante para el control.

OE5: Definir una representación de confianza/validez durante la operación

$$C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$$

y evaluar su capacidad para anticipar o representar la degradación del modelo de forma útil para el controlador.

OE6: Integrar la señal de validez en un controlador MPC/NMPC mediante la adaptación del horizonte y evaluar su efecto en el desempeño en lazo cerrado y la robustez empírica.

OE7: Comparar el enfoque propuesto con arquitecturas de referencia que permitan aislar los efectos del modelo aprendido, la estimación de validez y la detección fuera de distribución.

OE8: Como extensión, si el calendario lo permite, evaluar el uso de la señal de validez en una CBF y/o en una estrategia de adquisición de datos y reentrenamiento basada en DAgger para condiciones asociadas con la incertidumbre epistémica.

Capítulo 3

Fundamentos de dinámica vehicular y control

3.1. Dinámica vehicular relevante para el control

El movimiento lateral utilizado en esta tesis se describe mediante un modelo de bicicleta dinámico lineal. Esta representación concentra las ruedas de cada eje en una sola rueda equivalente y supone pequeños ángulos de deriva, rigideces laterales lineales y velocidad longitudinal constante alrededor de un punto de operación. Para el seguimiento de trayectoria, el modelo se amplía con los errores lateral y de orientación, lo que permite representar los estados relevantes sin reproducir toda la dinámica multicuerpo de la planta de alta fidelidad. El vector de estados resultante es

$$\mathbf{x} = \begin{bmatrix} e_y & e_\psi & v_y & r \end{bmatrix}^\mathsf{T}, \tag{3.1}$$

donde $e_\psi = \psi - \psi_{\text{ref}}$. La entrada de control es el ángulo efectivo de dirección de las ruedas delanteras, δ, mientras que la curvatura de la trayectoria de referencia, κ_{ref}, constituye una entrada conocida.

La figura 3.1 ilustra la representación del vehículo y las variables asociadas al seguimiento de la trayectoria de referencia.

Las ecuaciones del modelo son

$$\dot{e}_y = V_{x,0} e_\psi + v_y, \tag{3.2}$$

$$\dot{e}_\psi = r - V_{x,0} \kappa_{\text{ref}}, \tag{3.3}$$

$$\dot{v}_y = -\frac{C_f + C_r}{m V_{x,0}} v_y + \left(\frac{C_r l_r - C_f l_f}{m V_{x,0}} - V_{x,0} \right) r + \frac{C_f}{m} \delta, \tag{3.4}$$

$$\dot{r} = \frac{C_r l_r - C_f l_f}{I_z V_{x,0}} v_y - \frac{C_f l_f^2 + C_r l_r^2}{I_z V_{x,0}} r + \frac{C_f l_f}{I_z} \delta. \tag{3.5}$$

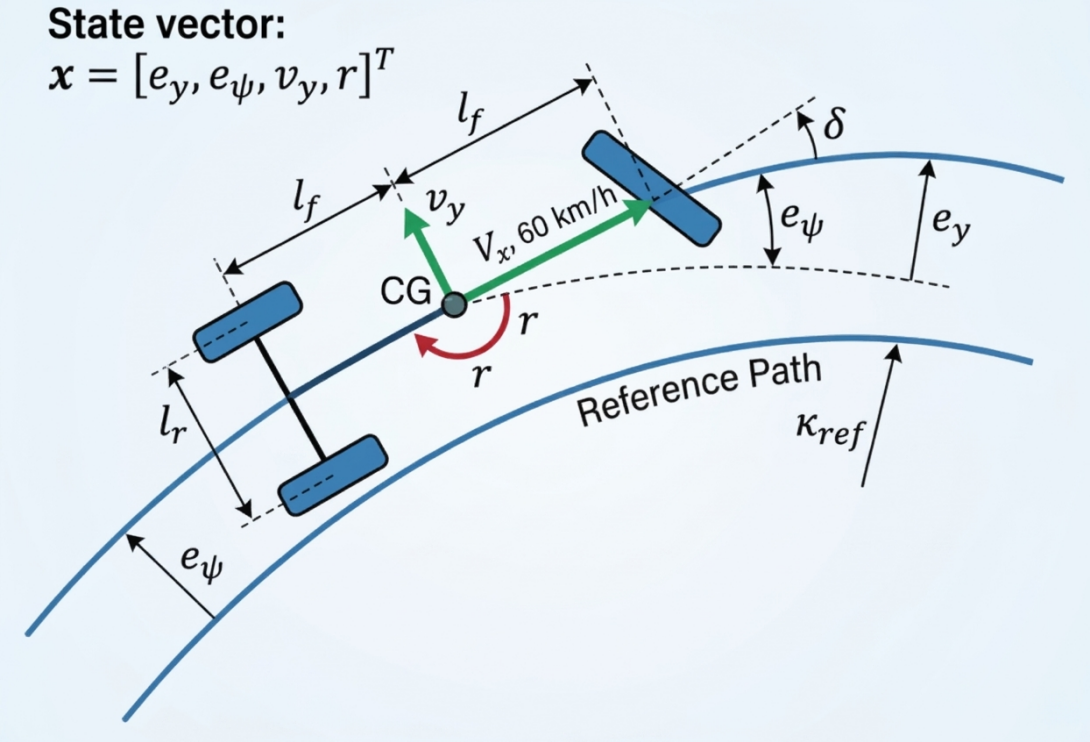


Figura 3.1: Esquema del modelo de bicicleta y de las variables utilizadas para describir el movimiento lateral y el seguimiento de trayectoria.

Las rigideces laterales C_f y C_r representan valores equivalentes por eje. Las fuerzas laterales se aproximan linealmente, sin saturación explícita por adherencia.

Cuadro 3.1: Estados y entradas del modelo de bicicleta ampliado.

Símbolo	Descripción	Unidad
e_y	Error lateral respecto a la trayectoria	m
e_ψ	Error de orientación	rad
v_y	Velocidad lateral en el centro de gravedad	m/s
r	Velocidad angular de guiñada	rad/s
δ	Ángulo efectivo de dirección delantero	rad
κ_{ref}	Curvatura de la trayectoria de referencia	m^{-1}

La masa, el momento de inercia de guiñada, la posición del centro de gravedad y las rigideces laterales determinan la respuesta lateral y de guiñada. En particular, las rigideces C_f y C_r describen la pendiente local de la relación fuerza–ángulo de deriva y no deben confundirse con el límite de fuerza impuesto por la adherencia neumático–carretera. Cuando el vehículo opera cerca de saturación, cambia su carga o se aleja del punto de velocidad nominal, las hipótesis lineales pueden dejar de representar adecuadamente la respuesta de la planta.

3.2. Modelos orientados al control y discrepancias del modelo

Para su uso en control, las ecuaciones anteriores se organizan como un modelo en espacio de estados. Esta formulación conserva las relaciones dominantes entre dirección, movimiento lateral y guiñada, y permite obtener un modelo discreto compatible con la frecuencia de actualización del controlador.

A partir de estas ecuaciones, la representación continua en espacio de estados es

$$\dot{\mathbf{x}} = \mathbf{A}_c\mathbf{x} + \mathbf{B}_c\delta + \mathbf{E}_c\kappa_{\text{ref}}, \tag{3.6}$$

con

$$\mathbf{A}_c = \begin{bmatrix} 0 & V_{x,0} & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & -\dfrac{C_f + C_r}{mV_{x,0}} & \dfrac{C_r l_r - C_f l_f}{mV_{x,0}} - V_{x,0} \\ 0 & 0 & \dfrac{C_r l_r - C_f l_f}{I_z V_{x,0}} & -\dfrac{C_f l_f^2 + C_r l_r^2}{I_z V_{x,0}} \end{bmatrix}, \tag{3.7}$$

$$\mathbf{B}_c = \begin{bmatrix} 0 \\ 0 \\ C_f/m \\ C_f l_f/I_z \end{bmatrix}, \qquad \mathbf{E}_c = \begin{bmatrix} 0 \\ -V_{x,0} \\ 0 \\ 0 \end{bmatrix}. \tag{3.8}$$

Para utilizarlo en la predicción del MPC, el modelo se discretiza mediante un retenedor de orden cero (*zero-order hold*, ZOH), considerando las entradas constantes en cada intervalo de muestreo:

$$\mathbf{x}_{k+1} = \mathbf{A}_d\mathbf{x}_k + \mathbf{B}_d\delta_k + \mathbf{E}_d\kappa_{\text{ref},k}, \tag{3.9}$$

donde

$$\mathbf{A}_d = \exp\left(\mathbf{A}_c T_s\right), \tag{3.10}$$

$$\begin{bmatrix} \mathbf{B}_d & \mathbf{E}_d \end{bmatrix} = \int_0^{T_s} \exp\left(\mathbf{A}_c\tau\right) \begin{bmatrix} \mathbf{B}_c & \mathbf{E}_c \end{bmatrix} \mathrm{d}\tau. \tag{3.11}$$

Las matrices se calculan a la velocidad nominal $V_{x,0}$ y se mantienen constantes durante la simulación. Este modelo interno lineal, compuesto únicamente por el modelo de bicicleta, se denomina B0 y constituye la base física sobre la que se incorpora la corrección aprendida.

La simplificación que hace computacionalmente útil a B0 también origina discrepancias respecto de CarSim. Entre sus fuentes se encuentran la linealización de los neumáticos, la omisión de saturaciones y acoplamientos, los errores en los parámetros nominales y los cambios de régimen de operación. Un parámetro real desconocido pero constante puede

producir error de modelo sin constituir un cambio de distribución; el cambio de distribución aparece cuando la operación se aparta de las condiciones representadas por los datos o por las hipótesis empleadas para construir el modelo.

3.3. Modelos híbridos: física y residuales aprendidos

Un modelo híbrido conserva la predicción física como estructura base y añade una función aprendida para aproximar la discrepancia que esa estructura no explica. En forma general,

$$\mathbf{x}_{k+1} = f_{\text{phys}}(\mathbf{x}_k, \mathbf{u}_k) + \mathbf{r}_{\boldsymbol{\theta}}(\mathbf{x}_k, \mathbf{u}_k) + \mathbf{w}_k, \tag{3.12}$$

donde f_{phys} es el modelo nominal, $\mathbf{r}_{\boldsymbol{\theta}}$ es el residual aprendido y $\mathbf{w}_k$ agrupa perturbaciones y discrepancias no representadas. En la arquitectura B1, esta idea se particulariza para los estados laterales del modelo de bicicleta.

Para complementar la descripción física de B0, se incorpora un modelo residual que estima las discrepancias de predicción de la velocidad lateral y de la velocidad angular de guiñada. La combinación del modelo de bicicleta con esta corrección aprendida se denomina B1. Su propósito es representar parte de la dinámica que no queda recogida por las aproximaciones del modelo nominal, conservando la estructura física como base de la predicción.

Se define el vector de estados laterales como

$$\boldsymbol{\xi}_k = \begin{bmatrix} v_{y,k} \\ r_k \end{bmatrix}. \tag{3.13}$$

La predicción física de estos estados se obtiene mediante

$$\hat{\boldsymbol{\xi}}^{\text{B0}}_{k+1|k} = \mathbf{A}_{\text{lat}}\boldsymbol{\xi}_k + \mathbf{B}_{\text{lat}}\delta_k, \tag{3.14}$$

donde $\mathbf{A}_{\text{lat}} \in \mathbb{R}^{2\times 2}$ y $\mathbf{B}_{\text{lat}} \in \mathbb{R}^{2\times 1}$ son las submatrices de $\mathbf{A}_d$ y $\mathbf{B}_d$ correspondientes a los estados v_y y r, respectivamente.

Una vez definida la predicción física, el residual utilizado como objetivo de entrenamiento se obtiene como la diferencia entre la respuesta de CarSim en el instante siguiente y la predicción física a un paso:

$$\mathbf{d}_k = \boldsymbol{\xi}^{\text{CarSim}}_{k+1} - \hat{\boldsymbol{\xi}}^{\text{B0}}_{k+1|k} = \begin{bmatrix} d_{v_y,k} \\ d_{r,k} \end{bmatrix}. \tag{3.15}$$

Ambas respuestas se comparan para la misma transición, utilizando el estado inicial y la entrada de dirección correspondientes. El intervalo de predicción coincide con el período de muestreo del controlador, T_s. Por tanto, las componentes del residual tienen unidades

de m/s y rad/s: representan correcciones discretas de los estados, no de sus derivadas.

Para aproximar este residual, se utiliza una red neuronal de tipo *multilayer perceptron* (MLP), cuyo vector de entrada es

$$\mathbf{z}_k = \begin{bmatrix} V_{x,k} & v_{y,k} & r_k & \delta_k \end{bmatrix}^\mathsf{T}. \tag{3.16}$$

La red proporciona una estimación determinista de las dos componentes del residual:

$$\hat{\mathbf{d}}_k = \mathbf{g}_{\boldsymbol{\theta}}(\mathbf{z}_k), \tag{3.17}$$

donde $\boldsymbol{\theta}$ agrupa sus pesos y sesgos. Aunque la velocidad longitudinal medida forma parte de las entradas de la red, las matrices del modelo físico permanecen fijas en el punto nominal.

Una vez entrenado el residual, la predicción lateral del modelo híbrido se construye sumando la corrección aprendida a la predicción de B0:

$$\boxed{\hat{\boldsymbol{\xi}}^{\mathrm{B1}}_{k+1|k} = \mathbf{A}_{\mathrm{lat}}\boldsymbol{\xi}_k + \mathbf{B}_{\mathrm{lat}}\delta_k + \mathbf{g}_{\boldsymbol{\theta}}(\mathbf{z}_k).} \tag{3.18}$$

El residual se suma directamente a la predicción física, sin multiplicarlo nuevamente por T_s, porque ya representa una discrepancia sobre un intervalo de muestreo.

La validez de esta corrección depende del dominio cubierto por los datos. Fuera de él, un residual determinista puede producir una corrección numéricamente plausible sin indicar que su error ha aumentado. Esta limitación motiva estimar durante la operación la incertidumbre, la calibración y el grado de alejamiento respecto del dominio de entrenamiento, y relacionar esas señales con el efecto del error sobre el control.

3.4. Control predictivo basado en modelos

El MPC calcula una secuencia de entradas utilizando un modelo para predecir la evolución del sistema sobre un horizonte finito y considerar explícitamente sus restricciones [17]. Para un horizonte de predicción N, una formulación representativa es

$$\begin{aligned} \min_{\mathbf{u}_{0|k},\ldots,\mathbf{u}_{N-1|k}} \quad & \sum_{i=0}^{N-1} \left(\|\mathbf{x}_{i|k} - \mathbf{x}^{\mathrm{ref}}_{i|k}\|^2_{\mathbf{Q}} + \|\mathbf{u}_{i|k}\|^2_{\mathbf{R}} \right) + \|\mathbf{x}_{N|k} - \mathbf{x}^{\mathrm{ref}}_{N|k}\|^2_{\mathbf{P}}, \\ \text{sujeto a} \quad & \mathbf{x}_{i+1|k} = f_{\mathrm{pred}}(\mathbf{x}_{i|k}, \mathbf{u}_{i|k}), \\ & \mathbf{x}_{i|k} \in \mathcal{X}, \qquad \mathbf{u}_{i|k} \in \mathcal{U}. \end{aligned} \tag{3.19}$$

Las matrices $\mathbf{Q}$, $\mathbf{R}$ y $\mathbf{P}$ ponderan el seguimiento, el esfuerzo de control y el estado terminal; $\mathcal{X}$ y $\mathcal{U}$ representan las restricciones. Si f_{pred} es lineal se obtiene una formulación MPC lineal; si conserva no linealidades relevantes, el problema corresponde a NMPC.

Solo la primera entrada de la secuencia optimizada se aplica a la planta. En el instante siguiente se actualiza el estado, se desplaza el horizonte y se resuelve nuevamente el problema. Este principio de horizonte móvil permite incorporar nueva información, pero no elimina la dependencia respecto de la calidad del modelo: un error persistente en f_{pred} se propaga a lo largo del horizonte y puede modificar tanto el costo previsto como la activación de restricciones.

En esta tesis, el horizonte N es la principal variable candidata para adaptar el controlador con base en la señal de validez. La dirección y magnitud de esa adaptación no se presuponen: deben determinarse mediante el análisis del compromiso entre alcance predictivo, acumulación del error de modelo, desempeño en lazo cerrado y costo computacional.

3.5. Funciones de barrera de control como extensión opcional

Capítulo 4

Información aprendida y validez durante la operación

4.1. Información aprendida relevante para el controlador

La información producida por un modelo aprendido resulta relevante para el control cuando interviene en la representación de la dinámica, en la estimación del estado o en alguna decisión del controlador. El aprendizaje puede utilizarse, por ejemplo, para representar fuerzas o componentes de la dinámica, estimar estados o parámetros y corregir las predicciones de un modelo nominal. Estas funciones no son equivalentes: un modelo de fuerzas aprendido introduce una descripción específica de un subsistema, un estimador proporciona una magnitud física o un estado y un modelo residual aproxima directamente la discrepancia de predicción sin separar sus causas [24, 2, 11].

En esta tesis, la información aprendida principal es el residual discreto definido en la ecuación (3.15). A partir de las variables disponibles en $\mathbf{z}_k$, el modelo aprendido estima la corrección $\hat{\mathbf{d}}_k$ de la velocidad lateral y de la velocidad angular de guiñada. Esta corrección se incorpora a la transición utilizada por el MPC/NMPC, según la ecuación (3.18). Por tanto, el residual no constituye una acción de control ni una estimación directa de la adherencia, la masa o la rigidez lateral de los neumáticos: representa el efecto conjunto que las simplificaciones estructurales, los errores paramétricos y otras discrepancias producen sobre la predicción a un paso. Esta formulación permite aprender el error del modelo sin identificar por separado cada causa física, como ocurre en otros enfoques de aprendizaje residual para control predictivo [11, 7].

La arquitectura distingue así tres niveles de información. Los parámetros reales pertenecen a la planta y pueden cambiar entre escenarios; los parámetros nominales determinan el modelo físico B0; y las señales medidas o estimadas forman las entradas disponibles para calcular la predicción. En el protocolo propuesto, V_x, v_y, r y δ están disponibles para

el modelo residual, mientras que la adherencia y los parámetros que caracterizan la masa, las inercias o los neumáticos no se suministran como entradas cuando el experimento los define como desconocidos. En consecuencia, un cambio físico latente puede modificar la discrepancia modelo–planta aun cuando las variables observadas permanezcan dentro de rangos conocidos.

La relevancia del residual no se determina únicamente por su error instantáneo. Al formar parte del modelo de transición, sus correcciones pueden propagarse a lo largo del horizonte de predicción y modificar la secuencia de entradas seleccionada por el controlador. En las configuraciones probabilísticas, la predicción residual se acompaña además de una caracterización de su dispersión o de la incertidumbre del modelo. Estas señales adicionales no sustituyen al residual ni constituyen por sí solas una medida de validez; su función es aportar evidencia para evaluar si la corrección aprendida continúa siendo adecuada para las decisiones de control. Las secciones siguientes precisan la interpretación de la incertidumbre, los cambios de distribución y la validez durante la operación.

4.2. Incertidumbre predictiva

Una predicción puntual del residual indica la corrección que el modelo considera más probable, pero no expresa cuánta dispersión atribuye a esa estimación. Los modelos probabilísticos representan cada componente $d_{j,k}$ mediante una distribución predictiva condicionada a la entrada y a los datos de entrenamiento,

$$p(d_{j,k} \mid \mathbf{z}_k, \mathcal{D}_{\mathrm{tr}}), \qquad j \in \{v_y, r\}. \tag{4.1}$$

En las configuraciones estudiadas, esta distribución se describe mediante una media $\mu_{j,k}$ y una varianza predictiva. Para facilitar el análisis, la varianza total se descompone operacionalmente como

$$U^2_{\mathrm{tot},j,k} = U^2_{\mathrm{ale},j,k} + U^2_{\mathrm{epi},j,k}, \tag{4.2}$$

donde U_{ale} representa la dispersión condicional atribuida a la variabilidad aleatoria y U_{epi} la incertidumbre asociada al conocimiento del modelo. Esta separación depende del modelo y del procedimiento de estimación: sus componentes no son magnitudes físicas observadas directamente ni quedan identificadas de manera única a partir de los datos.

La incertidumbre predictiva se utiliza aquí como información de supervisión del residual, no como sinónimo de error. Una desviación estándar elevada no demuestra que la media sea incorrecta y una desviación pequeña no garantiza que la predicción sea válida. Su utilidad debe establecerse contrastándola con los errores observados, con los cambios de distribución y, finalmente, con las consecuencias de esos errores para el controlador.

4.2.1. Incertidumbre aleatoria

La incertidumbre aleatoria describe la variabilidad que permanece en la salida después de condicionar la predicción a las variables proporcionadas al modelo. Puede reunir ruido de medición, perturbaciones no observadas y variaciones de la planta que las entradas seleccionadas no permiten explicar. Se considera no reducible bajo la representación y la información disponibles, aunque puede cambiar si se incorporan nuevas variables, se modifica el modelo o mejora el sistema de medición. Por esta razón, la separación entre incertidumbre aleatoria y error de modelado debe interpretarse con relación a los supuestos adoptados, y no como una clasificación absoluta [5].

Cuando se supone una dispersión constante para todo el espacio de entrada, el modelo es homoscedástico. Esta hipótesis se utiliza en B2, donde el término $\sigma_{n,j}^2$ de la ecuación (7.6) es único para cada componente del residual. Un modelo heteroscedástico permite, en cambio, que la dispersión dependa de $\mathbf{z}_k$:

$$d_{j,k} = \mu_j(\mathbf{z}_k) + \varepsilon_{j,k}, \qquad \varepsilon_{j,k} \sim \mathcal{N}\big(0, U_{\text{ale},j}^2(\mathbf{z}_k)\big)\,. \tag{4.3}$$

B3 aprende esta dispersión junto con la media mediante una función de pérdida gaussiana heteroscedástica, mientras que B4 la estima en una segunda etapa a partir de residuos fuera de pliegue. En ambos casos, U_{ale} debe leerse como una estimación operacional de la dispersión residual. Puede contener no solo ruido físico, sino también discrepancias de la media y variabilidad no explicada entre corridas.

Una región con elevada dispersión condicional puede seguir perteneciendo al dominio de entrenamiento, y un cambio físico no observado puede producir un error sistemático sin incrementar esta componente. En consecuencia, la incertidumbre aleatoria aporta información sobre la amplitud esperada de los errores, pero no establece por sí sola que el residual haya perdido validez.

4.2.2. Incertidumbre epistémica

La incertidumbre epistémica representa la falta de conocimiento asociada a datos finitos, cobertura insuficiente del dominio y ambigüedad en el ajuste del modelo. A diferencia de la componente aleatoria, puede reducirse en principio mediante observaciones informativas en las regiones pertinentes, aunque la reducción efectiva depende de la capacidad de la familia de modelos para representar la dinámica [5].

Esta componente se aproxima de dos maneras en las configuraciones probabilísticas. En los procesos gaussianos B2 y B4 se utiliza la desviación posterior de la función latente, que depende de la ubicación de la consulta respecto de los datos de entrenamiento y del kernel seleccionado. En B3 se emplea el desacuerdo entre las medias de los miembros del

conjunto:

$$U^2_{\text{epi},j,k} = \frac{1}{M}\sum_{m=1}^{M}\left(\mu^{(m)}_{j,k} - \bar{\mu}_{j,k}\right)^2, \qquad \bar{\mu}_{j,k} = \frac{1}{M}\sum_{m=1}^{M}\mu^{(m)}_{j,k}. \tag{4.4}$$

El desacuerdo refleja sensibilidad a distintas soluciones obtenidas durante el entrenamiento, pero no cubre todas las fuentes de desconocimiento. Los miembros pueden compartir datos, arquitectura y sesgos de representación y, por tanto, coincidir en una predicción errónea.

Es esperable que U_{epi} aumente en regiones escasamente representadas, pero esta respuesta no está garantizada ante cualquier cambio. En particular, una modificación de adherencia, masa o neumáticos que no forme parte de $\mathbf{z}_k$ puede alterar la relación entrada–salida sin desplazar visiblemente las entradas. La incertidumbre epistémica y la detección fuera de distribución son, por tanto, conceptos relacionados pero no equivalentes: una entrada alejada puede no causar un error relevante y un cambio dinámico latente puede producir un fallo confiado.

4.2.3. Calibración

La calibración contrasta las distribuciones predictivas con los errores que se observan posteriormente. Para una aproximación gaussiana con desviación $U_{\text{tot},j,k}$, un intervalo bilateral con nivel nominal $1-\alpha$ se define como

$$\mathcal{I}^{1-\alpha}_{j,k} = \left[\mu_{j,k} - q_{1-\alpha/2}U_{\text{tot},j,k}, \mu_{j,k} + q_{1-\alpha/2}U_{\text{tot},j,k}\right], \tag{4.5}$$

donde $q_{1-\alpha/2}$ es el cuantil correspondiente de la distribución normal estándar. La cobertura empírica sobre N observaciones es

$$\widehat{\text{Cov}}^{1-\alpha}_{j} = \frac{1}{N}\sum_{k=1}^{N}\mathbb{I}\left\{d_{j,k} \in \mathcal{I}^{1-\alpha}_{j,k}\right\}. \tag{4.6}$$

Una cobertura inferior al nivel nominal indica sobreconfianza, mientras que una cobertura superior puede indicar intervalos conservadores. Sin embargo, la cobertura aislada no recompensa la concentración: intervalos innecesariamente amplios pueden cubrir muchas observaciones y aportar poca información.

Por este motivo se utiliza también la log-verosimilitud negativa gaussiana, que combina el error de la media con la dispersión declarada:

$$\text{NLL}_j = \frac{1}{N}\sum_{k=1}^{N}\left[\frac{1}{2}\log\left(2\pi U^2_{\text{tot},j,k}\right) + \frac{\left(d_{j,k} - \mu_{j,k}\right)^2}{2U^2_{\text{tot},j,k}}\right]. \tag{4.7}$$

La evaluación conjunta de cobertura y NLL permite detectar tanto sobreconfianza como dispersiones excesivas. Cuando la predicción procede de una mezcla, como en el conjun-

to B3, debe indicarse si la NLL corresponde a la mezcla exacta o a una aproximación gaussiana obtenida mediante ajuste de momentos.

La calibración debe comprobarse en particiones no utilizadas para ajustar el modelo y desglosarse por región y familia de cambio. Una cobertura adecuada en promedio dentro del dominio nominal puede ocultar errores locales y no garantiza que los intervalos permanezcan calibrados cuando cambia la dinámica. Además, calibrar el error residual a un paso no demuestra que la incertidumbre represente el error acumulado sobre el horizonte ni su efecto en lazo cerrado. Por ello, la calibración constituye una condición de calidad para interpretar las señales probabilísticas, pero no una definición suficiente de validez para el control.

4.3. Detección fuera de distribución y cambios de distribución en la dinámica vehicular

4.3.1. Régimen físico no representado

4.3.2. Dinámica fuera de distribución

4.3.3. Entradas fuera de distribución

4.3.4. Fallo o degradación de sensores

4.4. Validez y confianza durante la operación

$$C_k = g(U_{\mathrm{epi},k}, U_{\mathrm{ale},k}, \mathrm{Cal}_k, S_{\mathrm{OOD},k}) \,, \tag{4.8}$$

4.5. Validez relevante para el control

Capítulo 5

Estado del arte

5.1. Estrategia de revisión bibliográfica

5.2. Modelos aprendidos e híbridos para el control de la dinámica vehicular

5.3. Dinámica aprendida con consideración de la incertidumbre para el control

5.4. Detección fuera de distribución, cambios de distribución y supervisión durante la operación

5.5. Control con consideración de la validez y la confianza

5.6. Síntesis crítica y brecha de investigación

Capítulo 6

Marco conceptual y arquitectura propuesta

6.1. La cadena cambio–validez–control

6.2. Modelo híbrido de predicción

6.3. Estimador de validez

6.4. Integración con MPC/NMPC

6.5. Extensiones opcionales

6.5.1. Modulación de una función de barrera de control (CBF)

6.5.2. Adquisición de datos y reentrenamiento

Capítulo 7

Metodología de investigación y validación (prioridad 1)

7.1. Estrategia general

E1: Establecer el modelo físico orientado al control y el controlador MPC/NMPC de referencia.

E2: Entrenar el residual aprendido y cuantificar su mejora y sus limitaciones respecto al modelo físico dentro del dominio nominal.

E3: Implementar la estimación de incertidumbre aleatoria y epistémica, la calibración y una puntuación OOD de bajo costo computacional.

E4: Diseñar cambios físicamente interpretables en la dinámica vehicular y caracterizar sus efectos sobre la predicción, la incertidumbre, OOD y la validez.

E5: Construir y validar la señal C_k frente al error relevante para el control.

E6: Integrar C_k en la adaptación de MPC/NMPC.

E7: Comparar las arquitecturas de referencia y el enfoque propuesto bajo condiciones nominales y fuera de distribución.

E8: Evaluar la robustez empírica y, si el avance lo permite, incorporar las extensiones con CBF y/o DAgger.

7.2. Entorno común de entrenamiento y evaluación de los modelos

Los modelos B1–B4 se construyen sobre el mismo modelo físico B0 y utilizan un entorno experimental común. Esta decisión permite atribuir las diferencias observadas al

tipo de modelo residual y a su representación de la incertidumbre, sin confundirlas con cambios en los datos, la partición o el preprocesamiento. En esta sección se documentan una sola vez el modelo nominal, el dominio de identificación, la partición congelada y el protocolo de evaluación. Las secciones dedicadas a cada modelo describen únicamente sus particularidades.

7.2.1. Modelo físico nominal B0

Cuadro 7.1: Parámetros utilizados en el modelo de bicicleta nominal B0.

Símbolo	Descripción	Valor	Unidad
m	Masa del vehículo	1501	kg
I_z	Momento de inercia de guiñada	2192,089539	$\mathrm{kg\,m^2}$
l_f	Distancia del CG al eje delantero	1,049562958	m
l_r	Distancia del CG al eje trasero	1,860437042	m
C_f	Rigidez lateral equivalente del eje delantero	159055	N/rad
C_r	Rigidez lateral equivalente del eje trasero	92776,5	N/rad
$V_{x,0}$	Velocidad longitudinal nominal	60/3,6	m/s
T_s	Período de muestreo	0,020	s

Las matrices discretas de B0 se obtienen mediante un retenedor de orden cero con el período de muestreo indicado en el Cuadro 7.1. Se calculan en el punto de velocidad nominal y se mantienen fijas durante la generación y evaluación de las líneas base. Los parámetros reales modificados en los escenarios de cambio se registran por separado y no se proporcionan al controlador, salvo que el protocolo de un experimento lo indique explícitamente.

7.2.2. Generación de datos y dominio nominal

Los datos proceden de simulaciones en lazo cerrado con la planta CarSim, el vehículo *C-Class hatchback* y un MPC basado exclusivamente en B0. El dominio de identificación comprende las maniobras *double lane change* (DLC) y *double lane change truncated* (DLCT), una velocidad de referencia de 60 km/h y un coeficiente de adherencia $\mu = 1$. Las señales se muestrean a 50 Hz, de modo que cada objetivo representa la discrepancia acumulada durante un intervalo de 20 ms.

El conjunto contiene cinco corridas completas de cada maniobra. No se excluyeron muestras del dominio nominal: las diez corridas aportan 5170 transiciones, distribuidas como se resume en el Cuadro 7.2.

Para todos los modelos, la entrada es el vector $\mathbf{z}_k = [V_{x,k},\, v_{y,k},\, r_k,\, \delta_k]^\mathsf{T}$ definido en la ecuación (3.16), y el objetivo es el residual discreto $\mathbf{d}_k = [d_{v_y,k},\, d_{r,k}]^\mathsf{T}$ de la ecuación (3.15). Por tanto, la matriz de entradas tiene dimensión 5170×4 y la matriz de objetivos dimensión 5170×2. La consistencia de los residuos almacenados se verificó reconstruyendo

Cuadro 7.2: Composición del conjunto nominal común a B1–B4.

Maniobra	Corridas	Muestras por corrida	Total
DLC	001–005	634	3170
DLCT	001–005	400	2000
Total	10	—	5170

ambas componentes a partir de la predicción de B0 y la respuesta de CarSim; el error máximo de esa comprobación fue numéricamente nulo.

7.2.3. Partición congelada por corridas

La separación se realiza por corridas completas y se conserva sin cambios para B1–B4. De esta manera, ninguna transición de una corrida aparece en más de una partición y todas las comparaciones utilizan exactamente los mismos datos. Para abreviar, DLC-002 denota la corrida 002 de la maniobra DLC y análogamente para los demás grupos.

Cuadro 7.3: Partición común y congelada de las corridas nominales.

Partición	Corridas	Muestras
Entrenamiento	DLC-001, DLCT-001, DLCT-002, DLC-004, DLCT-004 y DLC-005	3102
Validación	DLC-003 y DLCT-005	1034
Prueba ID	DLC-002 y DLCT-003	1034

La partición de validación se utiliza para seleccionar configuraciones o detener el entrenamiento, según el algoritmo. La partición de prueba ID permanece excluida de esas decisiones y se utiliza únicamente para la comparación final dentro del dominio nominal. Esta definición explícita sustituye una descripción basada solamente en una semilla aleatoria y constituye la referencia reproducible para los modelos posteriores.

7.2.4. Preprocesamiento y protocolo de comparación

Las entradas y los objetivos se estandarizan con estadísticas calculadas exclusivamente sobre las 3102 muestras de entrenamiento:

$$\tilde{\mathbf{z}}_k = \mathbf{S}_z^{-1} \left(\mathbf{z}_k - \boldsymbol{\mu}_z \right), \tag{7.1}$$

$$\tilde{\mathbf{d}}_k = \mathbf{S}_d^{-1} \left(\mathbf{d}_k - \boldsymbol{\mu}_d \right). \tag{7.2}$$

Los vectores $\boldsymbol{\mu}_z$ y $\boldsymbol{\mu}_d$ contienen las medias de entrenamiento, mientras que $\mathbf{S}_z$ y $\mathbf{S}_d$ son matrices diagonales con las desviaciones estándar correspondientes. Las mismas transformaciones se aplican sin reajuste a validación y prueba ID. Una predicción normalizada se

devuelve a unidades físicas mediante

$$\hat{\mathbf{d}}_k = \boldsymbol{\mu}_d + \mathbf{S}_d \hat{\tilde{\mathbf{d}}}_k. \tag{7.3}$$

La capacidad predictiva se evalúa por componente mediante RMSE y MAE del residual. Además, la predicción híbrida a un paso se compara con B0 sobre las mismas transiciones de prueba ID. Para los modelos probabilísticos se añaden métricas de incertidumbre y calibración, pero estas se definen en las secciones particulares correspondientes. Los escenarios externos al dominio nominal no intervienen en el entrenamiento ni en la selección y se reservan para el estudio de pérdida de validez.

7.3. Descripción de los modelos entrenados

Cada modelo se presenta a partir de su función dentro del estudio, su estructura específica, el criterio de entrenamiento o selección y su verificación en la partición común. El dominio de datos, las variables, la normalización y la partición no se repiten en las descripciones individuales.

7.3.1. B1: MLP residual determinista

B1 es la línea base residual determinista. Su función es establecer cuánto puede reducirse el error de B0 mediante una corrección neuronal puntual, sin incorporar todavía una distribución predictiva, una descomposición de incertidumbre ni un mecanismo de supervisión de validez. La salida de B1 es la estimación de las dos componentes del residual a un paso.

La MLP recibe cuatro entradas estandarizadas, contiene dos capas ocultas de 64 neuronas con activación ReLU y produce dos salidas lineales. En forma compacta,

$$\hat{\tilde{\mathbf{d}}}_k = \mathbf{W}_3 \rho(\mathbf{W}_2 \rho(\mathbf{W}_1 \tilde{\mathbf{z}}_k + \mathbf{b}_1) + \mathbf{b}_2) + \mathbf{b}_3, \tag{7.4}$$

donde $\rho(a) = \max(0, a)$ se aplica componente a componente. La salida se desestandariza mediante la ecuación (7.3) y se suma directamente a la predicción física, conforme a la ecuación (3.18).

El ajuste se realiza con la función `fitrnet` de MATLAB. Se comparan límites de 100 y 200 iteraciones y se selecciona el candidato con menor RMSE conjunto de validación en el espacio estandarizado:

$$J_{\text{val}} = \sqrt{\frac{1}{2N_{\text{val}}} \sum_{k \in \mathcal{I}_{\text{val}}} \left\| \tilde{\mathbf{d}}_k - \hat{\tilde{\mathbf{d}}}_k \right\|_2^2}. \tag{7.5}$$

El límite de 200 iteraciones obtuvo $J_{\text{val}} = 0{,}073810$, frente a 0,075873 para 100 iteracio-

nes, y fue la configuración conservada. El Cuadro 7.4 resume únicamente las decisiones específicas de B1.

Cuadro 7.4: Configuración específica del modelo B1.

Elemento	Configuración
Función en el estudio	Línea base residual determinista
Tipo de modelo	MLP de regresión entrenada con `fitrnet`
Arquitectura	$4 \to 64 \to 64 \to 2$
Activación	ReLU en las capas ocultas y salida lineal
Salida	Estimación puntual de $d_{v_y,k}$ y $d_{r,k}$
Límites evaluados	100 y 200 iteraciones
Configuración seleccionada	200 iteraciones
Criterio de selección	Menor RMSE conjunto estandarizado de validación
Incertidumbre predictiva	No disponible

El Cuadro 7.5 presenta el desempeño del residual en las tres particiones. La proximidad entre entrenamiento y validación indica que la selección no depende de una reducción del error exclusiva de las muestras de ajuste; la prueba ID se mantiene como comprobación independiente.

Cuadro 7.5: Desempeño de B1 en la predicción del residual a 20 ms.

	d_{v_y} (m/s)		d_r (rad/s)	
Partición	RMSE	MAE	RMSE	MAE
Entrenamiento	0.009128	0.006627	0.007390	0.005420
Validación	0.008871	0.006100	0.007033	0.004664
Prueba ID	0.010784	0.008180	0.008546	0.006490

Finalmente, el Cuadro 7.6 compara la predicción a un paso de B0 y B1 en prueba ID. B1 reduce el RMSE de v_y en un 91,66 % y el de r en un 90,25 %. Estos resultados justifican su uso como línea base predictiva, pero no informan sobre la validez de la corrección fuera del dominio nominal.

Cuadro 7.6: Comparación a un paso entre B0 y B1 en prueba ID.

Estado	RMSE B0	RMSE B1	Mejora
v_y (m/s)	0.129336	0.010784	91,66 %
r (rad/s)	0.087671	0.008546	90,25 %

7.3.2. B2: proceso gaussiano homoscedástico

B2 reemplaza la MLP determinista de B1 por dos procesos gaussianos (GP) independientes, uno para d_{v_y} y otro para d_r. Su función en el estudio es conservar una capacidad

de corrección comparable con B1 y añadir una distribución predictiva que permita cuantificar la incertidumbre dentro y fuera del dominio nominal. La independencia entre las dos salidas simplifica el entrenamiento, aunque implica que B2 no modela explícitamente su covarianza cruzada.

Para cada componente $j \in \{v_y, r\}$ se considera

$$d_{j,k} = f_j(\tilde{\mathbf{z}}_k) + \varepsilon_{j,k}, \qquad \varepsilon_{j,k} \sim \mathcal{N}(0, \sigma_{n,j}^2), \tag{7.6}$$

donde f_j sigue un GP exacto con kernel cuadrático exponencial y selección automática de relevancia (ARD). Para entradas estandarizadas, el kernel puede escribirse como

$$k_j(\mathbf{z}, \mathbf{z}') = \sigma_{f,j}^2 \exp\left[-\frac{1}{2}\sum_{q=1}^{4}\frac{(z_q - z_q')^2}{\ell_{j,q}^2}\right], \tag{7.7}$$

con una escala de longitud $\ell_{j,q}$ por entrada. El término $\sigma_{n,j}$ es constante en todo el espacio de entrada; esta hipótesis define el carácter homoscedástico de B2.

La distribución predictiva de cada salida se representa como

$$p(d_{j,*} \mid \tilde{\mathbf{z}}_*, \mathcal{D}_{\text{tr}}) = \mathcal{N}\left(\mu_{j,*}, \sigma_{\text{epi},j,*}^2 + \sigma_{n,j}^2\right). \tag{7.8}$$

Aquí, $\sigma_{\text{epi},j,*}$ corresponde a la desviación estándar posterior de la función latente y disminuye cerca de datos informativos; $\sigma_{n,j}$ representa una dispersión constante aprendida. Por tanto, B2 proporciona una incertidumbre predictiva total y una aproximación a la componente epistémica, pero no puede representar variaciones locales de la dispersión aleatoria.

Se entrenan los dos GP sobre la partición común, sin búsqueda adicional de datos o modificación de la normalización. El Cuadro 7.7 resume las decisiones específicas y los tiempos registrados en el artefacto de entrenamiento.

Cuadro 7.7: Configuración específica del modelo B2.

Elemento	Configuración
Función en el estudio	Línea base probabilística homoscedástica
Tipo de modelo	Dos GP exactos independientes
Kernel	Cuadrático exponencial con ARD
Salidas	Distribuciones predictivas separadas para $d_{v_y,k}$ y $d_{r,k}$
Modelo de ruido	Gaussiano, aprendido y constante para cada salida
Incertidumbre disponible	Total y epistémica latente aproximada
Tiempo de entrenamiento	42,402 s para d_{v_y} y 35,840 s para d_r

Las escalas de longitud aprendidas se muestran en el Cuadro 7.8. Como las entradas se encuentran estandarizadas, una escala menor indica una variación más rápida de la

función respecto de esa característica, pero no constituye por sí sola una medida causal de importancia.

Cuadro 7.8: Escalas de longitud ARD aprendidas por B2.

Entrada	GP de d_{v_y}	GP de d_r
V_x	2.6832	1.2561
v_y	3.1020	1.8271
r	0.9062	0.9574
δ	1.7534	1.3580

El Cuadro 7.9 presenta el desempeño de la media predictiva. Los errores son cercanos a los obtenidos por B1, lo que permite estudiar la información probabilística de B2 sin introducir una pérdida relevante de precisión nominal.

Cuadro 7.9: Desempeño de B2 en la predicción del residual a 20 ms.

	d_{v_y} (m/s)		d_r (rad/s)	
Partición	RMSE	MAE	RMSE	MAE
Entrenamiento	0.009375	0.006769	0.007347	0.005371
Validación	0.008791	0.005860	0.006884	0.004620
Prueba ID	0.010684	0.008057	0.008624	0.006552

En prueba ID, los niveles de ruido homoscedástico aprendidos fueron 0,009575 m/s para d_{v_y} y 0,007583 rad/s para d_r. El Cuadro 7.10 resume los diagnósticos probabilísticos. La cobertura de los intervalos gaussianos nominales del 95 % queda alrededor del 91,7 %, lo que indica una ligera sobreconfianza y motiva evaluar posteriormente la calibración de forma explícita.

Cuadro 7.10: Diagnósticos probabilísticos de B2 en prueba ID.

Magnitud	d_{v_y}	d_r
σ_n aprendida	0,009575 m/s	0,007583 rad/s
Desviación predictiva media	0,009824 m/s	0,007936 rad/s
Desviación epistémica media aproximada	0,001766 m/s	0,001841 rad/s
Cobertura del intervalo del 95 %	91,68 %	91,78 %
NLL gaussiano	−3,1080	−3,3202

La comparación a un paso del Cuadro 7.11 confirma que la media de B2 conserva la mejora predictiva del modelo híbrido: reduce el RMSE de v_y en un 91,74 % y el de r en un 90,16 % respecto de B0. Su contribución diferencial frente a B1 no es, por tanto, una mejora sustancial de la media, sino la disponibilidad de una distribución predictiva homoscedástica que servirá como referencia para los modelos heteroscedásticos posteriores.

Cuadro 7.11: Comparación a un paso entre B0 y B2 en prueba ID.

Estado	RMSE B0	RMSE B2	Mejora
v_y (m/s)	0.129336	0.010684	91,74 %
r (rad/s)	0.087671	0.008624	90,16 %

7.3.3. B3: conjunto profundo de MLP heteroscedásticas

B3 utiliza un *deep ensemble* formado por cinco MLP heteroscedásticas. A diferencia de B1, cada miembro predice simultáneamente la media y la varianza condicional de las dos componentes del residual. A diferencia de B2, la dispersión aleatoria puede cambiar con la entrada y la incertidumbre epistémica se aproxima mediante el desacuerdo entre redes entrenadas de forma independiente.

Cada miembro $m \in \{1, \ldots, M\}$ recibe $\tilde{\mathbf{z}}_k$ y produce cuatro salidas:

$$\left[\boldsymbol{\mu}_k^{(m)}, \mathbf{s}_k^{(m)}\right] = \mathbf{g}_{\boldsymbol{\theta}_m}(\tilde{\mathbf{z}}_k), \qquad \boldsymbol{\mu}_k^{(m)}, \mathbf{s}_k^{(m)} \in \mathbb{R}^2, \tag{7.9}$$

donde $\boldsymbol{\mu}_k^{(m)}$ es la media residual normalizada y $\mathbf{s}_k^{(m)}$ representa la log-varianza. Para mantener estable el entrenamiento, sus componentes se restringen al intervalo $[-8, 5]$ y se transforman mediante

$$\left(\boldsymbol{\sigma}^2\right)_k^{(m)} = \exp\left(\mathbf{s}_k^{(m)}\right). \tag{7.10}$$

Cada red se ajusta minimizando la log-verosimilitud negativa (NLL) gaussiana heteroscedástica en el espacio normalizado. Omitiendo constantes independientes de los parámetros, la pérdida de un miembro es

$$\mathcal{L}_{mathrmNLL}^{(m)} = \frac{1}{2N} \sum_{k=1}^{N} \sum_{j=1}^{2} \left[s_{j,k}^{(m)} + \exp\left(-s_{j,k}^{(m)}\right) \left(\tilde{d}_{j,k} - \mu_{j,k}^{(m)}\right)^2 \right]. \tag{7.11}$$

Esta función obliga a cada miembro a equilibrar el error de la media y la dispersión que asigna a cada muestra; una varianza grande reduce la penalización cuadrática, pero aumenta directamente el término de log-varianza.

La predicción conjunta se obtiene combinando los momentos de los $M = 5$ miembros.

Para cada componente del residual,

$$\bar{\mu}_k = \frac{1}{M}\sum_{m=1}^{M} \mu_k^{(m)}, \tag{7.12}$$

$$U_{\text{epi},k}^2 = \frac{1}{M}\sum_{m=1}^{M} \left(\mu_k^{(m)} - \bar{\mu}_k\right)^2, \tag{7.13}$$

$$U_{\text{ale},k}^2 = \frac{1}{M}\sum_{m=1}^{M} \left(\sigma^2\right)_k^{(m)}, \tag{7.14}$$

$$U_{\text{tot},k} = \sqrt{U_{\text{epi},k}^2 + U_{\text{ale},k}^2}. \tag{7.15}$$

Las medias y desviaciones se transforman después a unidades físicas mediante las estadísticas comunes de los objetivos. U_{ale} debe interpretarse como una estimación operacional de la dispersión condicional aprendida, no como una medición directa y pura del ruido físico.

Cada MLP conserva las dos capas ocultas de 64 neuronas de B1, pero su capa de salida tiene cuatro componentes. El entrenamiento utiliza lotes de 256 muestras, tasa de aprendizaje 10^{-3}, un máximo de 250 épocas y parada temprana con paciencia de 25 épocas. La semilla base 42 controla la inicialización reproducible de los miembros; no define la partición de datos, que permanece fijada por el Cuadro 7.3. El entrenamiento se realizó en CPU. El Cuadro 7.12 resume estas decisiones.

Cuadro 7.12: Configuración específica del modelo B3.

Elemento	Configuración
Función en el estudio	Línea base neuronal con incertidumbre descompuesta
Tipo de modelo	*Deep ensemble* heteroscedástico de cinco MLP
Arquitectura por miembro	$4 \to 64 \to 64 \to 4$
Salidas por miembro	Dos medias y dos log-varianzas
Función de pérdida	NLL gaussiana heteroscedástica
Tamaño de lote	256 muestras
Tasa de aprendizaje	10^{-3}
Épocas máximas y paciencia	250 y 25, respectivamente
Límites de log-varianza	$[-8, 5]$
Semilla base	42
Incertidumbre disponible	Epistémica, aleatoria condicional y total

Los cinco miembros activaron la parada temprana y alcanzaron valores de NLL de validación próximos entre sí, sin que apareciera una red claramente anómala. El Cuadro 7.13 presenta la época final y el mejor valor de validación de cada miembro.

En prueba ID, la media del conjunto alcanzó los resultados del Cuadro 7.14. Su precisión permanece en el mismo orden que B1 y B2, por lo que la estimación heteroscedástica y el desacuerdo del conjunto no se obtienen a costa de una degradación relevante de la

Cuadro 7.13: Convergencia de los miembros del conjunto B3.

Miembro	Época de parada	Mejor NLL de validación
1	187	−2,1428
2	122	−2,0985
3	169	−2,1416
4	120	−2,1212
5	145	−2,1013

predicción nominal.

Cuadro 7.14: Desempeño predictivo de B3 en prueba ID.

Métrica	d_{v_y} (m/s)	d_r (rad/s)
RMSE	0.010591	0.008718
MAE	0.007949	0.006583

El Cuadro 7.15 muestra que, dentro del dominio nominal, la incertidumbre aleatoria media es aproximadamente cinco veces mayor que la epistémica. Esto es consistente con un conjunto cuyos miembros coinciden en regiones representadas por los datos, mientras mantienen una dispersión condicional residual. La cobertura permanece por debajo del 95 % nominal, por lo que B3 está ligeramente sobreconfiado en prueba ID.

Cuadro 7.15: Diagnósticos probabilísticos de B3 en prueba ID.

Magnitud	d_{v_y}	d_r
U_{epi} medio	0,001680 m/s	0,001533 rad/s
U_{ale} medio	0,009230 m/s	0,007686 rad/s
U_{tot} medio	0,009438 m/s	0,007890 rad/s
Cobertura del intervalo del 95 %	92,36 %	93,13 %
NLL gaussiano ajustado por momentos	−3,1869	−3,3687

El NLL anterior corresponde a la aproximación gaussiana $\mathcal{N}(\bar{\mu}, U_{\text{epi}}^2 + U_{\text{ale}}^2)$ obtenida por ajuste de momentos; no es el NLL exacto de la mezcla de cinco gaussianas. Esta convención permite compararlo con B2, pero debe conservarse al interpretar sus valores. Frente al GP homoscedástico, B3 mejora modestamente tanto la cobertura como el NLL en prueba ID, aunque ninguno de los dos modelos está perfectamente calibrado.

Finalmente, el Cuadro 7.16 muestra la comparación con B0. B3 reduce el RMSE de v_y en un 91,81 % y el de r en un 90,06 %. Su contribución principal respecto de B1 y B2 es proporcionar simultáneamente una media residual competitiva, una dispersión condicional y una señal de desacuerdo entre modelos.

Cuadro 7.16: Comparación a un paso entre B0 y B3 en prueba ID.

Estado	RMSE B0	RMSE B3	Mejora
v_y (m/s)	0.129336	0.010591	91,81 %
r (rad/s)	0.087671	0.008718	90,06 %

7.3.4. B4: proceso gaussiano heteroscedástico en dos etapas

B4 conserva sin modificaciones los dos GP de media de B2 y añade una segunda etapa destinada a estimar una dispersión residual dependiente de la entrada. Esta construcción permite aislar el efecto de la heteroscedasticidad: B2 y B4 comparten la misma media predictiva y la misma incertidumbre epistémica latente, mientras que difieren en el tratamiento de la dispersión residual, constante en B2 y variable en B4.

La primera etapa se define por los GP exactos con kernel cuadrático exponencial ARD descritos para B2. Para entrenar la segunda etapa sin emplear residuos obtenidos sobre las mismas muestras usadas para ajustar la media, se generan predicciones fuera de pliegue dentro de la partición de entrenamiento. Si $g(i)$ identifica el grupo al que pertenece la muestra i, el residuo correspondiente es

$$e_{j,i}^{\mathrm{OOF}} = d_{j,i} - \hat{\mu}_j^{(-g(i))}(\tilde{\mathbf{z}}_i), \qquad j \in \{v_y, r\}, \tag{7.16}$$

donde $\hat{\mu}_j^{(-g(i))}$ se obtiene sin utilizar el grupo de la muestra evaluada. Los RMSE de estas predicciones fuera de pliegue fueron 0,010188 m/s para d_{v_y} y 0,008365 rad/s para d_r.

Para cada salida se ajusta un segundo GP sobre una transformación logarítmica del residuo cuadrático fuera de pliegue. El artefacto de entrenamiento conserva la corrección $c_{\chi^2} = \mathbb{E}[\log(\chi_1^2)] = -1{,}27036$, empleada para compensar el sesgo introducido por la transformación logarítmica. En forma compacta, el objetivo de esta etapa puede expresarse como

$$q_{j,i} = \log\left[\left(e_{j,i}^{\mathrm{OOF}}\right)^2 + \epsilon_j\right] - c_{\chi^2}, \tag{7.17}$$

donde $\epsilon_j > 0$ evita la singularidad del logaritmo. Si $\hat{q}_j(\tilde{\mathbf{z}}_*)$ es la predicción del GP de dispersión, las componentes operacionales de incertidumbre se obtienen como

$$U_{\mathrm{ale},j,*}^2 = \exp[\hat{q}_j(\tilde{\mathbf{z}}_*)]\,, \tag{7.18}$$

$$U_{\mathrm{epi},j,*} = \sigma_{f,j,*}, \tag{7.19}$$

$$U_{\mathrm{tot},j,*} = \sqrt{U_{\mathrm{epi},j,*}^2 + U_{\mathrm{ale},j,*}^2}, \tag{7.20}$$

donde $\sigma_{f,j,*}$ es la desviación estándar posterior de la función latente del GP de media. Las magnitudes anteriores se presentan en unidades físicas después de invertir la estandarización común.

La denominación U_{ale} se mantiene para conservar una taxonomía uniforme entre los

modelos, pero su interpretación requiere cautela. Al aprenderse a partir de e^{OOF}, esta componente puede reunir ruido irreducible, error del modelo de media y variabilidad entre grupos. Por ello, en B4 representa una *estimación heteroscedástica de la dispersión residual*, no una medición pura del ruido aleatorio físico.

El Cuadro 7.17 resume las decisiones propias de B4. Los datos, la partición congelada y la estandarización son los definidos en el entorno común; por tanto, no se repiten aquí.

Cuadro 7.17: Configuración específica del modelo B4.

Elemento	Configuración
Función en el estudio	Extensión heteroscedástica y ablación directa de B2
Etapa de media	Los dos GP exactos ARD-SE de B2, sin modificaciones
Etapa de dispersión	Dos GP independientes ajustados sobre residuos fuera de pliegue
Objetivo de la segunda etapa	Logaritmo del residuo cuadrático con corrección $c_{\chi^2} = -1{,}27036$
Semilla	42
U_{epi}	Desviación posterior latente del GP de media
U_{ale}	Estimación heteroscedástica de la dispersión residual
Incertidumbre total	Combinación cuadrática de U_{epi} y U_{ale}

Como B4 conserva la etapa de media de B2, ambos producen exactamente los mismos errores puntuales en validación y prueba ID. Esta igualdad constituye una comprobación de consistencia del artefacto y permite atribuir cualquier diferencia probabilística exclusivamente a la segunda etapa. El Cuadro 7.18 presenta las métricas correspondientes.

Cuadro 7.18: Desempeño de la media de B4 en la predicción del residual a 20 ms.

	d_{v_y} (m/s)		d_r (rad/s)	
Partición	RMSE	MAE	RMSE	MAE
Validación	0.008791	0.005860	0.006884	0.004620
Prueba ID	0.010684	0.008057	0.008624	0.006552

Los diagnósticos del Cuadro 7.19 muestran que, en prueba ID, la dispersión residual domina la incertidumbre total y presenta un orden de magnitud similar al estimado por B3, aunque los dos modelos la obtienen mediante mecanismos diferentes. La cobertura queda por debajo del 95 % nominal, especialmente para d_{v_y}, de modo que B4 también resulta ligeramente sobreconfiado en esta partición.

En validación, las coberturas fueron 93,71 % para d_{v_y} y 95,16 % para d_r, con NLL de $-3{,}6606$ y $-3{,}7967$, respectivamente. La degradación observada al pasar a prueba ID evidencia que una calibración cercana a la nominal en validación no garantiza que se conserve entre grupos no utilizados durante el ajuste.

Cuadro 7.19: Diagnósticos probabilísticos de B4 en prueba ID.

Magnitud	d_{v_y}	d_r
U_{epi} medio	0,001766 m/s	0,001841 rad/s
U_{ale} medio	0,009608 m/s	0,007899 rad/s
U_{tot} medio	0,009873 m/s	0,008252 rad/s
Cobertura del intervalo del 95 %	90,23 %	91,88 %
NLL gaussiano	−3,0422	−3,3273

La correlación de Spearman entre las incertidumbres instantáneas y el error absoluto se resume en el Cuadro 7.20. U_{ale} presenta una asociación positiva, pero débil, mientras que U_{epi} es prácticamente no correlacionada con el error a un paso. En consecuencia, estas señales no deben interpretarse aisladamente como predictores directos del próximo error.

Cuadro 7.20: Correlación de Spearman entre incertidumbre y error absoluto de B4 en prueba ID.

Indicador	$\lvert e_{v_y}\rvert$	$\lvert e_r\rvert$
U_{epi}	−0,0776	−0,0339
U_{ale}	0,1407	0,0849
U_{tot}	0,0425	0,0377

Finalmente, B4 reproduce las mejoras de la media de B2 frente a B0: reduce el RMSE de v_y en un 91,74 % y el de r en un 90,16 %. Su aportación no reside en una nueva corrección media, sino en reemplazar la dispersión constante de B2 por una función dependiente de la entrada. Esta relación convierte la comparación B2–B4 en una ablación directa del efecto de modelar heteroscedasticidad.

7.4. Escenarios de cambio de distribución

La campaña experimental se organizó en diez escenarios, E0–E9, diseñados para separar cambios en la excitación, variaciones observables del punto de operación, modificaciones latentes de la dinámica y cambios que ocurren durante la ejecución. En todos los escenarios se evaluaron B0–B4 sobre las mismas corridas. B0 proporciona la referencia puramente física; B1 permite medir la capacidad de una corrección determinista; y B2–B4 permiten estudiar, además del error predictivo, la respuesta de las componentes de incertidumbre disponibles en cada modelo. Los parámetros aprendidos y las estadísticas de normalización permanecieron congelados durante toda la campaña; ningún escenario E0–E9 se utilizó para reentrenar o readaptar los modelos.

El vehículo A corresponde a la configuración nominal empleada para generar los datos de entrenamiento. El vehículo B representa una configuración alternativa con cambios estructurales en propiedades como masa, inercias y neumáticos. La velocidad longitudinal

V_x forma parte del vector de entrada de los modelos residuales; en cambio, el coeficiente de adherencia μ y la identidad o los parámetros del vehículo no se entregan como entradas. Esta diferencia permite contrastar cambios observables de covariables con cambios dinámicos latentes.

El Cuadro 7.21 resume la configuración de las corridas. E0 utiliza corridas DLC y DLCT reservadas, no empleadas durante el entrenamiento, y constituye la referencia dentro de distribución. La maniobra *single lane change* (SLC) se incorpora como una excitación no observada durante el ajuste. Los demás escenarios modifican una o más condiciones respecto de la referencia E0.

Cuadro 7.21: Configuración de la campaña experimental E0–E9.

Reg.	Escenario	Maniobra o conjunto de evaluación	V_x (km/h)	μ	Vehículo
001	E0	DLC y DLCT; corridas reservadas	60	1.0	A
002	E1	SLC; maniobra nueva	60	1.0	A
003	E2	DLC y DLCT	50	1.0	A
004	E3	DLC y DLCT	70	1.0	A
005	E4	DLC y DLCT	60	0.8	A
006	E5	DLC y DLCT	60	0.6	A
007	E6	DLC y DLCT	60	0.3	A
008	E7	SLC; maniobra nueva	60	0.6	A
009	E8	DLC y DLCT	60	1.0	B
010	E9	DLC/DLCT continuo	60	$1{,}0 \rightarrow 0{,}6$	A

El Cuadro 7.22 presenta el tipo de cambio y la pregunta experimental asociada con cada escenario. La clasificación se refiere a la información disponible para los modelos, no solamente a la magnitud de la modificación física.

7.4.1. Referencia nominal y generalización de excitación: E0–E1

E0 establece el nivel de desempeño dentro de la distribución conocida. Aunque mantiene las maniobras DLC y DLCT, la velocidad nominal, la adherencia y el vehículo A, utiliza corridas completas que no participaron en el ajuste. Por tanto, E0 mide generalización entre corridas nominales y no desempeño sobre las muestras de entrenamiento. Sus errores e incertidumbres sirven como referencia para interpretar todos los incrementos observados en E1–E9.

E1 mantiene $V_x = 60\,\mathrm{km/h}$, $\mu = 1$ y el vehículo A, pero sustituye las maniobras de identificación por una única maniobra SLC. Este aislamiento permite evaluar la generalización ante un patrón de excitación no visto sin introducir simultáneamente un cambio en los parámetros físicos. La comparación principal es E1 frente a E0.

Cuadro 7.22: Propósito de los escenarios de la campaña experimental.

Escenario	Cambio aplicado	Clasificación	Pregunta experimental
E0	Ninguno	Referencia dentro de distribución	¿Los modelos aprendidos mantienen su capacidad predictiva en corridas nominales no utilizadas durante el entrenamiento?
E1	Maniobra SLC	Generalización de excitación	¿Generalizan a una trayectoria no vista cuando la configuración física permanece igual?
E2	$V_x \downarrow$	Cambio observable de covariable y punto de operación	¿Aumentan el error y U_{epi} al operar por debajo de la única velocidad de entrenamiento?
E3	$V_x \uparrow$	Cambio observable de covariable y punto de operación	¿Cómo responden la predicción y U_{epi} en un régimen superior y más exigente?
E4	$\mu \downarrow$ moderado	Cambio dinámico latente	¿Las incertidumbres reflejan una degradación causada por una variable física no observada?
E5	$\mu \downarrow$ fuerte	Cambio dinámico latente severo	¿Cómo evolucionan el error y las incertidumbres cuando aumenta la discrepancia dinámica?
E6	$\mu \downarrow$ extremo	Prueba extrema de la dinámica	¿Aparecen fallos confiados, caracterizados por error alto e incertidumbre epistémica baja?
E7	Maniobra SLC y $\mu = 0{,}6$	Cambio combinado	¿Cómo se comportan los modelos al combinar una excitación no vista con un cambio dinámico latente?
E8	Vehículo B	Cambio estructural de la dinámica	¿Las incertidumbres reflejan cambios de masa, inercias y neumáticos no incluidos en el vector de entrada?
E9	μ : 1,0 $\rightarrow$ 0,6 durante la corrida	Cambio dinámico durante la ejecución	¿Cómo evolucionan el error y las incertidumbres alrededor del instante de transición?

7.4.2. Cambios observables del punto de operación: E2–E3

E2 y E3 evalúan la extrapolación respecto de la única velocidad longitudinal presente en el entrenamiento. E2 reduce V_x de 60 a 50 km/h y E3 la aumenta a 70 km/h, manteniendo $\mu = 1$, el vehículo A y las familias de maniobras DLC y DLCT. Como V_x es una entrada de B1–B4, estos escenarios constituyen cambios observables de covariable y permiten comprobar si la incertidumbre epistémica de los modelos probabilísticos responde al alejamiento del dominio nominal. La evaluación separada de E2 y E3 permite, además, identificar una posible asimetría entre extrapolar hacia velocidades menores y hacerlo hacia un régimen más exigente.

7.4.3. Cambios dinámicos latentes de adherencia: E4–E6

E4–E6 forman una secuencia de severidad creciente en la que se mantienen $V_x = 60$ km/h, el vehículo A y las maniobras DLC y DLCT, mientras μ disminuye desde el valor nominal 1.0 hasta 0.8, 0.6 y 0.3. Dado que μ no pertenece al vector de entrada, estos escenarios modifican la relación entrada–salida de la planta sin proporcionar al modelo una indicación directa de la causa.

E4 representa una perturbación moderada; E5, un cambio fuerte; y E6, una prueba extrema. El análisis conjunto de los tres escenarios permite determinar si el error crece monótonamente con la discrepancia física y si U_{epi}, U_{ale} o U_{tot} acompañan ese crecimiento. E6 se utiliza de manera específica para buscar fallos confiados: intervalos en los que el error aumenta sin un incremento proporcional de la incertidumbre.

7.4.4. Cambio combinado de maniobra y adherencia: E7

E7 combina las dos modificaciones aisladas anteriormente: emplea la maniobra SLC no vista y reduce la adherencia a $\mu = 0{,}6$, manteniendo $V_x = 60$ km/h y el vehículo A. Las referencias naturales para su interpretación son E1, que contiene solamente el cambio de maniobra, y E5, que contiene solamente el mismo cambio de adherencia. Esta comparación permite examinar si la degradación conjunta puede explicarse a partir de los cambios aislados o si aparece una interacción adicional entre excitación y dinámica.

7.4.5. Cambio estructural del vehículo: E8

E8 conserva las condiciones nominales de maniobra, velocidad y adherencia, pero sustituye el vehículo A por el vehículo B. El escenario agrupa variaciones estructurales de masa, inercias y propiedades de los neumáticos que no se incluyen de forma explícita en el vector de entrada de los modelos aprendidos. Su comparación directa con E0 permite estudiar la sensibilidad al cambio de plataforma sin confundirla con variaciones de velocidad, superficie o maniobra. Al igual que en los escenarios de adherencia, los valores reales

de los parámetros modificados se utilizan para definir y analizar la prueba, pero no se proporcionan como entradas a B1–B4.

7.4.6. Cambio abrupto durante la ejecución: E9

E9 introduce una dimensión temporal ausente en los escenarios anteriores. Durante una ejecución continua basada en DLC/DLCT, μ cambia abruptamente de 1.0 a 0.6, mientras se mantienen $V_x = 60\,\mathrm{km/h}$ y el vehículo A. En lugar de resumir solamente el desempeño de toda la corrida, este escenario se analiza alrededor del instante de transición. El objetivo es caracterizar la evolución temporal del error y de las incertidumbres, así como cualquier retraso entre el cambio físico, la degradación predictiva y la respuesta de los indicadores disponibles. E0 y E5 proporcionan las referencias estacionarias antes y después del cambio, respectivamente.

7.5. Modelo aprendido e incertidumbre

7.6. Construcción y evaluación de la señal de validez

7.7. Uso de la señal de validez en MPC/NMPC

7.8. Arquitecturas de referencia y estudio de ablación

B0 – Solo modelo físico:
Controlador que utiliza un modelo físico sin residual aprendido.

B1 – Modelo aprendido sin supervisión de validez:
Controlador que utiliza un modelo físico y un residual aprendido, sin estimación de validez ni detección fuera de distribución.

B2 – Solo validez/incertidumbre:
Controlador que utiliza un modelo aprendido y una señal construida a partir de la incertidumbre y la calibración, sin un componente explícito de detección fuera de distribución.

B3 – Solo detección fuera de distribución:
Controlador que utiliza un modelo aprendido y una respuesta basada únicamente en la puntuación OOD, sin estimación probabilística de incertidumbre.

P – Propuesta:
Controlador que utiliza un modelo físico, un residual aprendido y la señal $C_k = g(U_{\mathrm{epi}}, U_{\mathrm{ale}}, \mathrm{Cal}, OOD)$ para adaptar el controlador MPC/NMPC.

7.9. Métricas de evaluación

7.9.1. Métricas del modelo

7.9.2. Métricas de incertidumbre, calibración y detección fuera de distribución

7.9.3. Métricas de desempeño en lazo cerrado

7.10. Criterio de robustez empírica

$$\Delta J_{\text{prop}} < \Delta J_{\text{ref}}, \tag{7.21}$$

7.11. Nivel de garantía y alcance de las conclusiones

7.12. Análisis estadístico y reproducibilidad

Capítulo 8

Resultados preliminares

8.1. Viabilidad del aprendizaje de modelos de dinámica vehicular

8.2. Comportamiento de la incertidumbre y de los indicadores fuera de distribución ante cambios de distribución

8.3. Integración preliminar con el control

8.4. Discusión de los resultados preliminares

Capítulo 9

Contribuciones esperadas

9.1. Estimación de la validez relevante para el control

9.2. Control vehicular con consideración de la validez

9.3. Caracterización de la validez durante la operación

9.4. Taxonomía experimental de cambios en la dinámica vehicular

9.5. Posibles extensiones

Capítulo 10

Plan de trabajo (prioridad 1)

10.1. Actividades pendientes

10.2. Cronograma

10.3. Hitos de decisión

Capítulo 11

Riesgos, limitaciones y estrategias de mitigación

11.1. Riesgo de redundancia entre incertidumbre y detección fuera de distribución

11.2. Riesgo de calibración inadecuada o de correlación débil con el error

11.3. Riesgo de que la adaptación del horizonte no mejore el desempeño en lazo cerrado

11.4. Riesgo computacional

11.5. Riesgo de ampliación del alcance

11.6. Limitaciones de las garantías formales

Capítulo 12

Conclusiones del examen de calificación

Bibliografía

[1] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. Model predictive contouring control for vehicle obstacle avoidance at the limit of handling. In Wei Huang and Mehdi Ahmadian, editors, *Advances in Dynamics of Vehicles on Roads and Tracks III*, volume 2 of *Lecture Notes in Mechanical Engineering*, pages 132–142. Springer, 2024.

[2] Alberto Bertipaglia, Mohsen Alirezaei, Riender Happee, and Barys Shyrokau. An unscented Kalman filter-informed neural network for vehicle sideslip angle estimation. *IEEE Transactions on Vehicular Technology*, 73(9):12731–12746, 2024.

[3] Bosch. 30 years of ESP: technology developed by Bosch evolves and continues to shape the future of mobility. Bosch Media Service Brasil, 2025. Press release in Portuguese; title translated into English. Accessed October 12, 2026.

[4] Bosch. Safe braking. Bosch Global, n.d. Accessed October 13, 2026.

[5] Lukas Brunke, Melissa Greeff, Adam W. Hall, Zhaocong Yuan, Siqi Zhou, Jacopo Panerati, and Angela P. Schoellig. Safe learning in robotics: From learning-based control to safe reinforcement learning. *Annual Review of Control, Robotics, and Autonomous Systems*, 5:411–444, 2022.

[6] Guoying Chen, Chenxiao Bi, Xuanming Zhao, Xinyu Wang, Zhenhai Gao, Wei Deng, Huili Yu, and Liunan Yang. Data-mechanism fused integrated motion control for distributed vehicle considering online model mismatch compensation. *IEEE Transactions on Vehicular Technology*, 75(9):19147–19160, 2026.

[7] Yutao Chen, Jie He, Jun Cheng, Jingli Huang, and Jie Huang. Hybrid offline–online Gaussian process regression-based model predictive control for autonomous vehicles trajectory tracking. *Engineering Applications of Artificial Intelligence*, 182:115841, 2026.

[8] Shuo Cheng, Bin-Bin Hu, Heng-Lai Wei, Liang Li, and Chen Lv. Deep learning-based hybrid dynamic modeling and improved handling stability assessment for autonomous vehicles at driving limits. *IEEE Transactions on Vehicular Technology*, 74(4):5582–5593, 2025. Published online December 11, 2024.

[9] J. Hu, H. Liu, S. Yi, and C. Huang. Lane-changing control strategy for distributed drive vehicles considering yaw stability. *IET Intelligent Transport Systems*, 19:e12605, 2025.

[10] Miren Isasa, Ángela Alonso-Solórzano, Itziar Gurrutxaga, and Heriberto Pérez-Acebo. A skid resistance predicting model for single carriageways. *Lubricants*, 13(8):365, 2025.

[11] Juraj Kabzan, Lukas Hewing, Alexander Liniger, and Melanie N. Zeilinger. Learning-based model predictive control for autonomous racing. *IEEE Robotics and Automation Letters*, 4(4):3363–3370, 2019.

[12] Dvij Kalaria, Qin Lin, and John M. Dolan. Adaptive planning and control with time-varying tire models for autonomous racing using extreme learning machine. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 10443–10449, 2024.

[13] Lun Li, Deping Wang, Zhicheng Chen, Bing Zhu, Jian Zhao, Haiqiao Li, Jiayi Han, Dongjian Song, and Peixing Zhang. Trajectory-tracking control of autonomous vehicles with dynamic nonlinear coupling characteristics and parameter uncertainty. *International Journal of Automotive Technology*, 27:1035–1049, 2026. Published online September 1, 2025.

[14] Wei Pan, Haoqi Hu, Yiding Hua, Han Wang, Lin Zhang, and Hong Chen. A real-time nonlinear robust MPC strategy for electric vehicle stability with model uncertainty. *Control Engineering Practice*, 172:106894, 2026.

[15] S. Salleh, R. Muhamad, and M.H. Abdillah. Performance of ralumac micro surfacing at blackspot eastbound, latar highway. *IOP Conference Series: Materials Science and Engineering*, 527(1):012054, 2019.

[16] Viktor Skrickij, Paulius Kojis, Eldar Šabanovič, Barys Shyrokau, and Valentin Ivanov. Review of integrated chassis control techniques for automated ground vehicles. *Sensors*, 24(2):600, 2024.

[17] Dongxu Su, Zhiguo Zhao, and Kun Zhao. Reinforcement learning-based tube nonlinear model predictive control for robust trajectory tracking control of autonomous vehicles. *IEEE Transactions on Vehicular Technology*, 75(9):18857–18870, 2026.

[18] Wenjie Wang, Hao Chen, Ran Shu, Solyeon Kwon, Kyoungseok Han, and Hongyu Shu. Adaptive deep Koopman operator for vehicle dynamics modeling: A physics-informed and tire-force-driven approach. *Expert Systems with Applications*, 333:134228, 2027. Available online August 29, 2026.

[19] Zihang Weng, Zhen Leng, Yuchuan Du, Chenglong Liu, Xinqiang Zhang, Danning Li, and Yulin He. Leveraging tabular prior-data fitted networks for accurate pavement friction coefficient prediction from 3d texture features. *Tribology International*, 218:111794, 2026.

[20] Feixiang Xu, Junkang Feng, Yafei Wang, Xiaoyi Wang, Chuanwang Shen, and Chen Zhou. Parallel self-learning adaptive strategy based on model predictive control for trajectory tracking of autonomous vehicles. *Engineering Applications of Artificial Intelligence*, 173:114495, 2026.

[21] Kumlachew Yeneneh and Gadisa Sufe. AutoDyn: robust model predictive control design for trajectory tracking under varying vehicle dynamics. *Scientific Reports*, 16:25130, 2026.

[22] Kumlachew Yeneneh, Bisrat Yoseph, and Gadisa Sufe. Adaptive model predictive control for robust lateral motion tracking of semi-autonomous vehicles with dynamic parameter variation. *Scientific Reports*, 16:716, 2026. Published online November 30, 2025.

[23] Duk Sun Yun and Byung Chul Lim. Real-time axle-load sensing and AI-enhanced braking-distance prediction for multi-axle heavy-duty trucks. *Applied Sciences*, 16:1547, 2026.

[24] Zhisong Zhou, Yafei Wang, Xulei Liu, Zexing Li, Mingyu Wu, and Guofeng Zhou. Hybrid of neural network and physics-based estimator for vehicle longitudinal dynamics modeling using limited driving data. *IEEE Transactions on Intelligent Transportation Systems*, 26(10):16735–16746, 2025.