

Universidad XXXXX

Programa de Doctorado en XXXXX

Título provisional de la investigación

Estimación de validez en tiempo de ejecución para la integración de
modelos híbridos aprendidos en control de dinámica vehicular

Nombre del doctorando

Director / Orientador

Año

Resumen

Índice general

1. Introducción	4
1.1. Contexto y motivación	4
1.2. Problema científico	4
1.3. Delimitación del problema	4
1.4. Brecha de investigación	4
1.5. Pregunta de investigación	4
1.6. Preguntas específicas de investigación	4
1.7. Hipótesis de investigación	5
2. Objetivos	6
2.1. Objetivo general	6
2.2. Objetivos específicos	6
3. Fundamentos de dinámica y control vehicular	8
3.1. Dinámica vehicular relevante para control	8
3.2. Modelos control-oriented y model mismatch	8
3.3. Modelos híbridos: physics + learned residual	8
3.4. Control predictivo basado en modelo	8
3.5. Control Barrier Functions como extensión opcional	8
4. Información aprendida y validez en tiempo de ejecución	9
4.1. Información aprendida relevante para el controlador	9
4.2. Incertidumbre predictiva	9
4.2.1. Incertidumbre aleatoria	9
4.2.2. Incertidumbre epistémica	9
4.2.3. Calibración	9
4.3. OOD y distribution shift en dinámica vehicular	9
4.3.1. Régimen físico no representado	9
4.3.2. Dynamics OOD	9
4.3.3. Input OOD	9
4.3.4. Fallo o degradación sensorial	9

4.4. Validez/confianza runtime	9
4.5. Validez relevante para control	10
5. Estado del arte	11
5.1. Estrategia de revisión de literatura	11
5.2. Modelos aprendidos e híbridos en control de dinámica vehicular	11
5.3. Uncertainty-aware learned dynamics para control	11
5.4. OOD, distribution shift y runtime monitoring	11
5.5. Validity-aware y confidence-aware control	11
5.6. Síntesis crítica y brecha	11
6. Marco conceptual y arquitectura propuesta	12
6.1. Cadena shift–validity–control	12
6.2. Modelo híbrido de predicción	12
6.3. Estimador de validez	12
6.4. Integración con MPC/NMPC	12
6.5. Extensiones opcionales	12
6.5.1. Modulación de una CBF	12
6.5.2. Adquisición de datos y reentrenamiento	12
7. Metodología de investigación y validación	13
7.1. Estrategia general	13
7.2. Escenarios de shift	14
7.2.1. Cambio de fricción desconocida	14
7.2.2. Extensión del rango de velocidad	14
7.2.3. Fallo/degradación de sensores	14
7.2.4. Input OOD	14
7.3. Modelo aprendido e incertidumbre	14
7.4. Construcción y evaluación de la señal de validez	14
7.5. Integración validity-aware con MPC/NMPC	14
7.6. Baselines y ablation study	14
7.7. Métricas de evaluación	15
7.7.1. Métricas del modelo	15
7.7.2. Métricas de uncertainty, calibration y OOD	15
7.7.3. Métricas closed-loop	15
7.8. Criterio de robustez empírica	15
7.9. Nivel de garantía y alcance de las conclusiones	15
7.10. Análisis estadístico y reproducibilidad	15

8. Resultados preliminares	16
8.1. Viabilidad del modelado aprendido de dinámica vehicular	16
8.2. Comportamiento de uncertainty y OOD bajo shifts	16
8.3. Integración preliminar con control	16
8.4. Discusión de resultados preliminares	16
9. Contribuciones esperadas	17
9.1. Control-relevant validity estimation	17
9.2. Validity-aware vehicle control	17
9.3. Runtime validity characterization	17
9.4. Taxonomía experimental de shifts vehiculares	17
9.5. Extensiones potenciales	17
10. Plan de trabajo	18
10.1. Actividades restantes	18
10.2. Cronograma	18
10.3. Hitos de decisión	18
11. Riesgos, limitaciones y estrategias de mitigación	19
11.1. Riesgo de redundancia entre uncertainty y OOD	19
11.2. Riesgo de mala calibración o mala correlación con error	19
11.3. Riesgo de que la adaptación del horizonte no mejore closed-loop	19
11.4. Riesgo computacional	19
11.5. Riesgo de sobreextensión del alcance	19
11.6. Limitaciones de garantías formales	19
12. Conclusiones del examen de calificación	20

Capítulo 1

Introducción

1.1. Contexto y motivación

1.2. Problema científico

1.3. Delimitación del problema

1.4. Brecha de investigación

1.5. Pregunta de investigación

¿Cómo estimar en tiempo de ejecución la validez de un modelo residual aprendido de dinámica vehicular y utilizar esa estimación para adaptar un controlador MPC/NMPC ante condiciones de operación no representadas durante el entrenamiento?

1.6. Preguntas específicas de investigación

P1: ¿Qué tipos de shifts físicamente relevantes en dinámica vehicular producen pérdida significativa de validez del residual aprendido?

P2: ¿Qué información proporcionan la incertidumbre epistémica, la incertidumbre aleatoria, la calibración y un indicador OOD sobre el error del modelo relevante para control?

P3: ¿En qué medida las señales de uncertainty, calibration y OOD son complementarias o redundantes para caracterizar validez runtime?

- P4:** ¿Cómo construir una señal de confianza/validez $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Calibration}, \text{OOD})$ que guarde relación con el error relevante para el controlador?
- P5:** ¿Cómo debe utilizarse C_k para adaptar el horizonte de un MPC/NMPC de manera que se reduzca la degradación closed-loop cuando disminuye la validez del modelo aprendido?
- P6:** ¿Qué mejora ofrece la arquitectura propuesta frente a un controlador basado únicamente en el modelo físico, un controlador que utiliza el modelo aprendido sin monitoreo de validez y arquitecturas que utilizan únicamente validity o únicamente OOD?
- P7:** Como extensión opcional, ¿puede la información de validez emplearse para modificar la acción de una CBF o activar estrategias de actualización de datos/modelo ante incertidumbre epistémica?

1.7. Hipótesis de investigación

La combinación calibrada de incertidumbre epistémica, incertidumbre aleatoria y evidencia de distribución fuera del dominio puede proporcionar una estimación útil de la validez runtime de un residual aprendido de dinámica vehicular; al incorporar explícitamente esta estimación en la adaptación de un controlador MPC/NMPC, es posible reducir la degradación de desempeño closed-loop bajo cambios de régimen respecto a arquitecturas que utilizan el modelo aprendido sin validity awareness.

Capítulo 2

Objetivos

2.1. Objetivo general

Desarrollar y evaluar una metodología de estimación de validez en tiempo real para un modelo híbrido de dinámica vehicular basado en un modelo físico y un residual aprendido, e integrar dicha estimación en un controlador MPC/NMPC para reducir la degradación del desempeño closed-loop ante condiciones de operación no representadas durante el entrenamiento.

2.2. Objetivos específicos

- OE1:** Formular una arquitectura híbrida de dinámica vehicular compuesta por un modelo físico control-oriented y un residual aprendido.
- OE2:** Definir operacionalmente los tipos de shift/OOD relevantes para el estudio, distinguiendo al menos régimen físico no representado y dynamics OOD, e incluyendo input OOD si el alcance temporal lo permite.
- OE3:** Estimar y calibrar incertidumbre aleatoria y epistémica del modelo aprendido mediante un modelo heteroscedástico y un ensemble pequeño, complementado con un indicador OOD de bajo costo computacional.
- OE4:** Caracterizar experimentalmente la relación entre shift, uncertainty, calibration, OOD, error de predicción y error relevante para control.
- OE5:** Definir una representación de confianza/validez runtime $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Calibration}, \text{OOD})$ y evaluar su capacidad para anticipar o representar degradación del modelo útil para el controlador.
- OE6:** Integrar la señal de validez en un MPC/NMPC mediante adaptación de su horizonte y evaluar el efecto sobre desempeño y robustez empírica closed-loop.

- OE7:** Comparar la propuesta con arquitecturas de referencia que separen el efecto del modelo aprendido, la estimación de validez y la detección OOD.
- OE8:** Como extensión, si el cronograma lo permite, evaluar el uso de la señal de validez en una CBF y/o una estrategia de adquisición y reentrenamiento basada en DAgger para condiciones asociadas a incertidumbre epistémica.

Capítulo 3

Fundamentos de dinámica y control vehicular

- 3.1. Dinámica vehicular relevante para control
- 3.2. Modelos control-oriented y model mismatch
- 3.3. Modelos híbridos: physics + learned residual
- 3.4. Control predictivo basado en modelo
- 3.5. Control Barrier Functions como extensión opcional

Capítulo 4

Información aprendida y validez en tiempo de ejecución

- 4.1. Información aprendida relevante para el controlador
- 4.2. Incertidumbre predictiva
 - 4.2.1. Incertidumbre aleatoria
 - 4.2.2. Incertidumbre epistémica
 - 4.2.3. Calibración
- 4.3. OOD y distribution shift en dinámica vehicular
 - 4.3.1. Régimen físico no representado
 - 4.3.2. Dynamics OOD
 - 4.3.3. Input OOD
 - 4.3.4. Fallo o degradación sensorial
- 4.4. Validez/confianza runtime

$$C_k = g(U_{\text{epi},k}, U_{\text{ale},k}, \text{Cal}_k, S_{\text{OOD},k}), \quad (4.1)$$

4.5. Validez relevante para control

Capítulo 5

Estado del arte

- 5.1. Estrategia de revisión de literatura
- 5.2. Modelos aprendidos e híbridos en control de dinámica vehicular
- 5.3. Uncertainty-aware learned dynamics para control
- 5.4. OOD, distribution shift y runtime monitoring
- 5.5. Validity-aware y confidence-aware control
- 5.6. Síntesis crítica y brecha

Capítulo 6

Marco conceptual y arquitectura propuesta

6.1. Cadena shift–validity–control

6.2. Modelo híbrido de predicción

6.3. Estimador de validez

6.4. Integración con MPC/NMPC

6.5. Extensiones opcionales

6.5.1. Modulación de una CBF

6.5.2. Adquisición de datos y reentrenamiento

Capítulo 7

Metodología de investigación y validación

7.1. Estrategia general

- E1:** Establecer el modelo físico control-oriented y el controlador MPC/NMPC de referencia.
- E2:** Entrenar el residual aprendido y cuantificar su mejora y sus límites frente al modelo físico dentro del dominio nominal.
- E3:** Implementar estimación de incertidumbre aleatoria y epistémica, calibración y un score OOD de bajo costo.
- E4:** Diseñar shifts vehiculares físicamente interpretables y caracterizar cómo afectan predicción, incertidumbre, OOD y validez.
- E5:** Construir y validar la señal C_k respecto a error relevante para control.
- E6:** Integrar C_k en la adaptación del MPC/NMPC.
- E7:** Comparar baselines y propuesta bajo condiciones nominales y OOD.
- E8:** Evaluar robustez empírica y, si el desarrollo lo permite, incorporar extensiones CBF y/o DAgger.

7.2. Escenarios de shift

7.2.1. Cambio de fricción desconocida

7.2.2. Extensión del rango de velocidad

7.2.3. Fallo/degradación de sensores

7.2.4. Input OOD

7.3. Modelo aprendido e incertidumbre

7.4. Construcción y evaluación de la señal de validez

7.5. Integración validity-aware con MPC/NMPC

7.6. Baselines y ablation study

B0 – Physics-only: controlador con modelo físico sin residual aprendido.

B1 – Learned/no-awareness: controlador con modelo physics + learned residual, sin estimación de validity ni detección OOD.

B2 – Validity/uncertainty-only: controlador con modelo aprendido y señal construida a partir de uncertainty/calibration, excluyendo el componente OOD explícito.

B3 – OOD-only: controlador con modelo aprendido y reacción basada únicamente en el score OOD, sin estimación probabilística de uncertainty.

P – Proposed: controlador con modelo physics + learned residual y señal $C_k = g(U_{\text{epi}}, U_{\text{ale}}, \text{Cal}, \text{OOD})$ utilizada para adaptar el MPC/NMPC.

7.7. Métricas de evaluación

7.7.1. Métricas del modelo

7.7.2. Métricas de uncertainty, calibration y OOD

7.7.3. Métricas closed-loop

7.8. Criterio de robustez empírica

$$\Delta J_{\text{prop}} < \Delta J_{\text{baseline}}, \tag{7.1}$$

7.9. Nivel de garantía y alcance de las conclusiones

7.10. Análisis estadístico y reproducibilidad

Capítulo 8

Resultados preliminares

- 8.1. Viabilidad del modelado aprendido de dinámica vehicular
- 8.2. Comportamiento de uncertainty y OOD bajo shifts
- 8.3. Integración preliminar con control
- 8.4. Discusión de resultados preliminares

Capítulo 9

Contribuciones esperadas

- 9.1. Control-relevant validity estimation
- 9.2. Validity-aware vehicle control
- 9.3. Runtime validity characterization
- 9.4. Taxonomía experimental de shifts vehiculares
- 9.5. Extensiones potenciales

Capítulo 10

Plan de trabajo

10.1. Actividades restantes

10.2. Cronograma

10.3. Hitos de decisión

Capítulo 11

Riesgos, limitaciones y estrategias de mitigación

- 11.1. Riesgo de redundancia entre uncertainty y OOD
- 11.2. Riesgo de mala calibración o mala correlación con error
- 11.3. Riesgo de que la adaptación del horizonte no mejore closed-loop
- 11.4. Riesgo computacional
- 11.5. Riesgo de sobreextensión del alcance
- 11.6. Limitaciones de garantías formales

Capítulo 12

Conclusiones del examen de calificación